

MÉMOIRE DE RECHERCHE APPLIQUÉE

Qualification préalable d'un corpus d'évaluation pour des agents d'intelligence artificielle produisant des requêtes SQL

*Conception et mise à l'épreuve d'un protocole local francophone de
reconstruction, de traçabilité et de couverture relationnelle*

James Ripoll

Juillet 2026

Résumé

Ce mémoire étudie les conditions qui doivent être réunies avant de mesurer l'exactitude d'un agent d'intelligence artificielle chargé de répondre, en français, à une question d'analyse de données par SQL. Le point de départ est simple : une base SQLite peut être lisible, techniquement valide et interrogée sans erreur, tout en ne contenant pas une information relationnelle suffisante pour permettre une comparaison interprétable entre la sortie d'un agent et une requête SQL de référence. L'enjeu n'est donc pas d'établir un classement d'outils, mais de qualifier l'environnement de données qui rendrait, ou non, ce classement défendable.

L'étude s'appuie sur un corpus local reconstruit à partir de questions françaises, de définitions de tables, de fichiers JSON et d'éléments disponibles dans un dépôt de travail. L'inventaire local documente 547 questions françaises, 123 tâches associées à des bases SQLite disponibles et 29 bases distinctes ; une sélection pilote comporte 20 tâches. Les données effectivement manipulées sont des échantillons locaux, généralement limités à cinq lignes par table. Elles ne sont pas assimilées à un environnement officiel externe [E01-E07].

L'audit initial classe les 20 tâches pilotes en 13 tâches Ambre, 7 tâches au statut Rouge et aucune tâche au statut Vert. L'étude de cas local023 met ensuite au jour une cause précise de dégradation : des fichiers JSON français emploient des clés traduites alors que le schéma et la procédure d'insertion historique attendent des colonnes anglaises. L'appel `row.get(col)` sur une clé anglaise absente introduit alors des valeurs NULL dans sept colonnes critiques. Une correspondance explicite, limitée et versionnée restaure ces valeurs, fait passer local023 de Rouge à Ambre et réduit les divergences de 7 à 0. La tâche demeure toutefois non éligible à une mesure d'exactitude : les jointures nécessaires et la requête SQL de référence retournent toujours zéro ligne [E53-E56].

L'intervention est rejouée par quatre reconstructions fraîches. Les deux reconstructions historiques partagent une même empreinte logique ; les deux reconstructions corrigées partagent une autre empreinte. Cette propriété établit la rejouabilité de l'intervention dans le périmètre local documenté, sans extrapolation à une autre machine ou à une autre version logicielle [E57-E60]. Le même raisonnement est ensuite étendu aux 20 tâches : une grille Vert / Ambre / Rouge est formalisée, rejoue les 20 statuts historiques sans divergence, puis guide une étude de sensibilité, la correction de six divergences supplémentaires et un audit de couverture relationnelle [E61-E72].

Après correction explicitement documentée, les 358 divergences critiques observées dans le périmètre étudié sont ramenées à zéro et les 20 tâches sont classées Ambre ; aucune ne conserve le statut Rouge et aucune n'atteint le statut Vert. L'absence de tâche Verte ne relève plus d'une perte résiduelle démontrée à l'importation. Elle tient principalement à l'absence de relations nécessaires dans certains échantillons sources et, pour les autres tâches, à l'insuffisance des preuves relationnelles disponibles. La décision méthodologique est donc de ne pas calculer de score d'agent dans cet environnement local. Le résultat principal est une procédure de qualification, de correction contrôlée et de décision hors mesure, plutôt qu'un résultat de performance [E68-E72].

Mots-clés : agents d'intelligence artificielle ; requêtes SQL ; qualification des données ; traçabilité ; couverture relationnelle.

Abstract

This applied research dissertation examines the conditions that must be satisfied before measuring the accuracy of an artificial intelligence agent asked to answer a data-analysis question in French by producing SQL. A SQLite database may be readable, technically valid and queryable without error while still lacking the relational information required for an interpretable comparison between an agent's output and a reference SQL query. The aim is therefore not to rank tools, but to qualify the data environment that would make such a ranking scientifically defensible.

The study relies on a locally reconstructed corpus combining French questions, table definitions, JSON samples and artifacts available in a working repository. The local inventory contains 547 French questions, 123 tasks associated with available SQLite databases and 29 distinct databases; a deterministic pilot set comprises 20 tasks. The data actually used are local samples, generally limited to five rows per table, and are not treated as an official external distribution.

The initial audit assigns Amber status to 13 tasks, Red status to 7 tasks and Green status to none. The local023 case study identifies a specific reconstruction mechanism: French JSON keys are processed by a historical import procedure that expects English column names, silently inserting NULL values into seven critical columns. Explicit, versioned mappings restore the values and remove the observed import divergences. The task nevertheless remains ineligible for an accuracy measurement because the required joins and the reference query still produce no interpretable result.

Across the pilot sample, 358 critical divergences are reduced to zero, all 20 tasks become Amber, and no task reaches Green status. The main contribution is a traceable qualification protocol combining provenance, reconstruction, value preservation, relational coverage, reference interpretability and local replayability. In the environment studied, the scientifically justified decision is therefore to refrain from publishing an agent ranking rather than report a misleading score.

Keywords: artificial intelligence agents; Text-to-SQL; data qualification; provenance; relational coverage; local replayability.

Synthèse exécutive

Ce travail partait d'un objectif concret : comparer plusieurs agents capables d'examiner une base de données et de produire une requête SQL à partir d'une question en français. Avant de lancer une campagne comparative, il fallait toutefois reconstruire localement les bases et préparer un espace de travail identique pour chaque outil. Les premiers contrôles ont montré que les fichiers SQLite s'ouvraient correctement. Pourtant, plusieurs requêtes de référence ne produisaient aucun résultat exploitable et certaines colonnes essentielles étaient vides. La question de recherche s'est alors déplacée : avant de demander quel agent est le meilleur, il fallait déterminer si les tâches permettaient réellement de les comparer.

Le mémoire propose donc un protocole de qualification préalable. Celui-ci distingue cinq niveaux : la provenance des fichiers, la reconstruction de la base, la conservation des valeurs, la présence des relations nécessaires et l'interprétabilité du résultat de référence. Une tâche n'est déclarée Verte que lorsque toutes ces conditions sont établies. Un défaut critique démontré conduit au statut Rouge ; une preuve manquante ou ambiguë conduit au statut Ambre. Les tâches Ambre et Rouge restent hors mesure d'exactitude.

L'application de ce protocole à 20 tâches locales produit un résultat important. Sept tâches étaient initialement Rouge en raison de pertes de valeurs lors de l'importation. Ces pertes ont été expliquées par des incompatibilités entre les noms français utilisés dans certains fichiers JSON et les noms anglais attendus par le schéma. Des correspondances explicites ont supprimé 358 divergences. Les sept tâches Rouge sont alors devenues Ambre. Aucune n'est toutefois devenue Verte, car les échantillons ne démontrent pas les jointures et les résultats de référence nécessaires à une mesure fiable.

La contribution principale n'est donc pas la correction d'un simple défaut informatique. Elle réside dans une méthode qui oblige à vérifier le support expérimental avant d'interpréter le comportement des agents. Dans le cas étudié, la conclusion la plus rigoureuse consiste à ne pas publier de classement. Ce refus de calculer un score n'est pas une absence de résultat : il protège l'étude contre une comparaison qui aurait attribué aux agents des effets provenant en réalité des données locales.

Avertissement méthodologique

Le présent document est un mémoire de recherche appliquée indépendant. Il ne constitue ni une thèse de doctorat, ni une évaluation officielle des distributions de Spider, MultiSpider ou Spider 2.0. Il porte exclusivement sur un environnement local reconstruit à partir des fichiers, scripts, configurations et échantillons identifiés dans le registre de preuves.

Les observations concernant Vibe et Codex décrivent deux exécutions locales. Elles ne permettent ni un classement, ni une conclusion générale sur les produits ou les modèles.

Aucun résultat n'est attribué à Gemini, faute d'artefact expérimental documenté.

Les expressions « tâche Verte », « tâche Ambre » et « tâche Rouge » qualifient le support de mesure, et non la qualité d'un agent. Toute conclusion est limitée au périmètre local, aux versions et aux artefacts effectivement étudiés.

Le document distingue systématiquement les faits observés, les diagnostics étayés, les propositions méthodologiques et les limites. Lorsqu'une preuve manque, l'incertitude est conservée au lieu d'être remplacée par une hypothèse.

Note sur l'assistance par intelligence artificielle

Ce mémoire a été conçu, piloté et interprété sous ma responsabilité. Des outils d'intelligence artificielle ont été employés comme assistants techniques et éditoriaux, notamment pour l'exploration du dépôt, l'exécution de scripts, la vérification de certains artefacts et l'amélioration de la rédaction. J'ai défini la problématique, validé le protocole, contrôlé les résultats et j'assume l'ensemble des analyses et conclusions présentées.

Table des matières

Résumé	2
Abstract	3
Synthèse exécutive	4
Avertissement méthodologique	5
Note sur l'assistance par intelligence artificielle	6
Liste des tableaux	12
Liste des figures	13
Glossaire	14
1. Introduction générale	15
1.1. Contexte général : des modèles de langage aux agents Text-to-SQL	15
1.2. Le problème scientifique : une mesure peut être précise sans être interprétable	16
1.3. Genèse de la recherche et réorientation du projet	17
1.4. Objectifs du mémoire	18
1.5. Questions de recherche	19
1.6. Hypothèses de travail	20
1.7. Contributions du mémoire	20
1.8. Périmètre de l'étude	21
1.9. Démarche scientifique adoptée	22
1.10. Organisation du mémoire	23
2. État de l'art et enjeux de l'évaluation	24
2.1. Le Text-to-SQL : permettre l'interrogation des bases en langage naturel	24
2.2. Évolution des approches : des règles aux modèles de langage	25
2.3. Les référentiels d'évaluation et la généralisation à des schémas non vus	25
2.4. Multilinguisme, robustesse et environnements proches des usages réels	26
2.5. Métriques : correspondance structurelle, exécution et tests sémantiques	26
2.6. Qualité des données, provenance et reproductibilité	27
2.7. Lacune méthodologique et positionnement du mémoire	28
2.8. Synthèse critique de l'état de l'art	29
2.9. Cadre conceptuel retenu : du corpus disponible à la mesure autorisée	31
3. Genèse du projet, périmètre empirique et données locales	33
3.1. Genèse du projet et choix d'un corpus existant	33
3.2. Construction d'un environnement local et inventaire	33

3.3. Origine des fichiers, choix multilingue et prudence de provenance	34
3.4. Pourquoi les échantillons limités posent un problème relationnel	35
3.5. Périmètre des conclusions	36
3.6. Des premières observations à la reformulation de la problématique	37
4. Méthode : protocole de qualification préalable	38
4.1. Pourquoi proposer un protocole de qualification préalable ?	38
4.2. Sept règles minimales	39
4.3. Logique de décision	40
4.4. Filiation des données et interventions contrôlées	41
4.5. Rejouabilité, tests et registre de preuves	41
4.6. Conditions d'exécution des agents	42
4.7. Les niveaux de qualification proposés	43
4.8. Pourquoi trois niveaux ?	43
4.9. Principes de décision et propriétés attendues	44
4.10. Validité de construit et autorisation de mesure	45
5. Mise à l'épreuve expérimentale du protocole	47
5.1. Objectif et organisation des expérimentations	47
5.2. Audit initial de viabilité	47
5.2.1. Enseignement méthodologique	48
5.3. Étude de cas local023 : diagnostic causal	49
5.3.1. Pourquoi le diagnostic est causal, mais local	50
5.3.2. Enseignement méthodologique	51
5.4. Intervention contrôlée sur local023	51
5.4.1. Ce que la correction démontre - et ce qu'elle ne démontre pas	52
5.5. Rejouabilité locale par empreintes logiques	53
5.5.1. Portée de la répétition	54
5.6. Formalisation et vérification de la grille de viabilité	54
5.6.1. Risque de circularité	55
5.7. Sensibilité du pilote aux divergences de correspondance	55
5.7.1. De l'étude de cas à l'audit du pilote	56
5.8. Correction contrôlée des six divergences restantes	56

5.8.1. Effet consolidé de la correction	57
5.9. Analyse de la couverture relationnelle	58
5.9.1. Pourquoi les relations ne sont pas recréées artificiellement	59
5.10. Résultats consolidés	59
5.10.1. Réponse synthétique aux cinq questions de recherche	61
5.11. Observations documentées sur deux exécutions d'agents	61
5.11.1. Pourquoi ces exécutions ne constituent pas une comparaison	62
5.12. Réponses aux questions de recherche	63
6. Discussion, limites et recommandations	64
6.1. Une méthode de qualification, et non un jugement sur les référentiels existants	64
6.2. Pourquoi cet environnement local constituait un cas d'étude pertinent	65
6.3. Une base techniquement valide n'est pas nécessairement une tâche mesurable	65
6.4. Le refus de calculer un score comme résultat scientifique	66
6.5. Portée potentielle et limites de généralisation de la méthode	67
6.6. Comportements des agents face à une tâche non qualifiée	67
6.7. Menaces à la validité	69
6.7.1. Validité interne	69
6.7.2. Validité de la grille	70
6.7.3. Validité externe	70
6.7.4. Rejouabilité locale et réplication indépendante	71
6.7.5. Représentativité des échantillons	71
6.7.6. Provenance, versions et droits de redistribution	72
6.8. Recommandations techniques et méthodologiques	72
6.8.1. Conserver un inventaire exact des entrées	73
6.8.2. Séparer les données sources, historiques et corrigées	73
6.8.3. Déclarer explicitement les correspondances de colonnes	74
6.8.4. Tester les valeurs avant et après importation	74

6.8.5. Préserver les relations lors de l'échantillonnage	74
6.8.6. Vérifier la requête de référence sur la base effectivement distribuée	75
6.8.7. Autoriser explicitement la mise hors score	75
6.9. Perspectives de recherche	75
6.10. Implications pour les futurs environnements d'évaluation	76
6.11. Contribution théorique : quatre propositions issues du cas étudié	77
6.12. Conditions d'une validation externe du protocole	78
7. Conclusion générale	79
7.1. Retour sur la problématique	79
7.2. Principaux résultats	79
7.3. Contribution principale	80
7.4. Une conclusion négative, mais scientifiquement utile	80
7.5. Portée et limites de la conclusion	81
7.6. Conclusion finale	81
Références bibliographiques	83
Annexes techniques	88
Annexe A - Registre de preuves (79 entrées)	89
Annexe B - Filiation des colonnes critiques de local023	95
Annexe C - Intervention et rejouabilité local023	96
Annexe D - Grille de viabilité	97
Annexe E - Sensibilité, correction et couverture relationnelle	98
Annexe F - Validation post-exécution Codex sur local023	99
Annexe G - Registre des scripts, commandes et tests exécutés	100
Annexe H - Limites ouvertes et conditions de poursuite	101
Annexe I - Guide détaillé d'application du protocole	102
Annexe I.1. Informations à réunir avant l'audit	102
Annexe I.2. Étape 1 - Vérifier la provenance	102
Annexe I.3. Étape 2 - Vérifier la reconstruction technique	102
Annexe I.4. Étape 3 - Identifier les éléments nécessaires à la tâche	103
Annexe I.5. Étape 4 - Vérifier la filiation des colonnes	103

Annexe I.6. Étape 5 - Vérifier les relations	103
Annexe I.7. Étape 6 - Exécuter la requête de référence	103
Annexe I.8. Étape 7 - Vérifier la jouabilité	104
Annexe I.9. Étape 8 - Attribuer le statut	104
Annexe I.10. Modèle de fiche synthétique de qualification	104
Annexe J - Chronologie méthodologique détaillée	105
Annexe J.1. Objectif initial	105
Annexe J.2. Préparation de l'environnement	105
Annexe J.3. Apparition des premières limites	105
Annexe J.4. Étude de cas et démonstration causale	105
Annexe J.5. Extension au pilote	105
Annexe J.6. Audit relationnel	105
Annexe J.7. Décision finale	106
Annexe K - Extrait de code et règle de lecture	107
Annexe L - Registre synthétique des tests automatisés	108
Annexe M - Règles de formulation scientifique	109
Annexe N - Matrice de conservation des résultats et éléments scientifiques	110

Liste des tableaux

- Tableau 1 - Questions de recherche et critères de réponse.
- Tableau 2 - Corpus local et périmètre empirique.
- Tableau 3 - Règles minimales de la grille de viabilité.
- Tableau 4 - Distribution initiale des statuts de viabilité.
- Tableau 5 - Filiation des sept colonnes critiques de local023.
- Tableau 6 - Effet de l'intervention contrôlée sur local023.
- Tableau 7 - Empreintes logiques des reconstructions local023.
- Tableau 8 - Rejeu de la grille de viabilité.
- Tableau 9 - Sensibilité des tâches aux divergences de correspondance.
- Tableau 10 - Correction contrôlée des six tâches restantes.
- Tableau 11 - Diagnostics de couverture relationnelle.
- Tableau 12 - Synthèse consolidée des résultats.
- Tableau 13 - Observations d'exécution sur local023.
- Tableau 14 - Menaces à la validité et réponses documentaires.
- Tableau 15 - Recommandations techniques et méthodologiques.
- Tableau A1 - Informations à réunir avant l'audit.
- Tableau A2 - Modèle de fiche synthétique de qualification d'une tâche.
- Tableau A3 - Registre synthétique des tests automatisés.
- Tableau A4 - Règles de formulation scientifique.
- Tableau A5 - Matrice de conservation des résultats et éléments scientifiques.

Liste des figures

Figure 1 - Genèse et réorientation de la recherche.

Figure 2 - Chaîne de qualification préalable.

Figure 3 - Arbre de décision de la grille de viabilité.

Figure 4 - Chaîne causale local023.

Figure 5 - Rejouabilité locale par empreintes logiques.

Figure 6 - Diagnostics de couverture relationnelle.

Figure 7 - Évolution des statuts de viabilité.

Glossaire

Terme	Définition retenue
Agent d'intelligence artificielle	Système capable d'examiner des fichiers, d'exécuter des commandes ou des requêtes et de produire une sortie structurée dans un espace de travail défini.
Corpus local	Ensemble des questions, schémas, fichiers de données, bases reconstruites et références effectivement utilisés dans l'étude.
Référentiel d'évaluation	Ensemble organisé de tâches et de règles permettant de comparer des systèmes. Le terme ne préjuge pas de la qualité ni du caractère officiel des données.
Conversion de questions vers SQL	Tâche consistant à traduire une question formulée en langage naturel en une requête SQL destinée à une base relationnelle. Le terme anglais Text-to-SQL est conservé dans les titres de publications.
Base SQLite locale	Fichier de base relationnelle reconstruit dans l'environnement de travail à partir de définitions de tables et d'échantillons disponibles.
Correspondance explicite de colonnes	Association versionnée entre une clé d'un fichier source et une colonne du schéma cible. Elle est justifiée par les fichiers disponibles et n'est pas déduite silencieusement.
Couverture relationnelle	Degré auquel les clés, relations et résultats nécessaires à une question sont présents et démontrables dans l'échantillon local.
Empreinte logique	Empreinte numérique calculée sur une représentation normalisée du schéma et du contenu d'une base afin de comparer des reconstructions indépendamment de leur encodage binaire.
Rouge (RED)	Statut attribué lorsqu'un défaut critique démontré empêche la reconstruction ou l'interprétation minimale de la tâche.
Ambre (AMBER)	Statut indiquant qu'un environnement peut être techniquement exploitable, mais qu'une preuve nécessaire à la mesure manque, demeure ambiguë ou n'est pas établie.
Vert (GREEN)	Statut réservé aux tâches pour lesquelles toutes les conditions nécessaires à une mesure d'exactitude sont positivement établies.
Rejouabilité locale	Capacité à reproduire un résultat dans le périmètre technique documenté. Elle ne vaut pas généralisation à tout environnement.
Traçabilité	Capacité à relier un résultat à des fichiers, scripts, configurations, entrées et contrôles identifiés.

1. Introduction générale

1.1. Contexte général : des modèles de langage aux agents Text-to-SQL

L'essor récent des modèles de langage de grande taille a profondément modifié les usages de l'intelligence artificielle. D'abord mobilisés pour produire du texte, résumer des documents ou répondre à des questions, ces modèles peuvent désormais interagir avec des outils externes, exécuter des programmes, explorer des fichiers et enchaîner plusieurs actions dans un environnement de travail. Cette évolution a favorisé l'apparition d'agents capables de planifier une démarche, d'observer les résultats de leurs actions et de réviser leur réponse.

Parmi les domaines concernés figure la conversion de questions formulées en langage naturel vers SQL, couramment appelée Text-to-SQL. Son objectif est de permettre à un utilisateur d'interroger une base relationnelle sans maîtriser directement la syntaxe SQL ni l'organisation détaillée du schéma. Le système doit comprendre l'intention exprimée, identifier les tables et les colonnes pertinentes, choisir les jointures nécessaires, appliquer les filtres et les agrégations attendus, puis produire une requête conforme au dialecte utilisé.

La difficulté ne réside donc pas dans une traduction mot à mot. Une expression métier peut correspondre à plusieurs colonnes, une même réponse peut être obtenue par plusieurs formulations SQL équivalentes et certaines questions exigent des opérations intermédiaires. Dans un dispositif agentique, la requête finale ne résume même plus l'ensemble du comportement : l'agent peut inspecter le schéma, exécuter des requêtes exploratoires, consulter des fichiers annexes et corriger progressivement sa solution.

Cette capacité ouvre des perspectives pratiques importantes pour l'accès aux données. Elle accroît cependant l'exigence méthodologique des évaluations comparatives. Le résultat observé dépend à la fois du modèle, des outils autorisés, des limites de ressources, du format de sortie demandé et de l'environnement de données réellement remis à l'agent. Plus le système dispose de moyens d'exploration, plus le corpus et sa préparation deviennent des composantes actives de la mesure.

L'enjeu pratique est important. Dans une organisation, les utilisateurs métiers savent souvent quelle information ils recherchent sans connaître le langage SQL ni la structure physique du système d'information. Une interface fiable en langage naturel pourrait réduire la dépendance à des spécialistes pour les demandes courantes, accélérer certaines analyses exploratoires et améliorer l'accès aux données. Mais cet intérêt renforce l'exigence

d'évaluation : plus une technologie est susceptible d'être utilisée pour prendre des décisions, plus il devient nécessaire de distinguer une réponse réellement exacte d'une réponse simplement plausible ou techniquement exécutable.

1.2. Le problème scientifique : une mesure peut être précise sans être interprétable

L'existence de référentiels publics a largement contribué aux progrès du Text-to-SQL. En proposant des tâches communes, ils permettent de comparer les systèmes dans des conditions proches et d'accumuler des résultats reproductibles. Une grande partie de la littérature se concentre ainsi sur la requête générée, le résultat d'exécution, la robustesse du raisonnement ou la stratégie de l'agent.

Cette organisation repose sur un présupposé : la base, le schéma, les exemples, les relations et la référence utilisés pour calculer le score sont suffisamment cohérents pour que la variation observée puisse être attribuée au système évalué. Or ce présupposé peut cesser d'être valide lorsqu'un environnement est reconstruit à partir de ressources partielles, traduites ou échantillonnées indépendamment.

Un fichier SQLite peut s'ouvrir normalement, passer un contrôle d'intégrité et accepter des requêtes sans que la tâche soit mesurable. Une colonne utile peut être entièrement vide. Deux tables peuvent contenir des identifiants non nuls sans partager de valeur commune. Une requête de référence peut s'exécuter et retourner zéro ligne sans que l'on puisse déterminer si ce résultat est attendu ou provoqué par une perte d'information. Dans ces situations, l'exactitude apparente du calcul ne garantit pas l'interprétabilité de la mesure.

Le risque est double. Une erreur issue des données peut être attribuée à l'agent, tandis qu'une requête non équivalente peut être récompensée parce qu'elle produit fortuitement le même résultat sur un échantillon trop pauvre. Le score conserve alors une précision numérique, mais perd une partie de sa validité de construit : il ne représente plus clairement la capacité que l'on souhaitait mesurer.

Le mémoire adopte donc une règle de séparation. La première étape porte sur le droit de mesurer : la tâche locale conserve-t-elle les informations qui rendent la question calculable et le résultat de référence interprétable ? La seconde étape seulement porte sur la qualité de la réponse de l'agent. Cette distinction est au cœur de la recherche, car elle évite de transformer une simple disponibilité technique des fichiers en présomption de validité scientifique.

1.3. Genèse de la recherche et réorientation du projet

L'objectif initial ne consistait pas à étudier la qualité d'un corpus. Le projet visait à comparer plusieurs agents capables de résoudre des tâches Text-to-SQL formulées en français. Une telle comparaison exigeait un environnement commun : mêmes questions, mêmes bases, mêmes consignes, mêmes limites d'accès et même format de réponse.


Le recours à des ressources existantes répondait à un choix méthodologique. Construire entièrement les questions, les schémas et les réponses attendues aurait créé un corpus conçu par la même personne que le protocole chargé de l'évaluer. Un ensemble existant permettait au contraire de partir de tâches qui n'avaient pas été élaborées pour favoriser les agents étudiés. La reconstruction locale devait également garantir l'indépendance à l'égard d'un service distant et permettre de rejouer les préparations.

À ce stade, aucune anomalie n'était présupposée. Les premières vérifications confirmaient que les fichiers SQLite s'ouvraient, que les schémas pouvaient être extraits et que des requêtes pouvaient être exécutées. Des comportements inattendus sont toutefois apparus : certaines références renvoyaient zéro ligne, plusieurs colonnes essentielles étaient nulles après importation et des jointures nécessaires ne pouvaient pas être démontrées.

Ces observations ne permettaient pas encore d'attribuer une cause. Elles pouvaient provenir de la reconstruction, d'une incompatibilité entre ressources, d'un échantillonnage insuffisant, d'une référence inadaptée ou du contenu source lui-même. Lancer davantage d'agents aurait augmenté le volume de journaux sans résoudre l'incertitude centrale.

La réorientation s'est faite en plusieurs étapes. Une anomalie a d'abord été décrite ; des hypothèses concurrentes ont ensuite été envisagées, notamment l'absence de valeurs dans les fichiers sources, une erreur de définition du schéma, une perte pendant l'importation ou un simple échantillonnage insuffisant. L'étude de local023 a permis d'isoler un mécanisme précis de perte de colonnes. L'extension de l'audit au pilote a montré que la correction de ce mécanisme ne suffisait pas à restaurer la couverture relationnelle. Le sujet du mémoire a ainsi évolué d'une comparaison de produits vers la conception d'une méthode de qualification préalable. Cette évolution n'est pas une justification a posteriori : elle constitue l'histoire scientifique du projet.

Genèse et réorientation de la recherche



La question de recherche évolue au contact des contrôles réalisés sur l'environnement local.

La réorientation précède la campagne de mesure : elle n'est pas une justification a posteriori.

Figure 1 - Genèse et réorientation de la recherche. Source : chronologie méthodologique du projet et registre de preuves [E01-E19, E53-E72].

1.4. Objectifs du mémoire

L'objectif principal est de proposer une méthode permettant de qualifier un corpus d'évaluation avant toute mesure de performance d'agents d'intelligence artificielle. Le mémoire déplace ainsi l'attention du seul système évalué vers le support expérimental qui rendrait son score interprétable.

Cet objectif général se décline en plusieurs objectifs opérationnels : identifier précisément les ressources utilisées ; reconstruire les bases dans des conditions documentées ; vérifier leur intégrité technique ; comparer les clés sources et les colonnes cibles ; détecter les pertes de valeurs ; examiner les relations nécessaires aux questions ; exécuter les références sur les bases exactes remises aux agents ; et vérifier la rejouabilité locale des transformations.

Le travail doit également produire une règle de décision. Il ne suffit pas de dresser une liste d'anomalies : il faut déterminer quand une tâche peut être utilisée, quand elle doit rester sous réserve et quand un défaut critique impose son exclusion. La grille Vert, Ambre et Rouge répond à cette fonction en associant chaque statut à un niveau de preuve.

L'ambition n'est ni de remplacer les référentiels existants ni de généraliser à partir d'un seul environnement. Elle consiste à proposer une étape complémentaire, réutilisable sous réserve d'adaptation, pour les situations où des ressources sont traduites, converties, échantillonnées ou reconstruites avant d'être remises à des agents.

Le travail vise aussi un objectif pédagogique. Le protocole doit être compréhensible par un lecteur qui n'a pas participé au développement du dépôt. Les noms de scripts et les commandes détaillées sont utiles en annexe, mais le corps du mémoire doit expliquer

pourquoi chaque contrôle existe, quel risque il réduit et ce que son résultat autorise réellement à conclure.

1.5. Questions de recherche

Trois questions générales structurent le mémoire. Premièrement, comment démontrer qu'un corpus reconstruit localement est scientifiquement apte à soutenir une évaluation d'agents Text-to-SQL ? Deuxièmement, quels contrôles sont nécessaires pour qualifier objectivement la viabilité d'une tâche avant toute mesure ? Troisièmement, dans quelles situations convient-il de renoncer à comparer des agents afin d'éviter une interprétation erronée des résultats ? Ces interrogations sont opérationnalisées par cinq questions expérimentales, présentées dans le tableau suivant, qui suivent la chaîne de preuve depuis l'identification du défaut jusqu'à la décision finale de mesurer ou non.

Question de recherche	Objet observé	Critère de réponse
QR1. Les statuts Rouge initiaux proviennent-ils d'un défaut de reconstruction identifiable ?	Artefacts de local023 et audit de sensibilité	Cause retenue lorsque la divergence entre source et base est observée et expliquée.
QR2. Une correspondance explicite restaure-t-elle les valeurs perdues ?	Conditions historique et corrigée	Comparaison avant/après sans modification des artefacts historiques.
QR3. La correction rend-elle la tâche éligible à une mesure ?	Colonnes, jointures et requête de référence	Statut Vert uniquement si toutes les preuves positives sont établies.
QR4. Le résultat est-il rejouable dans le périmètre local ?	Reconstructions fraîches répétées dans l'environnement local et empreintes logiques	Identité des empreintes au sein de chaque condition.
QR5. Quelle cause résiduelle explique l'absence de tâche Verte ?	Audit de couverture relationnelle	Distinction entre relation absente dans les sources, perdue à l'importation ou non établie.

Tableau 1 - Questions de recherche et critères de réponse. Source : protocole et études locales [E53-E72].

Les cinq questions opérationnelles distinguent la cause de reconstruction, l'effet d'une correction explicite, l'éligibilité à la mesure, la rejouabilité locale et la cause résiduelle de l'absence de tâche Verte. Cette décomposition empêche qu'une simple amélioration technique soit confondue avec une validation complète du support expérimental.

Les questions de recherche suivent la chaîne de transformation des données. La première s'intéresse à l'origine des statuts Rouge : un défaut de reconstruction peut-il être observé dans les fichiers et relié à une opération précise ? La deuxième porte sur l'intervention : une correspondance explicite entre clé source et colonne cible restaure-t-elle effectivement les valeurs perdues ? La troisième vérifie que la correction n'est pas surinterprétée : la disparition d'un défaut d'importation suffit-elle à rendre la tâche mesurable ?

Chaque question est associée à un critère de réponse dans le chapitre méthodologique et à des preuves dans le chapitre expérimental. Le mémoire ne se contente donc pas d'énoncer des interrogations générales ; il précise les observations qui permettraient de répondre positivement, négativement ou de maintenir une conclusion incertaine.

1.6. Hypothèses de travail

La première hypothèse est que la qualification du corpus peut être traitée comme une étape autonome, antérieure à l'évaluation des agents. Une méthode explicite devrait donc permettre d'examiner les données sans utiliser le comportement d'un modèle comme substitut de diagnostic.

La deuxième hypothèse est qu'une validité informatique ne suffit pas à établir une validité expérimentale. L'ouverture d'un fichier, l'accès au schéma et l'exécution sans erreur constituent des conditions nécessaires, mais non suffisantes, lorsque la question dépend de valeurs et de relations qui peuvent avoir été perdues.

La troisième hypothèse est que les anomalies de reconstruction et les limites relationnelles peuvent être documentées de façon rejouable à l'aide d'audits, de correspondances versionnées, de tests automatisés et d'empreintes logiques. Si cette hypothèse est soutenue, une décision de mesure ou de non-mesure peut être rattachée à des preuves identifiées plutôt qu'à une appréciation informelle.

La première hypothèse suppose qu'une tâche peut être qualifiée indépendamment de l'agent. Elle serait mise en défaut si la viabilité ne pouvait être appréciée qu'en observant les réponses de plusieurs systèmes. Le protocole choisit au contraire de partir des fichiers, du schéma, des valeurs, des relations et de la référence. Les sorties des agents interviennent après cette qualification et ne servent pas à combler une preuve manquante.

Ces hypothèses sont formulées de façon prudente. Elles ne prédisent pas que tous les corpus reconstruits contiennent des défauts, ni que la grille proposée sera universelle. Un environnement entièrement cohérent aurait également constitué un résultat informatif : le protocole aurait alors documenté les raisons permettant de lancer une évaluation.

1.7. Contributions du mémoire

La première contribution est un protocole de qualification préalable organisé autour de la provenance, de la reconstruction, de la conservation des valeurs, de la couverture relationnelle

et de l'interprétabilité de la référence. Il place explicitement la viabilité du corpus entre la préparation technique et l'évaluation des agents.

La deuxième contribution est une grille de décision Vert, Ambre et Rouge. Elle ne classe pas les agents ; elle qualifie le support de mesure. Le statut Vert exige l'établissement positif de toutes les conditions nécessaires, le statut Rouge correspond à un défaut critique démontré et le statut Ambre conserve hors score les situations techniquement utilisables mais insuffisamment prouvées.

La troisième contribution est une mise à l'épreuve empirique sur vingt tâches locales. Elle combine l'étude causale de local023, une intervention contrôlée, quatre reconstructions fraîches, un audit de sensibilité, la correction documentée de six autres divergences et une analyse de couverture relationnelle.

La quatrième contribution est une discipline de traçabilité. Un registre de preuves, des commandes, des tests et des annexes relient les affirmations aux artefacts étudiés. La contribution principale n'est donc pas le nombre de défauts corrigés, mais la méthode permettant de décider si une mesure peut être interprétée.

Enfin, le mémoire formalise une décision hors score comme résultat scientifique. Il montre qu'un protocole d'évaluation peut produire une conclusion utile sans publier de classement, lorsque les conditions permettant d'attribuer les résultats aux agents ne sont pas établies.

1.8. Périmètre de l'étude

Le mémoire porte exclusivement sur un environnement local reconstruit à partir des fichiers, scripts, configurations et échantillons identifiés. Les chiffres d'inventaire décrivent cette copie de travail et ne doivent pas être présentés comme des statistiques officielles relatives aux distributions académiques d'origine.

L'étude n'évalue pas les versions officielles de Spider, MultiSpider ou Spider 2.0 et ne conclut pas à leur défaillance. Elle analyse les effets possibles d'une chaîne locale de traduction, de sélection, de conversion et d'importation. De même, les observations relatives à Vibe et Codex décrivent deux exécutions particulières et ne permettent aucun classement de produits ou de modèles.

Les résultats portent sur les vingt tâches pilotes, les versions logicielles et les reconstructions documentées. La méthode est proposée comme un cadre réutilisable sous

réserve d'adaptation ; sa validité externe, sa stabilité inter-évaluateurs et son application à d'autres moteurs restent à étudier.

Le périmètre empirique est volontairement circonscrit. Il comprend les fichiers effectivement présents dans la copie de travail, les scripts de reconstruction identifiés, les vingt tâches du pilote, les bases SQLite générées, les rapports d'audit et les deux exécutions d'agents documentées. Le nombre plus large de questions inventoriées décrit la disponibilité locale, mais il ne signifie pas que chacune a été qualifiée avec le même niveau de profondeur.

Cette délimitation est une condition de crédibilité. Elle permet d'employer des formulations fortes lorsqu'un fait local est démontré, tout en évitant de transformer un diagnostic précis en jugement global sur des ressources extérieures.

1.9. Démarche scientifique adoptée

La démarche se distingue d'une comparaison directe de modèles. Un protocole classique peut être résumé par la chaîne corpus, agent, score. Le protocole proposé introduit une étape préalable : corpus, qualification, décision d'éligibilité, agent, puis mesure éventuelle. Cette modification empêche d'utiliser le comportement de l'agent pour masquer ou diagnostiquer indirectement un défaut du support.

Chaque étape doit produire une preuve et peut interrompre la progression. L'absence d'une preuve nécessaire n'est jamais transformée en preuve d'absence. Inversement, une correction n'autorise pas automatiquement la mesure : elle doit être suivie de nouveaux contrôles portant sur les relations et la référence.

Le raisonnement repose sur la séparation entre faits observés, diagnostics étayés et limites ouvertes. Les fichiers historiques sont conservés, les corrections produisent de nouvelles conditions, et les conclusions sont limitées au niveau de preuve disponible. Cette discipline explique pourquoi la décision finale de ne pas calculer de score constitue un résultat méthodologique plutôt qu'un échec de l'étude.

La démarche combine enquête technique et raisonnement méthodologique. Chaque anomalie est d'abord décrite sans lui attribuer immédiatement une cause. Les hypothèses sont confrontées aux fichiers sources, aux colonnes cibles, aux valeurs après importation et aux résultats de jointure. Une intervention n'est retenue que lorsqu'elle est limitée aux correspondances observables, conservée dans une configuration versionnée et comparée à un état historique intact.

Le projet conserve également la possibilité d'un résultat négatif. Une correction qui ne transforme pas une tâche en cas mesurable n'est pas considérée comme inutile : elle permet d'éliminer une cause et de localiser le problème restant. Cette manière de traiter les résultats est importante, car elle privilégie la progression de l'explication à la recherche d'un score à tout prix.

1.10. Organisation du mémoire

Le chapitre 2 présente l'état de l'art relatif au Text-to-SQL, aux référentiels multilingues, aux métriques d'évaluation, à la robustesse, à la provenance et à la reproductibilité. Le chapitre 3 retrace la genèse du projet, décrit les ressources locales et précise leurs limites.

Le chapitre 4 formalise le protocole de qualification, ses règles et sa logique de décision. Le chapitre 5 présente la mise à l'épreuve expérimentale, depuis l'audit initial jusqu'aux résultats consolidés, en distinguant pour chaque étude l'objectif, la méthode, le résultat, l'interprétation et les limites.

Le chapitre 6 discute la portée scientifique de la méthode, les menaces à la validité, les recommandations et les perspectives. Le chapitre 7 conclut en revenant sur la problématique et sur la décision hors score. Les annexes conservent le registre de preuves, les scripts, les commandes, la chronologie, les extraits de code et les fiches nécessaires à la vérification et à la réutilisation du protocole.

L'enchaînement des chapitres suit le chemin de preuve. L'état de l'art présente d'abord les difficultés propres au Text-to-SQL, les métriques et les enjeux de qualité des référentiels. Le contexte empirique explique ensuite pourquoi un corpus existant a été retenu, comment il a été reconstruit et à quel moment la question de recherche a changé. La méthode formalise les contrôles avant que les résultats ne soient examinés, afin d'éviter que les règles soient ajustées silencieusement pour correspondre aux observations.

2. État de l'art et enjeux de l'évaluation

2.1. Le Text-to-SQL : permettre l'interrogation des bases en langage naturel

L'accès aux bases relationnelles repose traditionnellement sur SQL, un langage puissant mais exigeant une connaissance du schéma, des relations et de la syntaxe. Le Text-to-SQL cherche à réduire cette barrière en transformant une question formulée en langage courant en une requête exécutable.

Le système doit accomplir plusieurs opérations qui ne se réduisent pas à la génération de code : reconnaître l'intention, relier les expressions de la question aux éléments du schéma, sélectionner les tables, déterminer les jointures, appliquer les filtres, construire les agrégations et respecter le dialecte. Une même question peut admettre plusieurs requêtes équivalentes, tandis qu'une requête syntaxiquement correcte peut néanmoins exprimer une intention différente.

Ces difficultés expliquent que l'évaluation ne puisse pas se limiter à la comparaison littérale avec une chaîne de référence. Elles rendent également le contenu de la base important : l'équivalence ou la non-équivalence de deux requêtes ne se manifeste pas nécessairement sur un échantillon pauvre.

Une tâche Text-to-SQL associe au minimum une question, un schéma et un contenu de base. Le système doit identifier les entités mentionnées, comprendre les contraintes implicites, sélectionner les tables et construire les relations nécessaires. Cette opération, souvent appelée mise en correspondance avec le schéma, est difficile lorsque le vocabulaire de la question diffère des noms techniques. Le mot « joueur » peut correspondre à une table `player`, tandis que « moyenne par match » exige de déterminer le dénominateur approprié et d'éviter un simple calcul par ligne d'événement.

La dimension française ajoute des difficultés propres. Les questions peuvent traduire des concepts dont le schéma conserve les noms anglais, employer des formes fléchies ou des expressions métier éloignées des identifiants techniques. La traduction des questions, des descriptions ou des clés doit donc être documentée, car elle peut modifier les correspondances nécessaires à la résolution.

2.2. Évolution des approches : des règles aux modèles de langage

Les premières interfaces en langage naturel reposaient souvent sur des grammaires, des patrons et des règles définies pour un domaine. Ces approches pouvaient être précises dans un périmètre restreint, mais leur généralisation à de nouveaux schémas exigeait un travail important.

Les modèles neuronaux ont ensuite appris la correspondance entre questions et requêtes à partir de corpus annotés. Les architectures de type encodeur-décodeur, les représentations de schéma et les mécanismes de contrainte ont progressivement amélioré la généralisation. Les modèles de langage de grande taille ont ajouté des capacités de génération de code, de raisonnement en contexte et d'utilisation d'exemples.

Le passage à des agents outillés constitue une nouvelle étape. Le système peut explorer la base, consulter des fichiers, exécuter des requêtes intermédiaires et modifier son plan. Le protocole d'évaluation doit alors documenter non seulement la sortie finale, mais aussi l'environnement accessible, les opérations autorisées, les limites de ressources et les états d'échec possibles.

Cette évolution justifie une description plus complète du protocole. La performance ne dépend pas seulement du modèle sous-jacent. Elle dépend de l'interface, de l'orchestration, des outils et des informations accessibles. Le mémoire ne cherche pas à départager ces composantes, mais il en tire une conséquence : l'environnement remis à chaque agent doit être figé, qualifié et documenté avant toute comparaison.

2.3. Les référentiels d'évaluation et la généralisation à des schémas non vus

Un référentiel d'évaluation associe des bases, des schémas, des questions, des références et une méthode de mesure. Sa fonction est de rendre les comparaisons cumulatives et de réduire les variations liées aux conditions expérimentales.

Spider a joué un rôle structurant en imposant une séparation entre les bases d'entraînement et de test. Le corpus annoncé par Yu et ses collaborateurs comprend 10 181 questions, 5 693 requêtes SQL uniques et 200 bases couvrant 138 domaines. Cette organisation évalue la généralisation à des schémas non vus plutôt que la mémorisation de patrons propres à une base (Yu et al., 2018).

CoSQL et SParC ont ensuite introduit des interactions en contexte et des dialogues autour de bases relationnelles (Yu, Zhang, Er, et al., 2019 ; Yu, Zhang, Yasunaga, et al., 2019). Ces

travaux montrent que l'évaluation peut porter sur une séquence de décisions et non seulement sur une requête isolée.

Le présent mémoire ne remet pas en cause l'utilité de ces ressources. Il s'intéresse à une situation différente : que reste-t-il des propriétés nécessaires à l'évaluation lorsqu'un environnement est recomposé localement à partir de ressources partielles, de traductions et d'échantillons ? La réponse ne peut pas être déduite du nom du référentiel ; elle doit être établie sur les fichiers effectivement utilisés.

2.4. Multilinguisme, robustesse et environnements proches des usages réels

MultiSpider étend l'évaluation à plusieurs langues, dont le français, et rend visibles les difficultés liées à la transposition linguistique des questions et des schémas. Les auteurs rapportent une baisse moyenne dans les langues autres que l'anglais selon les configurations étudiées, ce qui souligne que la traduction n'est pas une transformation neutre (Dou et al., 2023).

Dr.Spider examine la robustesse des systèmes face à des perturbations contrôlées des questions, des schémas et du contexte (Chang et al., 2023). BIRD élargit l'échelle et la diversité des données, tandis que Spider 2.0 propose des flux de travail proches des environnements d'entreprise, avec des bases volumineuses, des métadonnées, de la documentation et parfois plusieurs requêtes à produire (Li et al., 2023 ; Lei et al., 2025).

Ces évolutions renforcent la dépendance au support expérimental. Plus les tâches sont riches et outillées, plus la qualité des fichiers, des relations et de la documentation conditionne l'interprétation du résultat.

Le choix d'un corpus français est ainsi scientifiquement pertinent, mais il impose de documenter la chaîne de transformation. La langue n'est pas seulement une caractéristique de la question ; elle peut affecter les schémas traduits, les clés intermédiaires, les descriptions et les règles de reconstruction.

2.5. Métriques : correspondance structurelle, exécution et tests sémantiques

Finegan-Dollak et ses collaborateurs ont montré que la méthodologie d'évaluation et la séparation des données peuvent fortement influencer les conclusions (Finegan-Dollak et al., 2018). Les suites de tests distillées cherchent à distinguer plus efficacement les requêtes sémantiquement différentes (Zhong et al., 2020). FLEX part du constat que l'exécution brute

peut produire des faux positifs et des faux négatifs et enrichit le jugement par davantage de contexte (Kim et al., 2025).

Ces méthodes améliorent l'évaluation des réponses, mais elles présupposent toujours que les bases et les références utilisées conservent les propriétés nécessaires. Une métrique sophistiquée ne peut pas compenser une relation absente ou une colonne vidée lors de la reconstruction.

La correspondance exacte compare la structure de la requête produite à une référence normalisée. Elle facilite l'automatisation, mais pénalise les nombreuses formulations SQL équivalentes. Une jointure peut être écrite dans un ordre différent ; une sous-requête peut être remplacée par une agrégation conditionnelle ; des alias peuvent varier sans modifier le résultat. Cette limite a favorisé l'usage de l'exactitude d'exécution, qui compare les résultats obtenus sur la base.

Les recherches récentes sur les erreurs d'annotation rappellent par ailleurs que la requête dite de référence n'est pas infallible. L'étude CIDR 2026 consacrée à BIRD et Spider 2.0-Snow montre que des erreurs ou ambiguïtés de référence peuvent modifier les évaluations et les classements. Le mémoire ne transpose pas ces taux au corpus local ; il en retient une exigence générale : la référence doit être examinée sur la base exacte distribuée et ne doit pas être traitée comme une vérité indépendante de son contexte.

2.6. Qualité des données, provenance et reproductibilité

Les travaux sur la provenance des données rappellent qu'un résultat doit pouvoir être relié aux transformations et aux sources qui l'ont produit (Buneman et al., 2001 ; Cheney et al., 2009). Les fiches descriptives de jeux de données recommandent de documenter la motivation, la composition, la collecte, les usages et les limites des corpus (Gebru et al., 2021).

Les principes FAIR encouragent des données et des logiciels trouvables, accessibles, interopérables et réutilisables, sans réduire la reproductibilité à la simple mise à disposition d'un fichier (Wilkinson et al., 2016 ; Barker et al., 2022). Les travaux sur la reproductibilité en apprentissage automatique soulignent également l'importance des versions, des dépendances, des configurations et des artefacts d'exécution (Pineau et al., 2021). Les recherches consacrées aux dépôts de données de référence rappellent enfin que la qualité d'un benchmark dépend aussi de la documentation, de la maintenance et de la traçabilité des ressources qui le composent (Longjohn et al., 2024).

Pour un environnement Text-to-SQL reconstruit, ces principes se traduisent par des questions concrètes : quels fichiers ont été utilisés, quelles correspondances ont été appliquées, quelles lignes ont été sélectionnées, quelles valeurs ont été perdues et quelle base exacte a été remise à l'agent ?

La littérature sur la qualité des données distingue plusieurs dimensions : complétude, exactitude, cohérence, actualité et aptitude à l'usage. Dans un référentiel d'évaluation, l'aptitude à l'usage est centrale. Un échantillon peut être exact par rapport aux lignes sélectionnées tout en étant inadéquat pour une question nécessitant des relations absentes. La qualité ne se mesure donc pas uniquement table par table ; elle doit être appréciée au regard de la tâche.

D'autres travaux montrent que la documentation des données et des mesures n'est pas une formalité annexe. Les recommandations relatives aux « déclarations de données » invitent à décrire la population, les conditions de collecte et les limites d'usage d'un corpus ; les recherches sur les cascades de données montrent, de leur côté, que des choix de préparation insuffisamment documentés peuvent produire des effets durables dans toute une chaîne d'apprentissage ou d'évaluation (Bender et Friedman, 2018 ; Sambasivan et al., 2021). Les analyses consacrées à la mesure et à l'équité rappellent également qu'un indicateur n'est interprétable qu'au regard du construit qu'il prétend représenter, tandis que les synthèses critiques sur les jeux de données soulignent l'importance des décisions de sélection, d'échantillonnage et de maintenance (Jacobs et Wallach, 2021 ; Paullada et al., 2021). Ces apports ne démontrent pas les anomalies locales étudiées ici ; ils justifient néanmoins de considérer la préparation du support expérimental comme une composante scientifique de l'évaluation.

2.7. Lacune méthodologique et positionnement du mémoire

La littérature propose des modèles, des référentiels et des métriques de plus en plus élaborés. Des travaux récents analysent aussi les erreurs d'annotation et les effets de la qualité des références sur les classements. Jin et ses collaborateurs rapportent, sur les sous-ensembles qu'ils ont examinés, des taux élevés d'annotations problématiques et des variations de classement après correction (Jin et al., 2026).

Le présent mémoire ne transpose pas ces constats aux distributions officielles. Son objet est plus étroit : qualifier un environnement local produit par combinaison, traduction, échantillonnage et reconstruction de ressources. Il s'intéresse à la conservation des propriétés nécessaires entre le fichier source et la base effectivement distribuée à l'agent.

La contribution se situe donc entre la distribution des ressources et la mesure. Elle formalise une chaîne de qualification préalable et documente la décision de ne pas mesurer lorsque la provenance, les valeurs, les relations ou la référence ne sont pas suffisamment établies.

Les recherches existantes couvrent la qualité des annotations, la robustesse des modèles, la sémantique des métriques et la documentation des données. La lacune ciblée est plus étroite : entre la récupération de ressources et l'exécution des agents, comment décider qu'une tâche localement reconstruite a conservé les propriétés nécessaires à la mesure ? Cette étape est souvent absorbée dans des scripts de préparation et reste moins visible que le modèle ou la métrique.

2.8. Synthèse critique de l'état de l'art

Les travaux examinés font progresser l'évaluation du Text-to-SQL selon trois directions complémentaires. La première augmente la difficulté des tâches et la capacité de généralisation attendue, depuis les schémas non vus de Spider jusqu'aux flux de travail d'entreprise de Spider 2.0. La deuxième étend le champ d'évaluation aux variations linguistiques, aux perturbations contrôlées et à des bases de plus grande ampleur, comme l'illustrent MultiSpider, Dr.Spider et BIRD. La troisième cherche à améliorer la qualité du jugement, en dépassant la comparaison textuelle stricte par l'exécution, les suites de tests sémantiques ou des métriques enrichies telles que FLEX (Yu et al., 2018 ; Dou et al., 2023 ; Chang et al., 2023 ; Li et al., 2023 ; Lei et al., 2025 ; Zhong et al., 2020 ; Kim et al., 2025).

Ces avancées répondent principalement à la question suivante : comment mieux mesurer la qualité d'une requête produite dans un environnement donné ? Le présent mémoire se place légèrement en amont. Il demande comment établir que l'environnement donné conserve lui-même les propriétés nécessaires à cette mesure lorsqu'il résulte d'une traduction, d'un échantillonnage, d'une conversion ou d'une reconstruction locale. Cette différence de niveau est déterminante. Une métrique peut être très élaborée et rester incapable de compenser une colonne vidée pendant l'importation, une jointure détruite par l'échantillonnage ou une référence devenue non interprétable sur la base distribuée.

La littérature consacrée à la documentation des données apporte une réponse partielle à ce problème. Les data statements et les datasheets encouragent la description de la composition, de la collecte, des transformations, des usages prévus et des limites d'un jeu de données (Bender et Friedman, 2018 ; Gebru et al., 2021). Les travaux sur les data cascades montrent en outre que des décisions prises en amont peuvent produire des effets cumulatifs difficiles à

diagnostiquer au stade du modèle (Sambasivan et al., 2021). Ces contributions renforcent la traçabilité et la responsabilité, mais elles ne fournissent pas directement une décision de calculabilité pour chaque tâche relationnelle. Elles disent ce qui doit être documenté ; elles ne déterminent pas, à elles seules, si une question précise reste mesurable après reconstruction.

Les travaux sur la provenance complètent cette perspective en cherchant à expliquer pourquoi et d'où provient une donnée, ainsi que les transformations qui l'ont produite (Buneman et al., 2001 ; Cheney et al., 2009). Dans le cas étudié, la filiation d'une colonne depuis la clé JSON jusqu'à la cellule SQLite constitue précisément une application locale de ce principe. Toutefois, une provenance complète n'implique pas nécessairement une couverture relationnelle suffisante. Il est possible de savoir exactement comment cinq lignes ont été importées tout en constatant qu'elles ne partagent aucune clé avec les lignes d'une autre table.

La reproductibilité constitue une autre condition nécessaire. Les principes FAIR, les recommandations relatives aux logiciels de recherche et les initiatives de reproductibilité en apprentissage automatique insistent sur l'identification des versions, la disponibilité des artefacts, la description des environnements et la possibilité de rejouer les traitements (Wilkinson et al., 2016 ; Pineau et al., 2021 ; Barker et al., 2022). Le présent mémoire reprend cette exigence avec des reconstructions fraîches et des empreintes logiques. Il maintient néanmoins une distinction : reproduire fidèlement une base insuffisante ne la rend pas apte à mesurer un agent. La rejouabilité répond à la stabilité du processus ; la qualification répond à la validité du support de mesure.

La littérature récente confirme enfin que la qualité des annotations et des références peut modifier fortement les conclusions d'un classement. Finegan-Dollak et ses collaborateurs montrent que les choix de séparation et de méthodologie d'évaluation influencent les performances observées ; Jin et ses coauteurs documentent, dans d'autres corpus, des erreurs d'annotation capables de modifier les résultats et les rangs (Finegan-Dollak et al., 2018 ; Jin et al., 2026). Ces travaux ne prouvent rien sur la reconstruction locale analysée ici, mais ils rendent scientifiquement crédible une position de prudence : la qualité du système ne peut pas être isolée de la qualité de l'instrument qui le mesure.

La lacune ciblée peut donc être formulée avec précision. Les recherches existantes fournissent des tâches plus réalistes, des diagnostics de robustesse, des métriques plus fines et des cadres de documentation. Elles traitent moins directement la décision opérationnelle qui précède une campagne locale : pour une tâche donnée, les fichiers effectivement distribués

autorisent-ils une mesure d'exactitude, doivent-ils être corrigés, ou faut-il maintenir la tâche hors score ? Le protocole Vert / Ambre / Rouge proposé dans ce mémoire vise cette décision intermédiaire. Il ne remplace ni les référentiels ni les métriques ; il cherche à déterminer quand leur emploi local est méthodologiquement défendable.

2.9. Cadre conceptuel retenu : du corpus disponible à la mesure autorisée

Le cadre conceptuel du mémoire considère le corpus comme une composante de l'instrument de mesure. Une évaluation ne met pas seulement en relation une question et un agent : elle organise une chaîne composée d'entrées, de transformations, d'un environnement d'exécution, d'une référence et d'une règle de jugement. Une modification de cette chaîne peut changer la difficulté réelle de la tâche ou le sens du résultat sans modifier le nom de la question. L'objet à qualifier n'est donc pas seulement le fichier SQLite, mais l'association effective entre la question, le schéma, les données, les relations et la référence.

Six dimensions structurent cette qualification. La première est la traçabilité des entrées : les fichiers, leurs versions, les scripts et les paramètres doivent être identifiés. La deuxième est l'intégrité technique : la base doit pouvoir être ouverte, contrôlée et interrogée. La troisième est la fidélité de reconstruction : les valeurs nécessaires présentes dans les sources doivent être conservées dans les colonnes cibles. La quatrième est l'adéquation relationnelle : les clés et les recouvrements indispensables à la question doivent exister dans l'échantillon remis à l'agent. La cinquième est l'interprétabilité de la référence : son exécution doit produire un résultat dont le sens peut être établi. La sixième est la rejouabilité : les transformations importantes doivent pouvoir être répétées dans les conditions documentées.

Ces dimensions ne sont pas substituables. Une traçabilité excellente ne compense pas une jointure absente ; une base intègre ne compense pas une perte de valeurs ; une reconstruction fidèle ne compense pas un échantillon qui ne couvre pas la relation nécessaire ; une référence syntaxiquement exécutable ne compense pas un résultat vide impossible à interpréter. Le protocole adopte donc une logique cumulative : l'autorisation de mesurer exige la satisfaction positive de l'ensemble des conditions déclarées.

Cette logique est asymétrique. Un défaut critique observé peut suffire à bloquer la tâche, tandis que le statut positif exige plusieurs preuves convergentes. Cette asymétrie est cohérente avec la nature du risque expérimental. Une seule rupture dans la chaîne peut introduire un facteur de confusion entre les données et l'agent ; l'absence apparente d'erreur ne démontre pas, en revanche, que toutes les propriétés ont été conservées. Le statut Ambre matérialise

cette différence entre “aucun défaut critique restant n’est démontré” et “toutes les conditions nécessaires sont établies”.

Le cadre permet également de distinguer quatre types d’énoncés. Un fait observé est directement rattaché à un artefact ou à un test. Un diagnostic étayé relie plusieurs faits selon un mécanisme explicite. Une règle méthodologique indique la décision adoptée par le protocole. Une proposition de généralisation décrit une possibilité qui reste à éprouver. Cette typologie empêche une conclusion locale, par exemple la perte de sept colonnes sur local023, de devenir silencieusement une affirmation sur les distributions officielles ou sur tous les corpus Text-to-SQL.

Enfin, l’autorisation de mesurer n’est pas une certification absolue. Le statut Vert, s’il était atteint, signifierait que les contrôles définis par cette version du protocole sont satisfaits dans un périmètre donné. Il resterait nécessaire de figer les consignes, les versions, la métrique, les budgets et les modalités d’exécution des agents. Le cadre proposé agit donc comme un verrou préalable : il ne garantit pas à lui seul une évaluation parfaite, mais il empêche de commencer une mesure d’exactitude lorsque le support n’en fournit pas les conditions minimales.

3. Genèse du projet, périmètre empirique et données locales

3.1. Genèse du projet et choix d'un corpus existant

Le projet est né d'une volonté de comparer des agents sur des tâches SQL en français. Le choix d'un corpus existant évitait de fabriquer des questions et des réponses après avoir observé les systèmes. Il introduisait ainsi une indépendance minimale entre la conception des tâches et les agents évalués.

La dimension française répondait à un enjeu pratique et scientifique. Les référentiels demeurent largement centrés sur l'anglais, alors que les usages réels nécessitent des interfaces dans d'autres langues. Une question française peut également modifier la correspondance lexicale avec le schéma et rendre visibles des difficultés qui n'apparaissent pas dans la formulation anglaise.

Le choix de cet environnement répondait d'abord à l'objectif initial du projet. Il fallait réunir des questions en français, des identifiants de tâches SQL, des schémas et des données susceptibles d'être reconstruits localement. Créer entièrement les questions et les réponses aurait introduit un risque de conception sur mesure : le corpus aurait été façonné par la même personne que le protocole destiné à l'évaluer.

Le dépôt disponible fournissait un point de départ concret. Il permettait de sélectionner des tâches françaises et de préparer des bases SQLite sans dépendre d'un service distant. Ce choix ne supposait pas que les données comportaient des erreurs. Comme un contrôle qualité, la méthode aurait gardé son intérêt si toutes les vérifications avaient été satisfaisantes : elle aurait alors documenté l'autorisation de mesurer.

Un environnement local présentait enfin un avantage de contrôle. Chaque agent pouvait recevoir la même arborescence, la même base et les mêmes instructions. Les journaux pouvaient être conservés, et les données pouvaient être inspectées sans dépendre de l'état d'un service distant. La contrepartie était claire : la reconstruction locale devenait une transformation à auditer. Le mémoire assume cette responsabilité au lieu de considérer les fichiers générés comme équivalents par défaut aux ressources d'origine.

3.2. Construction d'un environnement local et inventaire

La reconstruction locale devait assurer que chaque agent reçoive les mêmes fichiers et qu'aucune évolution d'un service distant ne modifie silencieusement les conditions. Elle

permettait aussi de conserver les bases, les schémas, les consignes et les sorties dans un même espace de preuves.

Le matériel étudié est composé d'éléments locaux : fichier de questions françaises, définitions de tables, fichiers JSON, scripts de préparation, configurations, bases SQLite reconstruites, rapports d'audit et journaux d'exécution. L'inventaire recense 547 questions françaises, dont 123 sont associées à des bases SQLite disponibles dans la copie locale, et 29 bases distinctes. Une sélection déterministe de 20 tâches constitue le pilote [E01-E03].

Une autre configuration locale recense 23 tâches techniquement validées. Elle précise explicitement que ce sous-ensemble ne doit pas être utilisé pour produire un score scientifique, car les données reposent sur des échantillons limités [E04-E05].

Élément	Valeur observée dans le périmètre local	Interprétation autorisée
Questions françaises inventoriées	547	Nombre relevé dans la copie de travail, non une statistique officielle externe.
Tâches liées à une base SQLite disponible	123	Disponibilité locale, sans garantie de viabilité sémantique.
Bases SQLite distinctes	29	Inventaire local des bases accessibles.
Tâches pilotes	20	Sous-ensemble déterministe soumis à l'audit.
Données par table	Généralement 5 lignes JSON	Échantillon limité, insuffisant par défaut pour une généralisation.
Tâches techniquement validées dans la configuration primaire	23	Validation technique locale, explicitement non utilisable comme score scientifique.

Tableau 2 - Corpus local et périmètre empirique. Sources : inventaire et configuration locale [E01-E07].

La configuration locale mentionnant vingt-trois tâches techniquement validées est conservée comme information de contexte. Elle montre précisément pourquoi une qualification supplémentaire est nécessaire : une validation de présence et d'ouverture ne répond pas encore à la question de la mesurabilité. Les deux niveaux ne sont pas contradictoires ; ils utilisent des critères différents.

3.3. Origine des fichiers, choix multilingue et prudence de provenance

Le fichier français a été retenu parce qu'il fournissait un point d'entrée compatible avec l'objectif initial. Cette disponibilité ne garantissait cependant ni l'identité de version entre les ressources, ni la conservation des conventions de nommage, ni la cohérence relationnelle des échantillons. Le choix du corpus était donc pertinent pour construire l'expérience, mais il devait précisément être accompagné d'un audit.

Le fichier de questions françaises est conservé sous le chemin `external/Multilingual_Text_to_SQL/questions/spider2-lite_fr.jsonl`. Les définitions de tables

et les échantillons utilisés par la reconstruction sont présents sous un répertoire local Spider2. Ces chemins indiquent les ressources effectivement lues par les scripts ; ils ne suffisent pas à certifier leur statut officiel, leur version exacte ou leurs droits de redistribution [E06-E08].

Cette prudence répond directement à la question « d'où viennent les données ? ». La réponse scientifique doit distinguer trois niveaux. Le premier est observable : les fichiers se trouvent aux chemins documentés. Le deuxième est déclaré par les noms de projet et la documentation disponible. Le troisième, plus fort, serait une vérification complète de provenance et de licence. Ce dernier niveau n'a pas été achevé. Le mémoire n'emploie donc pas les fichiers locaux comme preuve d'une propriété des distributions officielles. Cette prudence rejoint les recommandations de documentation des jeux de données et des objets de recherche : l'origine, les transformations, les versions et les limites d'usage doivent être distinguées des simples noms de fichiers ou de répertoires (Geburu et al., 2021 ; Wilkinson et al., 2016).

La même distinction s'applique aux erreurs. Le défaut de correspondance entre clés françaises et colonnes anglaises est démontré dans la procédure locale. Il ne permet pas de conclure que MultiSpider ou Spider 2.0, utilisés dans leurs distributions et procédures propres, présentent le même défaut.

La prudence concerne aussi la diffusion. Un résultat scientifique peut être décrit sans redistribuer l'ensemble des données. Le registre peut indiquer les chemins, les empreintes et les transformations, tandis que la publication des fichiers sources ou des bases reconstruites reste conditionnée à la vérification des droits. Cette séparation entre vérifiabilité du raisonnement et droit de diffusion est maintenue dans les recommandations et les annexes.

3.4. Pourquoi les échantillons limités posent un problème relationnel

Un échantillon relationnel ne peut pas être évalué uniquement par le nombre de lignes de chaque table. Supposons qu'une table `match` conserve cinq rencontres et qu'une table `ball_by_ball` conserve cinq événements sélectionnés indépendamment. Les deux fichiers peuvent être valides et leurs identifiants non nuls, mais aucune valeur de `match_id` ne se recoupe. La jointure attendue retourne alors zéro ligne, non parce que la relation n'existe pas dans la base complète, mais parce que la méthode de sélection a rompu la cohérence entre les tables.

Le même problème apparaît avec les dimensions et les faits. Une table de joueurs peut contenir cinq personnes qui ne participent à aucun des événements retenus. Une table de

saisons peut omettre la saison demandée par la question. Une agrégation correcte au niveau du schéma devient alors impossible sur l'échantillon. Les contrôles de nullité ne détectent pas nécessairement cette situation : toutes les colonnes peuvent être renseignées, mais les valeurs ne forment pas la chaîne relationnelle nécessaire.

La conséquence méthodologique est importante. Pour les tâches à jointures, l'échantillonnage devrait partir d'entités centrales et préserver les lignes associées, plutôt que sélectionner le même nombre de lignes indépendamment dans chaque table. Cette piste n'est pas testée expérimentalement dans le mémoire ; elle est proposée comme recommandation à valider dans une étude ultérieure.

3.5. Périmètre des conclusions

Les résultats portent sur les 20 tâches pilotes, les bases reconstruites, les scripts et les versions documentés. Ils ne constituent pas un audit complet des 547 questions, une évaluation des référentiels officiels ni une validation générale de la grille.

Le terme « corpus local » désigne l'ensemble effectivement étudié. Le terme « référentiel » est utilisé pour décrire la fonction d'un ensemble de tâches dans une mesure, sans lui attribuer automatiquement un caractère officiel. Enfin, la méthode est présentée comme réutilisable sous réserve d'adaptation et de validation, non comme une norme universelle.

Les conclusions doivent être lues à trois niveaux. Au niveau le plus fort, certains faits locaux sont directement démontrés : nombre de divergences, valeurs nulles après importation, empreintes identiques au sein d'une condition, résultats de jointure et statuts produits par la grille. Au niveau intermédiaire, des diagnostics relient ces faits, par exemple l'attribution des valeurs NULL à l'accès à des clés anglaises absentes. Au niveau le plus prudent, des propositions sont formulées pour d'autres contextes sans prétendre qu'elles ont déjà été validées.

Le mémoire ne généralise donc ni les proportions observées ni l'absence de tâche Verte. Un autre échantillon, une distribution complète ou une procédure de reconstruction différente pourrait produire un résultat opposé. La portée utile du travail réside dans la méthode permettant de le déterminer, et non dans l'idée que tous les environnements reconstruits seraient nécessairement non viables.

Enfin, la portée des recommandations est plus large que celle des résultats chiffrés, mais elle reste conditionnelle. Vérifier la provenance, la filiation des colonnes et les relations

nécessaires constitue une pratique raisonnable dans d'autres projets de reconstruction ; le mémoire ne prétend toutefois pas que les sept règles proposées suffiraient sans adaptation à un entrepôt infonuagique, à une base documentaire ou à une tâche dont la réponse correcte serait légitimement vide. La transférabilité est une hypothèse argumentée et une perspective de validation, non un fait déjà établi.

3.6. Des premières observations à la reformulation de la problématique

Les premiers contrôles visaient uniquement à vérifier que les bases pouvaient être générées et interrogées. Ils ont confirmé la présence des fichiers et la validité technique de SQLite, mais ont également révélé des références vides, des colonnes critiques nulles et des jointures non démontrables.

Plusieurs hypothèses restaient alors ouvertes : erreur dans le script de construction, incompatibilité de noms entre les ressources, absence des valeurs dans les sources, sélection relationnellement incohérente ou référence inadaptée à l'échantillon. La recherche a consisté à séparer ces causes au lieu d'attribuer immédiatement le résultat aux agents.

Cette étape a transformé la question initiale. La comparaison des agents est devenue conditionnelle à une question préalable : l'environnement permet-il réellement de les comparer ? La méthode de qualification n'a donc pas été ajoutée après coup ; elle est la réponse construite à une difficulté rencontrée pendant la préparation expérimentale.

La bascule scientifique peut être résumée comme un enchaînement de décisions. Le projet visait d'abord une comparaison d'agents. La reconstruction locale a rendu possible un premier contrôle commun. Les anomalies ont ensuite empêché d'interpréter les sorties attendues. L'audit a montré que la difficulté n'était pas seulement le comportement des agents, mais la conservation des conditions de résolution. La question est donc passée de « quel agent répond le mieux ? » à « qu'est-ce qui autorise à interpréter une réponse comme une mesure de l'agent ? ».

Cette progression est conservée dans la chronologie en annexe. Elle permet au lecteur de distinguer les observations contemporaines de la préparation des formulations produites après analyse. Elle réduit ainsi le risque de présenter comme hypothèse initiale une conclusion apparue seulement au terme de l'enquête.

4. Méthode : protocole de qualification préalable

4.1. Pourquoi proposer un protocole de qualification préalable ?

Les protocoles de comparaison décrivent généralement avec précision les modèles, les instructions et les métriques, mais considèrent souvent le corpus comme une entrée déjà valide. Lorsqu'une ressource est reconstruite, cette hypothèse doit être vérifiée. Le protocole proposé répond à ce besoin sans remettre en cause la valeur des distributions d'origine.

Le protocole organise la mesure en deux temps. Le premier qualifie la tâche et son environnement. Le second, autorisé seulement après une qualification positive, évalue l'agent. Cette séparation évite d'utiliser le comportement du système comme moyen indirect de diagnostiquer les données.

La chaîne commence par la provenance des entrées. Elle se poursuit par la reconstruction et les contrôles techniques, puis par l'examen des valeurs, des correspondances de colonnes et des relations. La requête SQL de référence est exécutée sur la base exacte remise à l'agent. Ce n'est qu'en présence d'un résultat interprétable qu'une mesure d'exactitude devient envisageable.




Figure 2 - Chaîne de qualification préalable. Une mesure d'exactitude n'est autorisée qu'après l'établissement d'un statut Vert. Source : grille de viabilité [E61].

La qualification ne cherche pas à prouver qu'une tâche est parfaite. Elle vise un niveau de preuve suffisant pour que l'erreur éventuelle puisse être attribuée à l'agent plutôt qu'à un défaut connu ou non résolu du support. Lorsque ce niveau n'est pas atteint, la tâche peut rester utile pour l'ingénierie, l'exploration ou la démonstration, mais elle ne doit pas alimenter une mesure d'exactitude présentée comme scientifique.

4.2. Sept règles minimales

La grille associe chaque dimension à une preuve attendue et à une conséquence. Sa logique est asymétrique : un défaut critique démontré peut suffire à classer une tâche Rouge, tandis que le statut Vert exige que toutes les conditions soient positivement établies. L'absence de preuve ne devient jamais une preuve d'absence.

Règle	Condition	Preuve attendue	Conséquence
V1	Traçabilité des entrées	Fichiers, configurations et scripts, conditions identifiés.	Absence de preuve : pas de statut Vert.
V2	Validité SQLite	Ouverture, contrôles techniques et schéma accessibles.	Défaut technique démontré : Rouge.
V3	Schéma nécessaire	Tables et colonnes nécessaires présentes.	Absence démontrée : Rouge ; incertitude : Ambre.
V4	Valeurs critiques	Colonnes utiles contenant des valeurs exploitables.	Perte critique : Rouge tant qu'elle n'est pas corrigée.
V5	Correspondances de colonnes	Aucune divergence critique non résolue entre source et cible.	Divergence démontrée : Rouge.
V6	Jointures nécessaires	Recouvrement fonctionnel des clés utiles.	Absence ou non-établissement : pas de statut Vert.
V7	Référence interprétable	Résultat SQL interprétable pour la tâche.	Résultat vide non interprétable ou preuve manquante : pas de statut Vert.

Tableau 3 - Règles minimales de la grille de viabilité. Source : configuration et documentation locales [E61].

La règle V1 impose la traçabilité des entrées : question, schéma, données, référence, script et configuration doivent pouvoir être identifiés. V2 vérifie la santé technique de la base : ouverture, intégrité, tables et schéma. V3 s'intéresse à la présence des objets nécessaires à la question. Une base peut être valide tout en omettant une table ou une colonne indispensable.

V4 examine les valeurs critiques. La présence d'une colonne ne suffit pas si toutes ses valeurs sont nulles ou inexploitable. V5 compare les clés sources et les colonnes cibles afin de détecter les divergences de correspondance. V6 contrôle la couverture relationnelle : les clés nécessaires se recoupent-elles dans les données effectivement remises ? V7 porte enfin sur la référence : son exécution produit-elle un résultat dont le sens peut être établi ?

Le caractère minimal de la grille doit enfin être compris comme une borne inférieure. Une campagne réelle pourrait ajouter des critères portant sur la sécurité, le coût, le temps d'exécution, l'équité linguistique, la protection des données ou la robustesse aux reformulations. Ces dimensions deviennent pertinentes après l'établissement du support de mesure. Le protocole étudié se concentre volontairement sur ce qui conditionne l'interprétation de l'exactitude SQL dans un environnement local reconstruit.

4.3. Logique de décision

Le statut Rouge correspond à un défaut critique démontré. Le statut Ambre désigne un environnement où le défaut bloquant peut avoir disparu, mais où une condition nécessaire reste manquante ou ambiguë. Le statut Vert n'indique pas qu'un agent réussira ; il signifie uniquement que la tâche fournit un support interprétable pour mesurer sa réponse.

Cette distinction est importante dans les études de correction. Passer de Rouge à Ambre est un progrès de reconstruction et de diagnostic. Ce n'est pas une autorisation de publier un score.




Figure 3 - Arbre de décision simplifié de la grille de viabilité. Source : règles V1 à V7 [E61].

La logique est volontairement asymétrique. Le statut Rouge correspond à un défaut critique démontré : base invalide, objet nécessaire absent ou perte de valeur établie. Ambre correspond à une situation où la tâche n'est pas autorisée au score, mais où le défaut n'est pas de même nature : preuve relationnelle insuffisante, référence vide non interprétable ou ambiguïté non résolue. Vert exige au contraire que toutes les conditions déclarées soient positivement établies.

Cette logique vise à limiter les faux accords de mesure. Autoriser trop tôt une tâche risquerait d'attribuer à l'agent un effet produit par les données. Exclure définitivement toute tâche incertaine empêcherait, au contraire, les travaux de correction ou de documentation. Le

niveau Ambre joue le rôle d'un état de travail contrôlé : les analyses techniques restent possibles, mais leurs résultats ne sont pas intégrés à une mesure comparative.

4.4. Filiation des données et interventions contrôlées

Lorsqu'une valeur disparaît, l'audit suit son parcours depuis la clé du fichier source jusqu'à la colonne SQLite. Cette démarche opérationnalise une question classique de provenance : quelles données et quelles transformations expliquent la valeur observée ou son absence (Buneman et al., 2001 ; Cheney et al., 2009) ? Une correspondance n'est créée que si les fichiers disponibles permettent de justifier directement l'association. Les traductions heuristiques sont exclues : elles pourraient rendre la base plus remplie tout en introduisant une interprétation non vérifiable.

La filiation relie une valeur cible à son origine. Pour une colonne critique, l'audit cherche la clé correspondante dans le fichier source, compte les valeurs non nulles avant et après importation et documente la règle utilisée. Cette approche complète les contrôles de structure : elle détecte les pertes silencieuses qui ne rendent pas la base invalide au sens de SQLite.

Une intervention contrôlée respecte trois principes. L'état historique est conservé ; la correction est appliquée dans une condition séparée ; la correspondance est explicite et limitée aux cas démontrés. Le protocole refuse une traduction automatique générale qui pourrait remplir des colonnes sur la base d'une ressemblance lexicale non vérifiée. Une amélioration apparente obtenue par une inférence opaque affaiblirait la traçabilité.

Ce choix impose une forme de retenue. Lorsque plusieurs traductions sont plausibles ou qu'une clé source ne permet pas d'identifier sans ambiguïté la colonne cible, le protocole conserve l'incertitude au lieu de sélectionner la correspondance la plus vraisemblable. Une donnée plus complète pourrait ultérieurement résoudre ce cas. Tant qu'elle n'existe pas, ne pas corriger constitue une décision méthodologique plus solide qu'une réparation impossible à justifier.

4.5. Rejouabilité, tests et registre de preuves

Un fichier SQLite peut varier au niveau binaire en raison de détails d'écriture tout en représentant le même contenu logique. Le mémoire utilise donc une empreinte calculée sur une représentation normalisée du schéma et des valeurs. Deux reconstructions d'une même condition doivent produire la même empreinte logique ; les conditions historique et corrigée doivent, elles, rester différentes si l'intervention a un effet.

Les tests automatisés vérifient les propriétés attendues : détection du défaut historique, restauration des valeurs, séparation des conditions, application déterministe de la grille et impossibilité de promouvoir une tâche lorsque la relation ou la référence manque. Ils ne remplacent pas l'analyse scientifique, mais réduisent le risque de régression et rendent la procédure vérifiable.

Le registre de preuves joue enfin un rôle éditorial. Il permet de réviser le manuscrit sans transformer un diagnostic en fait ou une limite en résultat. Lorsqu'une affirmation est reformulée, l'auteur peut vérifier l'artefact qui l'autorise et la portée retenue. Cette pratique réduit les contradictions entre le texte principal, les tableaux et les annexes, et rend plus visible la frontière entre ce qui a été observé, ce qui est interprété et ce qui reste à démontrer.

4.6. Conditions d'exécution des agents

Dans le protocole local, l'agent reçoit un espace de travail dédié. Les références SQL, rapports d'audit et configurations de préparation restent hors de cet espace. La sortie attendue est un fichier `answer.json` et les opérations SQL sont limitées à la lecture [E20-E22]. Cette séparation est un contrôle pratique ; elle ne constitue pas une preuve formelle d'isolation du système. Les outils observés correspondent aux interfaces en ligne de commande Vibe Code CLI et Codex CLI décrites par leurs éditeurs respectifs (Mistral AI, n.d. ; OpenAI, n.d.).

Un fichier de sortie valide, un code de processus nul ou une requête exécutable ne valent pas exactitude. Ces états sont enregistrés séparément. La campagne comparative ne peut commencer que sur des tâches au statut Vert avec des versions, budgets, prompts et règles gelées.

Plusieurs états doivent être enregistrés séparément : absence de fichier, erreur de format, requête non autorisée, requête exécutable, abstention, dépassement de ressources et réponse exacte. Un code de sortie nul indique seulement que le processus s'est terminé sans erreur détectée par le système. Il ne prouve ni la présence du fichier attendu ni la correction analytique.

L'isolement du répertoire de travail reste un contrôle pratique et non une garantie de sécurité. Une évaluation plus formelle devrait examiner les permissions du système, l'accès aux variables d'environnement, les caches, les outils externes et les mécanismes de journalisation. Ces questions dépassent le corpus étudié, mais leur mention évite de présenter l'organisation locale comme un bac à sable de sécurité validé.

4.7. Les niveaux de qualification proposés

Le statut Vert est réservé aux tâches pour lesquelles la provenance, la reconstruction, les valeurs, les relations et la référence sont positivement établies. Le statut Ambre indique qu'une preuve nécessaire manque ou demeure ambiguë, même si la base peut être techniquement exploitée. Le statut Rouge correspond à un défaut critique démontré qui bloque la reconstruction ou l'interprétation minimale.

Ces statuts qualifient exclusivement le support de mesure. Une tâche Rouge ne signifie pas qu'un agent est mauvais ; une tâche Verte ne préjuge pas non plus de la qualité de sa réponse.

Le statut Rouge attire l'attention sur une défaillance qu'il est possible de localiser et, dans certains cas, de corriger. Ambre signale qu'une partie de l'environnement est exploitable : la base peut être ouverte, les données peuvent être inspectées et des scripts peuvent être testés. Il maintient toutefois la tâche en dehors du calcul d'un score d'exactitude. Vert représente une autorisation conditionnelle : les contrôles définis sont satisfaits, mais l'évaluation doit encore respecter un protocole figé et une métrique appropriée.

Cette gradation évite une opposition trop simple entre « fonctionne » et « ne fonctionne pas ». Dans l'étude, les corrections montrent précisément qu'une tâche peut progresser d'un statut à l'autre sans atteindre le niveau requis pour mesurer un agent.

Le statut Vert correspond à une autorisation conditionnelle de mesurer. Il ne certifie ni la qualité intrinsèque de la question, ni l'absence de toute erreur future, ni la réussite des agents. Il indique que, selon les règles déclarées et les preuves disponibles, le résultat d'une requête peut être comparé à une référence interprétable dans un environnement figé. Une campagne devrait encore documenter ses métriques, ses budgets et ses règles de traitement des équivalences SQL.

4.8. Pourquoi trois niveaux ?

Une décision binaire valide ou invalide serait trop grossière. Elle confondrait une absence de preuve, qui peut être résolue par un audit supplémentaire, avec un défaut démontré. Le niveau Ambre conserve cette distinction et empêche qu'une incertitude soit transformée en validation implicite.

La logique est volontairement asymétrique : une seule défaillance critique peut imposer le Rouge, tandis que le Vert exige que toutes les conditions nécessaires soient établies. Cette exigence limite les faux positifs de qualification.

Deux niveaux auraient conduit à classer ensemble des situations différentes. Une base dont une colonne critique est vidée par un import connu n'a pas le même statut qu'une base techniquement saine pour laquelle la relation attendue n'est pas établie dans un échantillon limité. Dans le premier cas, un défaut est démontré ; dans le second, une preuve manque ou l'échantillon est insuffisant. Les conséquences opérationnelles diffèrent également : corriger la transformation, reconstruire les données ou exclure la tâche.

Un nombre plus élevé de catégories aurait augmenté la précision descriptive, mais au prix d'une décision moins lisible. Les trois niveaux correspondent au besoin principal : défaut critique, incertitude bloquante, ou conditions établies. Les diagnostics détaillés restent conservés dans les rapports et les tableaux.

Cette architecture rend également les évolutions lisibles. La correction des divergences transforme les sept Rouge en Ambre sans masquer l'absence de Vert. Un système binaire aurait pu présenter cette évolution comme un passage d'invalidé à valide, ce qui aurait exagéré l'effet de la correction. La troisième catégorie permet donc de représenter un progrès réel sans le confondre avec l'atteinte de l'objectif final.

4.9. Principes de décision et propriétés attendues

Le protocole cherche quatre propriétés : explicabilité de la décision, conservation des artefacts historiques, rejouabilité des transformations et proportionnalité des conclusions au niveau de preuve. Toute intervention doit être déclarée et produire une nouvelle condition plutôt que modifier silencieusement les fichiers antérieurs.

La sortie du protocole n'est pas obligatoirement un score. Elle peut être une autorisation de mesurer, une liste de preuves à compléter ou une exclusion motivée. La possibilité de suspendre l'évaluation fait partie intégrante de la méthode.

La décision doit être explicable : deux lecteurs doivent pouvoir retrouver les preuves qui ont conduit au statut. Elle doit être conservative : une incertitude sur une condition nécessaire ne peut pas être transformée en validation. Elle doit être stable : la même configuration et les mêmes données doivent conduire au même résultat. Elle doit enfin être réversible au sens documentaire : une nouvelle preuve peut faire évoluer le statut sans effacer l'état antérieur.

Le protocole recherche également une forme de monotonie. La suppression d'un défaut ne peut pas dégrader artificiellement la tâche, mais elle ne doit pas non plus entraîner une promotion automatique jusqu'au Vert. Chaque condition est réévaluée séparément. Cette

propriété est visible dans local023 : la correction de la correspondance supprime le motif Rouge, tandis que l'absence de couverture relationnelle maintient Ambre.

Enfin, le protocole doit rester inspectable. Une automatisation totale qui ne produirait qu'une couleur serait insuffisante. Les comptages, les recouvrements de clés, les requêtes exécutées et les motifs de décision doivent pouvoir être consultés. L'automatisation sert à rendre les contrôles cohérents et répétables ; elle ne remplace ni la justification des critères ni l'examen humain des cas ambigus.

4.10. Validité de construit et autorisation de mesure

Le protocole peut être lu comme un dispositif de protection de la validité de construit. La capacité visée est celle d'un agent à interpréter une question, à identifier les éléments pertinents d'un schéma et à produire une requête SQL correcte. Pour que le score représente cette capacité, les variations de résultat doivent provenir principalement du comportement de l'agent. Une perte de données, une relation absente ou une référence ambiguë introduisent des causes concurrentes. Le score ne permet alors plus d'attribuer clairement l'erreur au système évalué.

La qualification préalable cherche à réduire ce facteur de confusion en séparant deux décisions. La première concerne l'éligibilité de la tâche : le support local rend-il la question calculable et la référence interprétable ? La seconde concerne l'évaluation de l'agent : la sortie respecte-t-elle les règles et produit-elle le résultat attendu ? Cette séparation interdit de diagnostiquer les données à partir de la seule réponse du modèle. Un agent prudent qui s'abstient ne doit pas être utilisé comme preuve que la base est insuffisante ; cette insuffisance doit être établie indépendamment par l'audit.

Trois issues sont possibles. Une tâche Rouge est bloquée par un défaut critique démontré. Une tâche Ambre reste techniquement inspectable, mais une preuve nécessaire manque ou demeure ambiguë. Une tâche Verte est candidate à la mesure parce que les contrôles déclarés sont positivement satisfaits. Cette dernière formulation est volontairement prudente : le statut Vert autorise le passage à l'étape suivante, mais ne garantit ni l'absence de toute erreur future ni la supériorité d'une métrique particulière.

La décision est prospective autant que diagnostique. Lorsqu'une intervention est envisagée, le protocole exige de conserver l'état historique, d'explicitier la transformation et de rejouer les contrôles. Une correction ne peut modifier silencieusement la définition de la tâche. Si les valeurs sont restaurées mais que la relation reste absente, la tâche progresse de

Rouge à Ambre sans être déclarée Verte. Cette règle protège contre une conclusion binaire qui confondrait “défaut ciblé supprimé” et “instrument de mesure validé”.

Le protocole joue enfin un rôle proche d'un critère d'arrêt préétabli. La campagne d'agents ne doit pas être poursuivie jusqu'à l'obtention d'un tableau de scores lorsque les conditions de mesure ne sont pas satisfaites. Le refus de calculer un score est donc prévu par la méthode et non décidé après observation d'un résultat décevant. Cette propriété réduit le risque de sélectionner a posteriori les tâches ou les interprétations qui produisent la conclusion la plus favorable.

La validité de cette autorisation reste elle-même limitée. Les sept règles découlent du problème étudié, de la littérature mobilisée et des risques observés. Elles n'ont pas encore été comparées à une autre grille, appliquées en aveugle par plusieurs évaluateurs ni éprouvées sur un corpus indépendant comportant des cas positifs connus. Le mémoire présente donc une formalisation argumentée et mise à l'épreuve localement, non une norme universelle.

5. Mise à l'épreuve expérimentale du protocole

5.1. Objectif et organisation des expérimentations

Les expériences ne cherchent pas à établir la supériorité d'un agent. Elles mettent à l'épreuve la capacité du protocole à détecter une tâche non mesurable, à isoler une cause de reconstruction, à vérifier l'effet d'une correction et à maintenir une décision prudente lorsque les relations restent insuffisantes. L'unité d'analyse est la tâche locale, définie par une question, une base, un schéma, des données et une référence.

La progression suit le chemin réel de la recherche : audit initial, étude causale de local023, intervention contrôlée, reconstructions fraîches et empreintes logiques, formalisation de la grille, extension aux vingt tâches, correction des divergences restantes et audit de couverture relationnelle. Chaque étude distingue l'objectif, la méthode, le résultat, l'interprétation et les limites.

Deux traces d'agents sont ensuite examinées comme des observations de protocole, jamais comme une comparaison de performance, puisqu'aucune tâche ne reçoit finalement le statut Vert.

Les résultats sont figés : le travail éditorial ne modifie ni les chiffres ni les artefacts et n'ajoute aucune expérience non documentée.

5.2. Audit initial de viabilité

Objectif et hypothèse

L'objectif est d'établir l'état initial des vingt tâches sans utiliser les sorties d'agents comme diagnostic. L'hypothèse est qu'une vérification combinant intégrité, colonnes critiques, jointures et référence révélera des différences invisibles dans un simple test d'ouverture SQLite.

L'audit initial porte sur les 20 tâches pilotes. Son résultat est sans ambiguïté pour toute mesure d'exactitude : aucune tâche n'est Verte. Treize sont Ambre et sept sont Rouge. Cette distribution n'est pas l'évaluation d'un agent. Elle décrit l'état des environnements de données locaux au regard des critères alors disponibles [E13-E19].

Statut initial	Nombre de tâches	Sens méthodologique
Vert	0	Aucune tâche ne réunit alors toutes les conditions nécessaires à une mesure d'exactitude interprétable.

Statut initial	Nombre de tâches	Sens méthodologique
Ambre	13	La base est partiellement exploitable, mais une condition nécessaire au score manque, reste ambiguë ou non établie.
Rouge	7	Un défaut critique de reconstruction ou d'interprétation minimale est démontré ou suffisamment documenté pour bloquer l'évaluation.

Tableau 4 - Distribution initiale des statuts de viabilité. Source : audit de viabilité local [E13-E19].

L'intérêt de cette étape est de faire apparaître un fait qui serait invisible dans une campagne d'agents : il est possible d'obtenir une base SQLite lisible, un schéma SQL généré et une requête de référence techniquement exécutable sans disposer d'une tâche sémantiquement viable. Le protocole refuse donc de faire de l'exécution technique un raccourci vers la mesure d'exactitude. Il enregistre au contraire les contrôles de nullité, les correspondances de clés et les résultats de référence afin d'expliquer le statut attribué.

La situation de local023 a servi de point d'entrée à l'analyse causale parce qu'elle rassemble plusieurs caractéristiques : une base IPL de huit tables et quarante lignes, un contrôle SQLite positif, une question nécessitant une chaîne de jointures et des colonnes critiques inexploitées dans la reconstruction historique. À ce stade, l'audit initial ne formulait qu'un diagnostic de défaut probable d'import ou de correspondance. Les études suivantes transforment ce diagnostic en cause démontrée dans un périmètre limité [E09-E19, E41].

5.2.1. Enseignement méthodologique

L'audit initial montre qu'une campagne d'agents aurait été prématurée. Les sept tâches Rouge comportaient un défaut critique ; les treize tâches Ambre ne fournissaient pas toutes les preuves nécessaires. Le chiffre de zéro tâche Verte constitue donc un résultat sur le dispositif, et non sur les outils qui devaient y être évalués.

Interprétation et limites

La distribution initiale décrit le support expérimental, non la performance des modèles. Elle constitue une photographie du pilote au regard des preuves disponibles et ne permet pas de généraliser aux 547 questions inventoriées.

L'audit initial combine plusieurs familles de contrôles. Il vérifie la présence et l'ouverture de la base, les tables attendues, les colonnes nécessaires à la question, la proportion de valeurs nulles dans les champs critiques, le recouvrement des clés de jointure et le résultat de la requête de référence. Cette combinaison permet d'éviter qu'un seul indicateur, par exemple PRAGMA quick_check, soit utilisé comme preuve générale de viabilité.

Les treize tâches Ambre ne présentent pas toutes le même diagnostic détaillé. Elles partagent cependant une conséquence : au moins une preuve nécessaire au score manque ou reste ambiguë. Les sept tâches Rouge présentent des pertes de correspondance démontrées ou un défaut critique équivalent dans la reconstruction. Aucune tâche ne fournit à la fois les valeurs, les relations et une référence interprétable nécessaires au statut Vert.

5.3. Étude de cas local023 : diagnostic causal

Objectif, hypothèses et enquête

L'étude cherche à expliquer pourquoi sept colonnes nécessaires sont nulles dans la reconstruction historique. Les hypothèses examinées portent sur l'absence des valeurs dans les sources, une erreur de schéma, une erreur d'insertion et une incompatibilité entre les noms français et anglais.

La tâche local023 demande d'identifier les cinq meilleurs joueurs selon une moyenne de points par match pour une saison donnée ; ces points sont appelés « runs » dans les données de cricket. La question nécessite au minimum un filtre de saison, une relation entre les matchs et les événements de jeu, une mesure des points et un rattachement des identifiants aux noms de joueurs. L'étude suit donc sept colonnes critiques : `match.season_id`, `match.match_id`, `ball_by_ball.match_id`, `ball_by_ball.ball_id`, `batsman_scored.runs_scored`, `player.player_id` et `player.player_name` [E51, E53-E54].


La reconstruction historique présente un mécanisme simple mais lourd de conséquences. Les fichiers JSON français contiennent les valeurs sous des clés traduites, notamment `id_de_saison`, `id_de_match`, `id_de_balle`, `points_marques`, `id_joueur` et `nom_joueur`. Le DDL, lui, définit les colonnes avec des noms anglais. Lors de l'insertion historique, le script parcourt les colonnes attendues et appelle `row.get(col)`. Si `col` vaut `match_id` alors que la ligne JSON n'a que la clé `id_de_match`, le résultat de l'accès est `None`. SQLite reçoit alors `NULL`. Le défaut ne provient donc pas d'une absence généralisée de valeurs dans les lignes sources étudiées ; il provient d'une incompatibilité explicitement observable entre clé source et colonne cible [E53-E54].

Colonne cible	Clé française observée	Valeurs sources non nulles	Valeurs non nulles historiques	Lecture
<code>match.season_id</code>	<code>id_de_saison</code>	5	0	Clé française disponible ; clé anglaise absente dans l'insertion historique.
<code>match.match_id</code>	<code>id_de_match</code>	5	0	Même mécanisme de perte à l'import.

Colonne cible	Clé française observée	Valeurs sources non nulles	Valeurs non nulles historiques	Lecture
ball_by_ball. match_id	id_de_match	5	0	Même mécanisme de perte à l'import.
ball_by_ball. ball_id	id_de_balle	5	0	Même mécanisme de perte à l'import.
batsman_scored. runs_scored	points_marques	5	0	Même mécanisme de perte à l'import.
player. player_id	id_joueur	5	0	Même mécanisme de perte à l'import.
player. player_name	nom_joueur	5	0	Même mécanisme de perte à l'import.

Tableau 5 - Filiation des sept colonnes critiques de local023. Les compteurs se rapportent aux lignes suivies dans l'audit. Source : ligne de filiation locale [E53-E54].

Chaîne causale observée sur local023



Effet établi : Rouge → Ambre. Effet non établi : Ambre → Vert.

Figure 4 - Chaîne causale local023 : une incompatibilité de noms introduit des valeurs NULL ; la correspondance explicite restaure les valeurs sans établir la viabilité relationnelle. Source : études local023 [E53-E56].

5.3.1. Pourquoi le diagnostic est causal, mais local

Le terme « causal » est employé ici dans un sens circonscrit. La condition historique et la condition corrigée utilisent les mêmes données locales et le même objectif de reconstruction, tandis que la correspondance explicite de colonnes est la modification contrôlée. La disparition des sept divergences suivies après cette modification soutient l'attribution du mécanisme de perte au défaut de correspondance. Cette conclusion ne prétend pas expliquer l'histoire complète des ressources externes ni l'état de tous les environnements possibles. Elle

établit uniquement que, dans la reconstruction locale étudiée, l'accès à une clé anglaise absente est responsable des NULL observés dans les colonnes suivies.

L'étude montre également une limite utile : la restauration de valeurs ne prouve pas que la question devient calculable. Les relations entre tables peuvent demeurer absentes dans l'échantillon, et la requête SQL de référence peut continuer à retourner zéro ligne. C'est exactement ce qui se produit pour local023. Le diagnostic de correspondance est donc une étape nécessaire, non une condition suffisante de viabilité.

5.3.2. Enseignement méthodologique

Le mécanisme est silencieux : aucun échec de création de la base ne signale la perte. La filiation des colonnes complète donc les contrôles d'intégrité. Elle vérifie non seulement que la structure existe, mais que la valeur qui devait l'alimenter a bien traversé la transformation.

Interprétation et limites

La comparaison des sources, du schéma et du code établit un mécanisme précis dans le périmètre étudié. Elle ne démontre pas que toutes les anomalies du corpus ont la même origine, ni que les distributions officielles utilisent cette procédure locale.

5.4. Intervention contrôlée sur local023

Objectif et principe de l'intervention

L'objectif est de tester la cause identifiée sans écraser les artefacts historiques. Une correspondance explicite et limitée associe chaque clé française observée à la colonne anglaise cible, puis une nouvelle base est reconstruite et comparée à la condition historique.

L'intervention conserve une condition historique, identifiée par le nom technique BASELINE_HISTORIQUE, et crée séparément une condition corrigée, identifiée par CORRIGE_MAPPING. Aucun fichier historique n'est écrasé. La correspondance est explicitement versionnée dans une configuration limitée à la base IPL et aux champs directement observés. Les ambiguïtés éventuelles ne sont pas comblées par une traduction automatique ou une règle heuristique. Cette contrainte est importante : une correction non documentée pourrait améliorer la forme de la base tout en masquant une inférence non vérifiable.

Condition	Divergences critiques	Statut de viabilité	Jointures nécessaires	Requête SQL de référence
Condition historique	7	Rouge	0	0 ligne
Condition corrigée	0	Ambre	0	0 ligne

Tableau 6 - Effet de l'intervention contrôlée sur local023. Source : rapport et CSV d'intervention [E55-E56].

La correction restaure les valeurs critiques associées explicitement et réduit les divergences de sept à zéro. Elle ne modifie pas le verdict de score : local023 devient Ambre, jamais Vert. Les jointures nécessaires restent nulles selon les diagnostics locaux et la requête SQL de référence n'apporte pas de résultat interprétable. Cette situation est méthodologiquement centrale. Elle empêche de confondre « correction du défaut de reconstruction » et « validation de la tâche ».

Cinq tests unitaires ont été rapportés comme réussis pour l'intervention. Ils contrôlent notamment la séparation entre condition historique et condition corrigée, la détection de la divergence historique, la préservation des valeurs sources dans la condition corrigée et l'impossibilité de promouvoir la tâche en Vert lorsque la couverture relationnelle ou la référence reste vide. Le test d'intégrité historique, qui échoue volontairement en signalant sept divergences de la reconstruction non corrigée, n'est pas comptabilisé comme validation de la correction ; il joue le rôle de détecteur de défaut historique [E73, E79].

5.4.1. Ce que la correction démontre - et ce qu'elle ne démontre pas

La disparition des sept divergences établit l'efficacité de la correspondance pour le défaut ciblé. Le maintien à zéro des jointures et de la référence interdit toutefois une conclusion plus forte. Une correction peut être techniquement complète et scientifiquement insuffisante : ce sont deux niveaux d'évaluation différents.

L'intervention est conçue comme une comparaison entre deux conditions. La condition historique conserve le script et les données tels qu'ils ont produit le défaut. La condition corrigée ajoute une configuration de correspondance limitée aux champs observés. Aucun fichier historique n'est écrasé, ce qui permet de rejouer la détection initiale et d'éviter une reconstruction rétrospective impossible à vérifier.

Le choix d'une configuration explicite plutôt que d'une traduction automatique répond à un risque méthodologique. Deux termes peuvent sembler équivalents sans l'être dans le modèle de données. Une règle générale pourrait remplir une colonne avec une clé plausible et produire une base plus dense mais sémantiquement fausse. La correction est donc restreinte aux associations démontrées par les fichiers et le contexte de la table.

5.5. Rejouabilité locale par empreintes logiques

Objectif et protocole


L'objectif est de vérifier que l'effet observé ne dépend pas d'une exécution isolée. Deux reconstructions historiques et deux reconstructions corrigées sont produites à partir d'espaces frais, puis comparées au moyen d'une représentation normalisée du schéma et du contenu.

Une correction ponctuelle n'est utile que si elle peut être rejouée. L'étude de rejouabilité locale reconstruit donc quatre bases fraîches : deux dans la condition historique et deux dans la condition corrigée. Plutôt que de comparer seulement les fichiers SQLite au niveau binaire, elle calcule une empreinte logique. Cette empreinte sérialise, dans un ordre déterministe, le schéma, la liste des tables, les colonnes, les lignes et une représentation explicite des valeurs NULL. Elle vise ainsi à comparer le contenu logique de deux reconstructions plutôt que des détails d'encodage de fichier [E57-E60].

Condition	Reconstruction 01 / 02	Empreinte logique SHA-256	Interprétation
Condition historique	Identiques	afc1f3e7ec5c25b6 5790e74e53f98fb1 1debfb7c1655f94 c73614dc771ec7de	Même reconstruction logique au sein de la condition.
Condition corrigée	Identiques	226d321fad13b5ed 2e5ea908ce2d77c3 332d9975e91aaf6f 11ed420c6ca1f32a	Même reconstruction logique au sein de la condition.
Historique vs corrigée	Différentes	Empreintes distinctes	La correction modifie bien le contenu logique reconstruit.

Tableau 7 - Empreintes logiques des reconstructions local023. Source : manifeste de rejouabilité locale [E57-E60].

Rejouabilité locale par empreintes logiques



Deux reconstructions par condition produisent le même contenu logique ; les deux conditions restent volontairement distinctes.

Portée : rejouabilité dans l'environnement documenté, sans prétention de réplication multi-machine.

Figure 5 - Rejouabilité locale de local023 et empreintes logiques observées. Source : étude de rejouabilité locale [E57-E60].

Sept tests unitaires ont été rapportés comme réussis pour cette étude. Ils vérifient l'identité logique des deux bases historiques, l'identité logique des deux bases corrigées, la persistance de sept divergences dans la condition historique, leur disparition dans la condition corrigée et l'interdiction de Vert lorsque les jointures ou la référence restent à zéro. La conclusion doit toutefois être lue avec sa limite : la rejouabilité est établie dans le périmètre local documenté, avec les entrées, scripts, système et versions disponibles. Elle ne constitue pas une réplication sur une autre machine ni une garantie de stabilité si les sources changent [E57-E60, E74].

5.5.1. Portée de la répétition

L'identité des empreintes au sein de chaque condition montre que les reconstructions contrôlées produisent le même contenu logique. Elle ne vaut pas réplication indépendante : la machine, les versions et les entrées restent celles du même environnement. Le mémoire emploie donc « rejouabilité locale » lorsque cette nuance est nécessaire.

5.6. Formalisation et vérification de la grille de viabilité

Objectif et logique de validation

L'objectif est de transformer les décisions historiques en règles explicites. La grille est appliquée aux vingt tâches et ses sorties sont comparées aux statuts documentés afin de vérifier la cohérence de la formalisation.

L'audit initial utilisait une catégorisation Vert / Ambre / Rouge. Pour éviter qu'elle soit seulement descriptive ou dépendante d'une lecture a posteriori, une grille versionnée a été produite. Elle associe les conditions minimales de viabilité à des règles de décision explicites :

validité technique, schéma, valeurs critiques, correspondances de colonnes, jointures, référence interprétable et traçabilité des entrées [E61].

Un rejoueur lit les indicateurs disponibles dans l'audit historique, applique ces règles et compare le statut proposé au statut enregistré. Sur les 20 tâches pilotes, le rejoueur confirme 20 statuts sur 20 et ne relève aucune divergence. Ce résultat démontre une cohérence déterministe de la grille avec l'audit existant dans le corpus local. Il ne prouve pas que la grille a reçu une validation externe indépendante, car elle est appliquée à un corpus et à des indicateurs dont elle formalise la logique [E61-E62].

Élément	Résultat	Portée
Statuts historiques relus	20 / 20 confirmés	Concordance du rejoueur avec l'audit local.
Divergences de statut	0	Pas de différence entre statut historique et statut rejoué.
Tests automatisés	9 tests unitaires, OK	Vérification des règles et des cas de décision déclarés.
Limite	Validation externe non établie	Le rejeu ne remplace pas un audit indépendant par un autre évaluateur ou un autre corpus.

Tableau 8 - Rejeu de la grille de viabilité v1. Sources : rapport de rejeu, configuration v1 et tests [E61-E62, E75].

5.6.1. Risque de circularité

La concordance de vingt statuts sur vingt prouve que les règles formalisent l'audit de manière déterministe. Elle ne constitue pas une validation externe, car la grille et l'audit appartiennent au même corpus méthodologique. Une étude inter-évaluateurs reste nécessaire pour mesurer l'accord d'application.

5.7. Sensibilité du pilote aux divergences de correspondance

Objectif et méthode

L'étude examine si le mécanisme observé sur local023 affecte d'autres tâches. Les clés sources et les colonnes cibles sont comparées de manière systématique, puis l'impact des divergences démontrées sur les statuts est simulé avant toute correction.

Après le diagnostic de local023, la question suivante est celle de la généralité interne du mécanisme. Une étude de sensibilité examine les 20 tâches pilotes une à une : DDL utilisés, fichiers JSON sélectionnés, ordre de sélection, colonnes du schéma, clés présentes dans les JSON et risque de divergence entre clé source et colonne cible. Le protocole interdit les correspondances implicites. Une tâche est classée sans divergence détectée, divergence démontrée, divergence possible non établie ou données insuffisantes pour auditer selon les éléments réellement observables.

Catégorie de risque de correspondance	Nombre de tâches	Interprétation
Aucune divergence détectée (AUCUNE_DIVERGENCE_DETECTEE)	9	Aucune divergence critique n'est détectée dans l'audit réalisé ; cela ne vaut pas Vert.
Divergence démontrée (DIVERGENCE_DEMONTREE)	7	Une incompatibilité entre clé source et colonne cible est observée dans le périmètre audité.
Divergence possible non établie (DIVERGENCE_POSSIBLE_NON_ETABLIE)	4	Un risque subsiste, mais les preuves disponibles ne permettent pas une correction explicite.
Données insuffisantes pour auditer (DONNEES_INSUFFISANTES_POUR_AUDITER)	0	Aucune tâche ne relève de cette catégorie dans le rapport de sensibilité.

Tableau 9 - Sensibilité des 20 tâches aux divergences de correspondance. Source : audit de sensibilité [E63].

À ce stade, seule la correction de local023 est appliquée. Le bilan passe de 13 tâches Ambre et 7 tâches au statut Rouge à 14 tâches Ambre et 6 tâches au statut Rouge ; aucune tâche n'atteint le statut Vert. Les six autres tâches présentant une divergence démontrée conservent le statut Rouge tant qu'une correspondance limitée à leur cas n'est pas établie. Cette discipline évite de résoudre une incertitude par une traduction seulement plausible. Une correspondance est considérée comme un élément de méthode : elle doit être versionnée, justifiée, restreinte et testable [E63-E64].

5.7.1. De l'étude de cas à l'audit du pilote

L'extension évite une généralisation intuitive de local023. Elle distingue explicitement les divergences démontrées, les divergences possibles et les cas sans divergence détectée. « Aucun défaut détecté » ne signifie pas « tâche conforme » ; le résultat porte uniquement sur la famille de risques recherchée.

Interprétation et limites

L'identification de cas analogues montre que le défaut n'est pas isolé dans le pilote. Elle ne prouve pas que toutes les différences de nommage doivent être traduites : seules les correspondances soutenues par les ressources disponibles sont retenues.

5.8. Correction contrôlée des six divergences restantes

Objectif et conditions de correction

L'objectif est de supprimer les pertes de valeurs démontrées dans six autres tâches sans inventer de données. Chaque correspondance est versionnée, limitée au cas observé et contrôlée par une comparaison avant-après.

La correction porte sur les six tâches classées en divergence démontrée à l'exclusion de local023 : local019, local075, local157, local163, local229 et local259. Pour chacune, une condition historique et une condition corrigée sont conservées séparément. Les correspondances de colonnes sont explicites et ne sont appliquées que lorsqu'elles sont directement démontrées par les fichiers étudiés. Les colonnes ambiguës ne sont pas corrigées par inférence [E65-E67].

Tâche	Divergences avant	Divergences après	Statut avant	Statut après
local019	19	0	Rouge	Ambre
local075	77	0	Rouge	Ambre
local157	77	0	Rouge	Ambre
local163	82	0	Rouge	Ambre
local229	48	0	Rouge	Ambre
local259	48	0	Rouge	Ambre
Total	351	0	6 Rouge	6 Ambre

Tableau 10 - Correction contrôlée des six tâches restantes. Source : rapport et fichier CSV de correction [E65-E67].

La réduction de 351 divergences à zéro montre que le mécanisme de correspondance n'était pas une anomalie isolée à local023. Dans le périmètre étudié, les six tâches passent du statut Rouge au statut Ambre. Aucun cas n'atteint le statut Vert. Ce résultat est double : il établit que les valeurs associées par des correspondances explicites peuvent être restaurées sans transformation heuristique ; il montre aussi que la suppression du défaut de correspondance ne suffit pas à démontrer les jointures nécessaires ni l'interprétabilité de la référence SQL [E66-E67].

Sept tests unitaires ont été rapportés comme réussis pour cette correction. Ils vérifient notamment que les six tâches sélectionnées correspondent au rapport de sensibilité, qu'aucune correspondance n'est appliquée sans preuve directe, que les fichiers historiques ne sont pas modifiés et qu'aucune tâche n'obtient le statut Vert sans satisfaire l'ensemble des règles de la grille [E77].

5.8.1. Effet consolidé de la correction

Les 351 divergences supprimées sur les six tâches, ajoutées aux sept de local023, conduisent à 358 corrections documentées. Le passage de sept tâches Rouge à vingt tâches Ambre montre que le défaut de correspondance expliquait les blocages critiques ciblés. Il ne crée aucune tâche mesurable.

5.9. Analyse de la couverture relationnelle

Objectif et définition opérationnelle

L'étude cherche à déterminer si les clés et les relations nécessaires aux questions sont effectivement présentes dans les échantillons. La couverture relationnelle est examinée à partir des intersections de clés, de la chaîne de jointures et du comportement de la référence.

La correction des correspondances déplace la question. Si les valeurs critiques sont désormais transférées correctement, pourquoi aucune tâche ne devient-elle Vert ? L'audit de couverture relationnelle examine ce point à partir de relations explicitement établies : clauses JOIN ... ON de la requête SQL de référence quand elles sont disponibles ou relations clairement décrites par le schéma. Il refuse d'inférer des relations métier non documentées. Cette restriction est volontaire, car une jointure plausible n'est pas une jointure démontrée.

Pour chaque relation identifiable, l'audit compare les valeurs non nulles et leur recouvrement côté source, puis côté SQLite reconstruite. Cinq diagnostics sont prévus : relation absente dans l'échantillon source ; relation perdue à l'import ; relation préservée mais résultat vide ; relation préservée et résultat interprétable ; relation non établie. Ces catégories permettent de distinguer une limite des données sources d'un échec de reconstruction. Elles empêchent aussi de baptiser « perte à l'import » une relation qui n'est pas observable dans les sources.

Diagnostic consolidé	Nombre de tâches	Signification
Relation non établie (RELATION_NON_ETABLIE)	16	Les preuves disponibles ne permettent pas de dériver la relation nécessaire sans hypothèse supplémentaire.
Relation absente de l'échantillon source (RELATION_ABSENTE_DANS_L_ECHANTILLON_SOURCE)	4	Aucune valeur commune n'est observée dans les sources sur une relation nécessaire.
Relation perdue à l'import (RELATION_PERDUE_A_L_IMPORT)	0	Aucune perte relationnelle résiduelle n'est démontrée après les correspondances explicites.
Relation préservée, résultat vide (RELATION_PRESERVEE_MAIS_RESULTAT_VIDE)	0	Aucun cas classé dans cette catégorie.
Relation préservée et résultat interprétable (RELATION_PRESERVEE_ET_RESULTAT_INTERPRETABLE)	0	Aucun cas classé dans cette catégorie.

Tableau 11 - Diagnostics de couverture relationnelle. Source : audit et manifeste de couverture relationnelle [E69-E71].




Figure 6 - Distribution des diagnostics de couverture relationnelle. Les vingt tâches restent hors mesure d'exactitude. Source : audit de couverture relationnelle [E69-E71].

Douze relations nécessaires sont explicitement absentes dans les sources étudiées et aucune relation nécessaire n'est démontrée comme perdue à l'import après correction. Aucun résultat de référence n'est interprétable dans l'audit final. Cette conclusion doit être formulée avec précision : elle n'affirme pas que les relations seraient absentes du jeu de données externe originel ; elle constate leur absence ou leur non-établissement dans les échantillons locaux et les preuves consultées. Cette nuance justifie le maintien de tous les cas en Ambre [E69-E72].

5.9.1. Pourquoi les relations ne sont pas recréées artificiellement

Ajouter des lignes ou modifier des identifiants aurait transformé le corpus en données synthétiques. Une telle démarche aurait nécessité un nouveau protocole de validation métier. L'étude choisit de préserver les échantillons et de déclarer leur insuffisance plutôt que de fabriquer une réponse à la question.

5.10. Résultats consolidés

Objectif de la consolidation

Cette section rassemble les résultats sans confondre les corrections d'importation et l'éligibilité à la mesure. Elle retrace l'évolution 13 Ambre, 7 Rouge et 0 Verte, puis 14 Ambre, 6 Rouge et 0 Verte, enfin 20 Ambre, 0 Rouge et 0 Verte.

La lecture consolidée doit respecter l'ordre temporel et logique des études. L'audit initial aboutit à 13 tâches Ambre et 7 tâches au statut Rouge, sans tâche au statut Vert. La correction

documentée de local023 conduit à 14 tâches Ambre et 6 tâches au statut Rouge. La correction des six autres divergences démontrées conduit ensuite à 20 tâches Ambre, sans tâche Rouge ni Verte. Le changement de statut exprime la résolution de défauts critiques de reconstruction ; il ne signifie pas que les tâches ont obtenu une qualité suffisante pour le calcul d'un score d'exactitude [E14-E15, E64, E68].




Figure 7 - Évolution des statuts de viabilité dans le périmètre corrigé. Les tâches passent de Rouge à Ambre après correction, sans accéder au statut Vert. Sources : audits initial, de sensibilité et de correction [E14-E15, E64, E68].

Étape	Vert	Ambre	Rouge	Divergences critiques corrigées	Décision de calcul d'un score d'exactitude
Audit initial	0	13	7	0	Interdit.
Après correction local023	0	14	6	7	Interdit.
Après correction des six autres tâches	0	20	0	358 au total	Interdit.

Tableau 12 - Synthèse consolidée des résultats. Les 358 divergences correspondent à 7 pour local023 et 351 pour les six tâches corrigées [E55, E66, E68].

La conclusion causale principale est donc stratifiée. Premièrement, les statuts Rouge initiaux du pilote étaient associés à des défauts de correspondance de colonnes démontrés et corrigés dans le périmètre versionné. Deuxièmement, la correction restaure les valeurs concernées et retire le motif Rouge lié au défaut de correspondance. Troisièmement, aucune tâche n'atteint le statut Vert parce que la couverture relationnelle requise par les questions

reste absente ou non établie dans les échantillons locaux. Aucun score d'agent n'est donc produit [E68-E72].

5.10.1. Réponse synthétique aux cinq questions de recherche

QR1 - Origine des statuts Rouge. Les sept statuts Rouge initiaux sont associés, dans le périmètre audité, à des divergences de correspondance entre clés sources et colonnes cibles. Le diagnostic est directement établi sur local023 puis retrouvé sur six autres tâches [E53–E67].

QR2 - Effet d'une correspondance explicite. Les correspondances limitées aux cas démontrés restaurent les valeurs critiques : sept divergences sont supprimées sur local023 et 351 sur les six autres tâches, sans modification des artefacts historiques [E55–E68].

QR3 - Éligibilité à la mesure. La correction ne suffit pas à rendre les tâches mesurables. Les vingt tâches restent Ambre, car les relations nécessaires ou l'interprétabilité de la référence ne sont pas positivement établies [E68–E72].

QR4 - Rejouabilité. Deux reconstructions historiques et deux reconstructions corrigées de local023 produisent, au sein de chaque condition, des empreintes logiques identiques. Le résultat est rejouable dans l'environnement documenté, mais n'équivaut pas à une réplique indépendante sur une autre machine [E57–E60].

QR5 - Cause résiduelle de l'absence de tâche Verte. Après suppression des divergences critiques d'importation, l'audit final attribue l'absence de Vert à une couverture relationnelle absente dans certains échantillons ou non établie par les preuves disponibles ; aucune perte relationnelle résiduelle n'est démontrée après correction [E69–E72].

Portée de la synthèse

Le résultat principal n'est pas l'amélioration des statuts mais l'explication de leur limite. Après correction, l'absence de Vert ne provient plus d'une divergence d'importation démontrée ; elle tient à la couverture relationnelle ou à l'insuffisance des preuves disponibles.

5.11. Observations documentées sur deux exécutions d'agents

Objectif de l'observation

Les traces Vibe et Codex sont conservées pour distinguer les états possibles d'une exécution : absence de sortie, dépassement de budget, fichier structuré, abstention, requête exécutable et résultat vide. Elles ne sont pas transformées en comparaison de performance.

Deux exécutions réelles sur local023 ont été documentées avant la correction des correspondances de colonnes. Elles sont retenues à titre d'observations de protocole, pas comme résultats de performance. Leur valeur est illustratrice : elles montrent que la fin d'un processus, l'existence d'un fichier de sortie, l'exécutabilité d'une requête et l'exactitude sont quatre dimensions distinctes.

Outil / exécution	Paramètres ou état observé	Sortie documentée	Interprétation autorisée
Vibe - 20260629_022234	MaxTokens 65 000 ; MaxTurns 12	Pas de answer.json ; arrêt sur dépassement de plafond de tokens : 66 941 > 65 000.	Non-completion sous la configuration documentée ; aucun score calculable.
Codex CLI 0.142.3 - 20260629_025110	Code de sortie 0 ; durée 94,423 s	answer.json présent ; statut abstain ; SQL en lecture seule exécutable, résultat 0 ligne.	Abstention documentée dans un environnement non viable ; exactitude non établie.

Tableau 13 - Observations d'exécution sur local023. Sources : journaux et validation post-exécution [E24-E38].

Le programme d'exécution de Vibe distingue un mode de simulation d'un mode d'exécution réelle et ne lance l'outil qu'avec un garde-fou explicite. Dans l'exécution observée, l'outil s'arrête avant la production du fichier attendu. Il est donc incorrect de lui attribuer une réponse juste ou fausse. Pour Codex, le fichier answer.json est valide et la requête proposée s'exécute en lecture seule, mais renvoie zéro ligne dans une tâche alors classée Rouge. Le statut abstain est motivé par des colonnes nécessaires nulles. Cette observation est compatible avec l'état des données, mais ne démontre rien sur la qualité générale de l'outil [E23-E38].

La présence de ces observations dans le mémoire a une fonction pédagogique. Elle empêche d'amalgamer une absence de fichier, une abstention et une requête vide. Dans un protocole correctement conçu, chacun de ces états est journalisé et interprété selon la viabilité de la tâche. L'agent reste un composant de l'expérience ; il n'est pas le juge de la qualité des données.

5.11.1. Pourquoi ces exécutions ne constituent pas une comparaison

Les paramètres, outils et résultats documentent deux comportements dans une tâche non Verte. Le dépassement de budget de Vibe et l'abstention structurée de Codex ne peuvent pas être convertis en score de compétence. L'environnement ne permet pas d'isoler ce qui relève de l'agent, de la prudence de sa stratégie ou de la non-viabilité des données.

Interprétation et limites

Vibe n'a pas finalisé la sortie attendue dans une exécution locale ; Codex a produit une abstention accompagnée d'une requête exécutable renvoyant zéro ligne. Ces faits décrivent les conditions observées, mais la tâche Ambre interdit de conclure à l'exactitude ou à la supériorité d'un outil.

5.12. Réponses aux questions de recherche

La première question reçoit une réponse positive dans le périmètre local : les statuts Rouge initiaux proviennent bien de défauts de reconstruction identifiables lorsque la divergence source-base est observée et expliquée. Local023 fournit la démonstration causale la plus détaillée, étendue ensuite à six autres tâches.

La deuxième question est également soutenue : une correspondance explicite restaure les valeurs perdues et supprime les divergences ciblées. La troisième reçoit en revanche une réponse négative : la correction ne rend pas les tâches éligibles à la mesure, car les relations nécessaires ou l'interprétabilité de la référence ne sont pas établies.

La quatrième question est soutenue au niveau de la rejouabilité locale par les empreintes logiques identiques au sein de chaque condition. Enfin, la cinquième question montre que l'absence de Vert s'explique principalement par des relations absentes dans certains échantillons et, pour les autres tâches, par une preuve relationnelle insuffisante.

Ces réponses montrent l'intérêt de séparer les niveaux de conclusion. Le protocole peut expliquer et corriger un défaut sans prétendre résoudre l'ensemble de la tâche.

Pris ensemble, ces résultats conduisent à une réponse méthodologique à la problématique générale : un corpus reconstruit peut être soumis à une qualification séquentielle, et cette qualification peut légitimement interrompre l'évaluation. Le mémoire valide surtout la capacité du protocole à détecter et expliquer une non-éligibilité ; sa validation sur plusieurs tâches au statut Vert reste un travail futur.

6. Discussion, limites et recommandations

6.1. Une méthode de qualification, et non un jugement sur les référentiels existants

Les résultats obtenus doivent être interprétés dans le périmètre exact de l'étude. Le travail ne démontre pas que les référentiels académiques consacrés à la conversion de questions vers SQL sont défaillants. Il ne permet pas davantage de conclure que les distributions officielles de Spider, MultiSpider ou Spider 2.0 présentent les anomalies observées dans l'environnement local.

L'objet étudié est différent : il s'agit d'une reconstruction locale réalisée à partir de ressources disponibles dans un dépôt de travail, puis adaptée à un protocole d'expérimentation en français. Les anomalies identifiées concernent cette chaîne locale de préparation, les fichiers effectivement sélectionnés, les règles d'importation appliquées et les échantillons réellement utilisés.

Cette distinction est essentielle. Une ressource peut être cohérente dans son environnement d'origine et devenir difficilement exploitable après une série de transformations : traduction de certaines clés, extraction partielle des données, conversion vers SQLite, sélection indépendante de quelques lignes par table ou combinaison de ressources provenant de répertoires distincts. Le problème ne réside alors pas nécessairement dans le référentiel initial, mais dans l'écart entre son contexte d'utilisation prévu et l'environnement effectivement remis à l'agent.

Le protocole proposé ne vise donc pas à invalider les référentiels existants. Il ajoute une étape de contrôle lorsque leur contenu est adapté ou reconstruit. Son rôle est de vérifier que les propriétés nécessaires à la mesure ont bien été conservées. Si les contrôles avaient conclu que les vingt tâches étaient pleinement exploitables, la même méthode aurait fourni les preuves permettant de lancer la campagne d'évaluation. Sa valeur ne dépend pas de la découverte d'un défaut.

Cette position évite deux excès : considérer toute ressource publiée comme automatiquement valide dans n'importe quelle adaptation, ou utiliser un défaut local pour disqualifier une ressource entière. Le mémoire reste entre ces deux positions en examinant les artefacts effectivement manipulés.

6.2. Pourquoi cet environnement local constituait un cas d'étude pertinent

Le choix de cet environnement ne reposait pas sur la connaissance préalable de ses limites. Il répondait initialement à un besoin expérimental : réunir des questions en français, des schémas relationnels, des requêtes SQL de référence et des données pouvant être préparées localement pour plusieurs agents.

Un corpus existant présentait plusieurs avantages par rapport à la création de données entièrement nouvelles. Il permettait de partir de questions et de structures qui n'avaient pas été conçues spécifiquement pour favoriser les agents étudiés. Il évitait également de fabriquer les réponses attendues après avoir observé le comportement des systèmes.

Le recours à un environnement local offrait un contrôle direct sur les fichiers remis aux agents. Les mêmes données, les mêmes instructions et les mêmes limites d'accès pouvaient être appliquées à chaque exécution. Cette maîtrise était nécessaire pour envisager une comparaison équitable.

Les difficultés sont apparues pendant cette préparation. Elles n'ont pas motivé le choix initial du corpus ; elles ont modifié la question de recherche. Le projet est passé d'une comparaison d'agents à l'audit du support expérimental, puis à la conception d'un protocole de qualification préalable. La méthode est ainsi née d'un problème réel de préparation, et non d'un scénario construit a posteriori pour illustrer une conclusion déjà décidée.

Enfin, l'environnement fournit des états contrastés : défaut de correspondance démontré, correction réussie, rejouabilité locale et insuffisance relationnelle persistante. Cette combinaison permet de tester plusieurs niveaux du protocole et d'illustrer pourquoi une correction technique n'est pas équivalente à une validation expérimentale.

6.3. Une base techniquement valide n'est pas nécessairement une tâche mesurable

Le cas local023 sépare nettement plusieurs niveaux qui sont souvent confondus. Le fichier SQLite est lisible ; les tables et les colonnes existent ; les contrôles techniques réussissent. Pourtant, certaines valeurs critiques ont d'abord été perdues pendant l'importation, puis les relations nécessaires sont restées absentes ou non établies après correction. La validité du fichier constitue donc une condition de fonctionnement, non une preuve de calculabilité.

Cette distinction s'applique aussi à la requête de référence. Une requête qui s'exécute sans erreur démontre sa compatibilité syntaxique avec le moteur et le schéma. Elle ne prouve pas

que le contenu de la base permet de juger une réponse d'agent. Deux requêtes non équivalentes peuvent produire le même résultat sur un échantillon pauvre ; inversement, une requête correcte peut retourner zéro ligne si les entités nécessaires ne se recouvrent pas.

Un résultat vide peut être parfaitement légitime. Pour devenir interprétable, il faut toutefois pouvoir démontrer qu'il correspond bien au sens de la question et non à une perte de valeurs, à une jointure impossible ou à un échantillonnage qui a détruit les relations. Dans le corpus étudié, cette démonstration n'était pas disponible pour les vingt tâches pilotes.

Le protocole distingue ainsi une chaîne de conditions successives : fichier présent, base techniquement valide, valeurs correctement importées, relations nécessaires préservées, résultat de référence interprétable, puis seulement tâche éligible à une mesure d'exactitude. Le franchissement d'un niveau ne garantit jamais le suivant.

L'enseignement dépasse SQLite. Dans un entrepôt infonuagique, un fichier tabulaire ou une base documentaire, une ressource peut être techniquement accessible et pourtant inadéquate pour la question. Les contrôles précis devront être adaptés, mais la distinction entre accessibilité et aptitude à la mesure demeure.

6.4. Le refus de calculer un score comme résultat scientifique

Les évaluations techniques valorisent souvent les tableaux de performance. Cette préférence peut encourager la production d'un nombre même lorsque ses conditions d'interprétation sont faibles. Le protocole adopte l'attitude inverse : l'absence de tâche Verte interdit le calcul d'un classement d'agents.

Cette décision n'est pas une interruption arbitraire. Elle localise le blocage, conserve les corrections démontrées et identifie les preuves qui manquent pour poursuivre. Un score aurait pu être calculé mécaniquement, mais il aurait attribué aux agents des effets provenant potentiellement des données, de la reconstruction ou de l'échantillonnage.

Le résultat principal est donc une décision de méthode : dans le périmètre documenté, ne pas comparer les agents. Le fait de renoncer à une mesure non défendable protège la validité de l'étude. Il transforme un résultat négatif en information utile sur les conditions minimales d'une future campagne expérimentale.

Dans une logique de projet, l'absence de classement peut sembler insatisfaisante. Dans une logique de recherche, elle devient un résultat lorsque la décision est fondée sur des critères annoncés, des preuves et une analyse des alternatives. Calculer malgré tout aurait

produit des nombres faciles à comparer, mais ces nombres auraient mélangé la qualité des agents et les limites du corpus.

Le non-calcul d'un score d'exactitude n'interdit pas toute observation. Les journaux peuvent renseigner la conformité au format, l'usage des outils ou la capacité d'abstention. Ils doivent simplement rester séparés d'une métrique d'exactitude. Le mémoire conserve ainsi des traces utiles sur Vibe et Codex sans les convertir en preuve de supériorité ou d'infériorité.

6.5. Portée potentielle et limites de généralisation de la méthode

Les contrôles ont été élaborés à partir d'un environnement francophone reconstruit sous SQLite. Plusieurs principes ne sont cependant pas liés exclusivement à cette langue ou à ce moteur. La vérification de la provenance, la conservation des valeurs, la justification des correspondances de colonnes et l'analyse des relations concernent toute transformation susceptible de modifier un support d'évaluation.

Ces questions peuvent apparaître lors d'une traduction de corpus, d'une conversion entre formats de stockage, d'une extraction partielle, d'une migration entre moteurs de bases de données, d'une anonymisation, d'une adaptation à un environnement agentique ou de la construction d'un sous-ensemble destiné à réduire les coûts d'exécution.

La méthode pourrait donc être adaptée à d'autres contextes, mais cette possibilité ne doit pas être confondue avec une généralisation déjà démontrée. Les critères devront être ajustés aux propriétés du corpus, au moteur utilisé, aux métriques retenues et à la nature des tâches. Une base documentaire, par exemple, ne sera pas auditée comme une base relationnelle.

La contribution réside moins dans une liste figée de contrôles que dans un principe : toute transformation susceptible de modifier les conditions de résolution d'une tâche doit être auditée avant que les résultats des agents puissent lui être attribués.

La grille elle-même doit être validée sur d'autres cas, notamment des tâches au statut Vert connues, des défauts différents et des évaluateurs indépendants. Tant que ces études ne sont pas réalisées, la portée démontrée reste le corpus local.

6.6. Comportements des agents face à une tâche non qualifiée

Deux exécutions d'agents ont été conservées dans le dossier expérimental. Elles ne sont pas utilisées pour produire un classement, mais elles illustrent la difficulté d'interpréter le comportement d'un agent lorsque la tâche elle-même n'est pas qualifiée.

Dans une première exécution, le fichier de réponse attendu n'a pas été produit avant l'atteinte de la limite de jetons configurée. Cette observation établit une non-finalisation dans les conditions précises de l'exécution. Elle ne permet pas de conclure à une incapacité générale de l'outil ni à une qualité inférieure à celle d'un autre agent.

Dans une seconde exécution, l'agent a produit une sortie structurée contenant une abstention et une requête SQL exécutable en lecture seule. La requête retournait zéro ligne. Le format et l'exécution sont donc vérifiables, mais l'exactitude ne l'est pas : l'environnement ne fournit pas de résultat de référence interprétable [E24-E38].

Ces traces imposent de distinguer plusieurs états qui ne doivent pas être confondus :

- absence de sortie attendue
- dépassement d'une limite de ressources
- erreur technique
- requête syntaxiquement exécutable
- résultat vide
- abstention explicite
- réponse exacte établie

Dans une tâche Verte, ces états pourraient contribuer à l'évaluation. Dans une tâche Ambre ou Rouge, ils décrivent seulement un comportement observé dans un environnement dont la capacité de mesure n'est pas établie. Sans cette séparation, une abstention prudente pourrait être notée comme un échec tandis qu'une réponse artificiellement assurée paraîtrait meilleure, alors même qu'elle ne serait pas vérifiable.

Une tâche non qualifiée peut induire des comportements opposés. Un agent prudent explore les tables, constate l'absence de résultat et s'abstient. Un autre produit une requête conforme à l'intention supposée, même si elle retourne zéro ligne. Un troisième cherche à modifier la base ou à inventer une hypothèse pour obtenir un résultat. Sans référence interprétable, il est impossible de transformer ces différences en classement d'exactitude.

La prudence n'est pas toujours récompensée par les métriques classiques. Une abstention peut être comptée comme une erreur, alors qu'elle évite une affirmation non vérifiable. À l'inverse, une requête qui coïncide avec un résultat vide peut obtenir un succès d'exécution sans être sémantiquement correcte. La conception d'évaluations agentiques devrait donc distinguer la correction, la calibration, l'abstention et le respect des contraintes.

Le mémoire ne mesure pas ces dimensions faute de tâches au statut Vert. Il montre cependant pourquoi elles devront être définies dans une campagne future. La qualification des données est la condition préalable ; une fois celle-ci satisfaite, le protocole pourra enregistrer la trajectoire de l'agent, son usage des outils et la qualité de sa décision finale.

6.7. Menaces à la validité

La solidité d'un travail expérimental dépend aussi de la manière dont ses limites sont reconnues. Le tableau suivant résume les principaux risques ; les sous-sections qui suivent explicitent leur portée.

Dimension	Risque	Réponse documentaire	Limite résiduelle
Validité interne	Les rapports de dépôt peuvent décrire des états intermédiaires différents.	Priorité aux CSV, JSON, manifests et résultats plus récents ; traçabilité par [E##].	Le document ne remplace pas l'audit de chaque fichier source brut.
Validité de construit	Risque de confondre fichier SQLite valide, SQL exécutable, answer.json valide et réponse exacte.	Séparation des niveaux technique, sémantique, sortie et exactitude.	Les règles restent spécifiques au protocole local.
Validité externe	Échantillons locaux limités, généralement cinq lignes par table ; environnement non officiel.	Conclusions strictement limitées au périmètre local et aux artefacts documentés.	Aucune généralisation à Spider, MultiSpider ou Spider 2.0.
Rejouabilité locale	Reconstructions répétées dans un même environnement, sans test sur une seconde machine.	Empreinte logique et scripts versionnés ; deux reconstructions par condition sur local023.	Pas d'extrapolation à un autre système, une autre version de Python ou des sources modifiées.
Validation externe de la grille	La grille est formalisée à partir du corpus qu'elle rejoue.	Rejeu déterministe 20/20, zéro divergence.	Pas de validation inter-évaluateur ou sur corpus externe.
Droits et licences	Les ressources locales référencent des ressources externes.	Limite explicitement conservée dans le registre.	Licences et droits de redistribution restent à vérifier avant diffusion.

Tableau 14 - Menaces à la validité et réponses documentaires.

6.7.1. Validité interne

L'analyse causale de local023 repose sur une comparaison entre les fichiers sources, le mécanisme d'importation historique et une condition corrigée. La disparition des sept divergences après l'introduction d'une correspondance explicite soutient l'explication retenue.

Cette conclusion reste limitée aux colonnes suivies et aux fichiers étudiés. Elle ne démontre pas que tous les problèmes du corpus relevaient du même mécanisme. La conservation séparée des conditions historique et corrigée, les fichiers bruts et les tests automatisés réduisent le risque de confondre l'effet de l'intervention avec une modification non documentée, sans supprimer toute possibilité d'erreur d'interprétation.

Une autre menace provient de l'ordre des analyses. La grille a été formalisée après les premiers audits, ce qui peut conduire à incorporer implicitement les caractéristiques du corpus étudié. Le registre chronologique, la conservation des rapports intermédiaires et la distinction

entre état historique et état corrigé réduisent ce risque sans l'annuler. Une validation prospective sur des tâches nouvelles demeure nécessaire.

6.7.2. Validité de la grille

La grille Vert, Ambre et Rouge reproduit les vingt décisions historiques sans divergence. Cette concordance montre que les règles ont été formalisées de manière cohérente avec l'audit existant.

Elle ne constitue pas une validation indépendante. La grille et l'audit proviennent du même travail, ce qui laisse subsister un risque de circularité. Une validation plus forte nécessiterait qu'un second évaluateur applique les règles sans connaître les statuts historiques, ou que la grille soit testée sur un autre corpus dont les résultats ne seraient pas connus à l'avance.

Une validation plus forte demanderait un protocole en aveugle : un second évaluateur recevrait les fichiers et les définitions des critères sans connaître les statuts historiques. L'accord pourrait être mesuré, les désaccords analysés et les règles ambiguës révisées. Cette étape n'a pas été réalisée et reste explicitement inscrite dans les perspectives.

6.7.3. Validité externe

L'étude porte sur vingt tâches pilotes et sur des échantillons locaux généralement limités à quelques lignes par table. Elle ne permet pas de conclure sur l'ensemble des questions disponibles, sur les distributions officielles d'origine, sur toutes les langues ou sur tous les moteurs de bases de données.

Les résultats établissent qu'un environnement local particulier ne satisfaisait pas les conditions définies. Ils montrent aussi que la méthode a permis d'expliquer plusieurs de ses limites. Toute application à un autre contexte nécessitera un nouvel audit et une adaptation explicite des règles.

Le pilote couvre vingt tâches et vingt environnements locaux, mais il provient d'une même chaîne de préparation et d'un même contexte francophone. Le protocole peut donc être sensible aux types de défauts présents dans cette chaîne. Des conversions de formats différentes, des bases non relationnelles, des schémas infonuagiques ou des tâches dont le résultat correct est légitimement vide pourraient nécessiter d'autres contrôles.

La transférabilité doit être testée plutôt que supposée. Une application future devra conserver le principe général — qualifier les transformations avant la mesure — tout en

redéfinissant les preuves attendues. Le mémoire revendique une portée analytique et méthodologique, pas une généralisation statistique à l'ensemble des évaluations d'agents.

6.7.4. Rejouabilité locale et réplication indépendante

Les reconstructions de local023 ont été répétées deux fois par condition et ont produit des empreintes logiques identiques au sein de chaque condition. Cette stabilité établit une jouabilité locale de l'intervention [E57-E60].

L'étude n'a pas été reproduite sur une seconde machine indépendante, sous un autre système d'exploitation ou avec d'autres versions logicielles. Le mémoire distingue donc la répétition contrôlée dans le même environnement de la réplication indépendante par une autre personne ou une autre infrastructure. Il ne revendique que la première.

Les quatre reconstructions de local023 démontrent que les mêmes entrées et scripts produisent la même représentation logique au sein de chaque condition. Cette stabilité est plus informative qu'une simple comparaison de fichiers binaires, car elle neutralise certains détails d'encodage SQLite. Elle reste néanmoins obtenue sur une même infrastructure et sous les mêmes versions générales de l'environnement.

Une réplication indépendante devrait être réalisée par une autre personne, sur une autre machine, à partir d'un paquet d'artefacts versionné et d'instructions complètes. Les écarts éventuels permettraient de distinguer les dépendances réellement nécessaires des propriétés accidentelles de l'environnement initial. Le mémoire emploie donc "jouabilité locale" plutôt que "reproductibilité universelle".

6.7.5. Représentativité des échantillons

Les fichiers utilisés ne contiennent généralement qu'un faible nombre de lignes par table. Une relation absente dans un échantillon de cinq lignes peut exister dans la base complète. Le diagnostic ne doit donc pas être interprété comme une affirmation générale sur le domaine métier ou sur toutes les données possibles.

Il décrit uniquement la capacité de l'échantillon remis à l'agent à soutenir la tâche concernée. Cette limite justifie l'une des recommandations centrales : préserver les relations nécessaires lors de la construction des échantillons, plutôt que de sélectionner indépendamment quelques lignes dans chaque table.

Cette limite affecte également le pouvoir discriminant d'une métrique d'exécution. Sur un échantillon trop pauvre, plusieurs requêtes non équivalentes peuvent produire le même résultat, notamment un ensemble vide. Une future étude devra comparer l'échantillonnage

indépendant utilisé ici à une sélection relationnellement cohérente construite à partir d'entités centrales et de leurs dépendances.

6.7.6. Provenance, versions et droits de redistribution

Les chemins locaux et les fichiers utilisés sont documentés, mais l'identité exacte de version et les droits de redistribution de l'ensemble des ressources n'ont pas été définitivement établis. Cette incertitude n'empêche pas l'analyse locale ; elle limite la possibilité de publier librement les bases reconstruites et certains fichiers sources.

Avant toute diffusion publique, les licences et les droits devront être vérifiés ressource par ressource. Les noms de répertoires ne peuvent pas, à eux seuls, servir de preuve d'origine officielle.

Une menace supplémentaire concerne la dépendance aux choix de décomposition des questions. L'audit relationnel identifie les tables et les clés jugées nécessaires. Une autre lecture métier pourrait, dans certains cas, proposer une requête équivalente utilisant une relation différente. Le risque est réduit par l'examen de la requête de référence et du schéma, mais il ne disparaît pas totalement. Une validation par un spécialiste du domaine renforcerait cette partie.

La mise en forme et le registre de preuves améliorent la vérifiabilité, mais ils ne remplacent pas la disponibilité du paquet de reproduction. Les droits de diffusion peuvent empêcher de partager certains fichiers, ce qui limite une réplication externe complète. Une publication future devrait fournir, lorsque les licences le permettent, les scripts, les empreintes, les configurations et un jeu de données de démonstration libre reproduisant les mécanismes essentiels.

Avant une publication du paquet de reproduction, chaque fichier devra être associé à une licence vérifiée, à une source identifiable et à une règle de redistribution. Si certains artefacts ne peuvent pas être diffusés, le protocole devra fournir des scripts de récupération ou de reconstruction et publier uniquement les empreintes, les configurations et les résultats autorisés.

6.8. Recommandations techniques et méthodologiques

Les résultats permettent de formuler des recommandations destinées aux personnes qui construisent ou adaptent un environnement d'évaluation. Elles sont synthétisées dans le tableau suivant, puis détaillées.

Recommandation	Mise en œuvre	Effet attendu
R1. Faire de Vert un verrou de calcul d'un score d'exactitude	Une campagne d'agents ne doit produire une mesure d'exactitude que sur des tâches dont toutes les conditions sont démontrées.	Évite les résultats numériquement propres mais conceptuellement non interprétables.
R2. Versionner les correspondances explicites	Chaque correspondance doit nommer la source, la colonne cible, la justification et le périmètre de validité.	Empêche les réparations silencieuses et facilite la revue.
R3. Conserver une condition historique	Une correction doit être évaluée contre une reconstruction historique séparée.	Permet une attribution causale limitée et vérifiable.
R4. Mesurer les jointures avant l'agent	Compter les clés non nulles, les valeurs communes et le noyau de jointure des relations nécessaires.	Distingue une limite source d'une perte à l'import.
R5. Traiter l'Ambre comme hors score	Ambre peut servir à auditer le pipeline, pas à mesurer un agent.	Préserve la frontière entre fonctionnement technique et évaluation d'exactitude.
R6. Ajouter une validation indépendante	Faire auditer une partie du corpus par un second évaluateur avec la grille gelée.	Réduit le risque de circularité de la classification.
R7. Résoudre la provenance avant diffusion	Vérifier les versions, les licences et les droits de redistribution des ressources.	Condition nécessaire à une diffusion scientifique ou publique responsable.

Tableau 15 - Recommandations techniques et méthodologiques dérivées du périmètre local.

6.8.1. Conserver un inventaire exact des entrées

Chaque tâche devrait être associée aux fichiers de question, de schéma, de données et de référence réellement utilisés. Les chemins seuls ne suffisent pas toujours : des empreintes numériques permettent de vérifier qu'un fichier n'a pas changé entre deux campagnes.

L'inventaire devrait être généré automatiquement au début de chaque campagne et contenir, pour chaque tâche, les chemins, tailles, dates, empreintes, versions et rôles des fichiers. Il doit aussi indiquer quelles ressources sont exposées à l'agent et lesquelles restent réservées à l'évaluation. Un tel manifeste facilite la comparaison entre campagnes et empêche qu'une modification silencieuse du corpus soit attribuée au modèle.

6.8.2. Séparer les données sources, historiques et corrigées

Les données sources, les bases historiques et les versions corrigées ne doivent pas s'écraser mutuellement. Chaque transformation doit produire une condition identifiable. Cette séparation permet de comparer les états et d'éviter qu'une correction rende impossible la reproduction du défaut initial.

Cette séparation peut être mise en œuvre par des répertoires immuables, des identifiants de condition et un manifeste décrivant la transformation. Les scripts doivent écrire vers une nouvelle destination et refuser l'écrasement des états historiques. Le bénéfice est double : l'effet d'une correction peut être isolé et le défaut initial reste disponible pour les tests de régression.

6.8.3. Déclarer explicitement les correspondances de colonnes

Lorsqu'un schéma et une source utilisent des noms différents, les associations doivent être versionnées, limitées et justifiées par les fichiers disponibles. Une traduction implicite, même plausible, peut introduire une erreur difficile à détecter. Les correspondances ambiguës doivent rester non établies jusqu'à l'obtention d'une preuve suffisante.

Chaque correspondance devrait préciser la clé source, la colonne cible, la justification, le fichier concerné et le niveau de confiance. Les associations ambiguës ne doivent pas être résolues par simple similarité lexicale. Une revue humaine ou une documentation de schéma est nécessaire lorsque plusieurs colonnes sont plausibles. La configuration devient ainsi un artefact scientifique contrôlable plutôt qu'une règle implicite enfouie dans le code.

6.8.4. Tester les valeurs avant et après importation

Les contrôles devraient comparer les valeurs non nulles présentes dans les sources avec celles réellement retrouvées dans la base cible. Un tel test permet d'identifier des pertes silencieuses qu'un contrôle d'intégrité SQLite ne détecte pas.

Les tests doivent comparer, au minimum, les nombres de valeurs non nulles, les domaines observés et quelques invariants simples entre la source et la cible. Pour les colonnes critiques, une filiation ligne à ligne peut être requise. Ces contrôles détectent des pertes silencieuses qu'un PRAGMA quick_check ne peut pas révéler, car l'intégrité du format SQLite ne dit rien de la fidélité sémantique de l'importation.

6.8.5. Préserver les relations lors de l'échantillonnage

Un échantillonnage indépendant de quelques lignes dans chaque table peut détruire les recouvrements de clés. Lorsqu'une tâche nécessite des jointures, l'échantillon devrait être construit en conservant des ensembles cohérents de lignes reliées. Dans le cas IPL, la sélection d'un match devrait entraîner celle de ses événements, de ses joueurs et des statistiques associées.

Cette recommandation décrit une piste de conception ; elle n'a pas été expérimentée dans le présent travail. Son effet sur la mesurabilité devra être évalué séparément.

Une stratégie préférable consiste à sélectionner une ou plusieurs entités centrales, puis à extraire les lignes dépendantes dans les tables reliées. La procédure doit documenter les clés suivies et vérifier que les jointures minimales nécessaires à la question produisent des lignes. Cette recommandation reste une proposition : elle devra être comparée expérimentalement à l'échantillonnage indépendant avant d'être présentée comme une solution validée.

6.8.6. Vérifier la requête de référence sur la base effectivement distribuée

Une requête de référence ne devrait pas être considérée comme suffisante parce qu'elle est syntaxiquement valide. Elle doit être exécutée sur la version exacte de la base remise à l'agent, et son résultat doit être examiné. Un résultat vide peut être légitime, mais son interprétation doit être documentée.

La vérification doit enregistrer le statut d'exécution, le schéma du résultat, le nombre de lignes, les valeurs principales et une justification de leur interprétation. Un résultat vide peut être accepté uniquement lorsque sa légitimité est établie par la question et les données. Cette étape devrait être exécutée après chaque reconstruction, et non seulement une fois lors de la création initiale du corpus.

6.8.7. Autoriser explicitement la mise hors score

Le protocole d'évaluation doit prévoir qu'une tâche puisse être exclue ou maintenue hors score lorsque les conditions de mesure ne sont pas réunies. Cette décision ne constitue pas un échec opérationnel ; elle protège l'étude contre la production de résultats trompeurs.

La politique d'évaluation doit définir avant la campagne les motifs d'exclusion, les informations conservées et la manière de publier le nombre de tâches écartées. Une mise hors score ne doit pas disparaître des résultats : elle doit être rapportée avec sa cause, afin d'éviter que la performance finale soit calculée sur un sous-ensemble sélectionné sans transparence. Cette règle transforme l'abstention méthodologique en élément auditable du protocole.

6.9. Perspectives de recherche

La première perspective concerne la validation indépendante de la grille. Un second évaluateur pourrait classer un ensemble de tâches sans accéder aux décisions historiques. L'accord et les désaccords permettraient de mesurer la stabilité des règles et d'en améliorer les définitions.

Une deuxième perspective consisterait à appliquer le protocole à un environnement officiellement complet et à plusieurs tâches dont la viabilité est connue. Cette étude apporterait des cas positifs permettant d'observer le passage complet jusqu'au statut Vert, puis à l'évaluation effective des agents.

Une troisième piste porte sur la construction d'échantillons relationnellement cohérents. Une procédure pourrait partir d'entités centrales et récupérer toutes les lignes nécessaires à

leurs relations, puis comparer la mesurabilité obtenue à celle d'un échantillonnage indépendant.

Une quatrième perspective concerne l'automatisation : détection des colonnes non alimentées, comparaison des clés source et cible, mesure du recouvrement des jointures, exécution de la requête de référence, génération du statut et archivage du rapport dans une chaîne d'intégration continue. Cette automatisation devra produire des preuves lisibles, ne pas masquer les décisions et permettre un contrôle humain des cas ambigus.

6.10. Implications pour les futurs environnements d'évaluation

La qualification préalable peut être intégrée à la chaîne de préparation des futurs référentiels adaptés ou réduits. Une fiche de tâche devrait relier la question, le schéma, les données, les transformations, les correspondances de colonnes et la référence exécutée sur la base distribuée.

Les sous-ensembles destinés à réduire les coûts devraient être construits de manière relationnellement cohérente. La sélection d'une entité centrale devrait entraîner la conservation des lignes associées dans les tables dépendantes, plutôt qu'un prélèvement indépendant de quelques lignes dans chaque table.

Enfin, les protocoles devraient prévoir un statut hors score. L'exclusion motivée d'une tâche ne diminue pas la valeur scientifique d'une campagne ; elle évite qu'une incertitude du corpus soit attribuée au modèle et rend les résultats restants plus défendables.

Les futurs référentiels agentiques gagneraient à distribuer non seulement des tâches, mais aussi une documentation de filiation et des contrôles de viabilité. Un manifeste pourrait préciser la version de la base, les tables nécessaires, les relations attendues, le comportement de la référence et les conditions dans lesquelles un résultat vide est légitime. Ces informations faciliteraient les adaptations locales sans exiger de faire confiance à une chaîne de transformation opaque.

La troisième implication concerne les tableaux de résultats. Ils pourraient distinguer les tâches exécutées, les tâches exclues pour défaut démontré, celles maintenues hors score pour preuve insuffisante et les abstentions des agents. Une telle transparence empêcherait qu'un taux global masque la qualité variable du support expérimental. Elle permettrait aussi de suivre séparément l'amélioration des agents et l'amélioration du corpus.

6.11. Contribution théorique : quatre propositions issues du cas étudié

Au-delà de la procédure technique, le mémoire formule quatre propositions conceptuelles. Elles sont issues du corpus local et doivent être comprises comme des résultats analytiques à éprouver dans d'autres environnements, non comme des lois universelles.

Proposition 1 - La validité technique est nécessaire, mais insuffisante pour autoriser une mesure. Un fichier peut satisfaire les contrôles du moteur, contenir le schéma attendu et exécuter une requête sans préserver les valeurs ou les relations dont dépend la question. L'intégrité informatique décrit la possibilité de faire fonctionner l'environnement ; la validité expérimentale décrit la possibilité d'attribuer le résultat à la capacité visée.

Proposition 2 - Les transformations du corpus font partie de l'instrument de mesure. Traduire des clés, convertir un format, sélectionner des lignes ou reconstruire une base ne sont pas de simples opérations logistiques. Elles peuvent modifier la difficulté, la calculabilité et le pouvoir discriminant de la tâche. Leur provenance, leurs paramètres et leurs effets doivent donc être documentés avec le même soin que la configuration des agents.

Proposition 3 - La preuve positive doit être asymétrique. Un défaut critique suffit à bloquer une tâche ; l'absence de défaut détecté ne suffit pas à la déclarer mesurable. Le statut Ambre formalise cette asymétrie en conservant hors score les situations où la base fonctionne mais où une condition nécessaire n'est pas démontrée. Cette catégorie évite les promotions optimistes fondées sur un silence des tests.

Proposition 4 - La décision de ne pas calculer de score peut constituer un résultat scientifique. Lorsqu'elle est liée à des critères annoncés, à des preuves et à une analyse des causes, la mise hors score ne représente pas un échec à produire des chiffres. Elle protège l'interprétation et fournit une information sur les conditions à réunir avant la campagne suivante.

Ces propositions repositionnent le corpus. Il n'est plus un arrière-plan passif, mais un instrument dont les propriétés conditionnent la mesure. Cette conception rejoint les travaux sur la documentation des données et la validité des mesures, tout en ajoutant une décision au niveau de la tâche relationnelle : autoriser, corriger ou suspendre l'évaluation.

La contribution reste modeste dans sa portée empirique. Elle ne démontre pas que les six dimensions retenues sont exhaustives, que trois statuts constituent le meilleur nombre de catégories ou que les mêmes seuils s'appliquent à toutes les bases. Son apport est de rendre le

raisonnement explicite et contrôlable : chaque conclusion doit pouvoir être rattachée à une condition, à une preuve et à une limite.

6.12. Conditions d'une validation externe du protocole

Le passage d'une méthode locale à un protocole validé plus largement nécessite un programme expérimental distinct. La première étape est une évaluation inter-évaluateurs. Deux personnes au moins devraient appliquer la grille en aveugle à un ensemble de tâches nouvelles. L'accord brut et un coefficient adapté pourraient être calculés, puis les désaccords utilisés pour clarifier les critères. Cette étude permettrait de déterminer si les statuts dépendent excessivement de l'interprétation de l'auteur initial.

La deuxième étape consiste à inclure des cas positifs connus. Le corpus actuel ne contient aucune tâche Verte. Il faut donc appliquer le protocole à des environnements dont la calculabilité et la référence sont établies, afin de vérifier qu'il n'est pas uniquement capable de détecter ou de conserver des limites. Une méthode utile doit savoir bloquer les cas insuffisants sans rendre impossible toute autorisation de mesure.

La troisième étape est la réplication sur un autre corpus et, idéalement, un autre moteur. Une sélection pourrait combiner des tâches SQLite complètes, des bases PostgreSQL ou des environnements infonuagiques. Les dimensions générales seraient conservées, mais les contrôles techniques et relationnels seraient adaptés. Cette comparaison montrerait quelles règles sont spécifiques au cas étudié et lesquelles se transfèrent.

La quatrième étape concerne l'échantillonnage. Une expérience contrôlée devrait comparer l'échantillonnage indépendant de quelques lignes par table à un échantillonnage relationnel construit autour d'entités centrales. Les mêmes questions et requêtes de référence seraient exécutées dans les deux conditions. L'effet sur les recouvrements de clés, les résultats de référence et les statuts permettrait d'évaluer directement la recommandation formulée dans ce mémoire.

La cinquième étape est une campagne d'agents réalisée seulement après qualification. Elle permettrait d'étudier la chaîne complète : tâche Verte, exécution sous protocole figé, comparaison des réponses et analyse des abstentions. Les statuts de qualification devraient rester indépendants des résultats des agents afin d'éviter que la méthode soit ajustée après observation des performances.

Ces travaux dépassent le périmètre du présent mémoire. Leur description précise évite toutefois une perspective vague. Elle transforme les limites identifiées en plan de validation testable et fournit les conditions sous lesquelles la contribution pourrait évoluer d'un protocole local documenté vers une méthode comparée et reproduite indépendamment.

7. Conclusion générale

7.1. Retour sur la problématique

Le travail était initialement destiné à comparer plusieurs agents d'intelligence artificielle sur des tâches d'analyse SQL formulées en français. La préparation de l'environnement a cependant révélé une difficulté plus fondamentale : les bases reconstruites pouvaient être techniquement valides sans permettre une mesure interprétable de l'exactitude.

La problématique a donc été reformulée autour d'une question préalable : comment déterminer qu'un environnement local reconstruit est suffisamment qualifié pour servir de support à l'évaluation d'agents produisant des requêtes SQL ?

Pour répondre à cette question, le mémoire a proposé un protocole fondé sur la provenance des données, la validité technique, la conservation des valeurs, la cohérence des correspondances de colonnes, la couverture relationnelle, l'interprétabilité de la requête de référence et la rejouabilité des transformations.

La réponse apportée est volontairement opérationnelle. Elle prend la forme de sept règles, de trois statuts, d'interventions versionnées et d'un registre de preuves. Cette architecture ne prétend pas épuiser la notion de qualité d'un référentiel, mais elle rend explicite le seuil minimal adopté dans ce projet pour autoriser une mesure d'exactitude.

7.2. Principaux résultats

L'audit initial des vingt tâches pilotes a produit treize statuts Ambre, sept statuts Rouge et aucun statut Vert. L'étude détaillée de local023 a ensuite mis en évidence un défaut précis de reconstruction : les fichiers JSON contenaient des valeurs sous des clés françaises, tandis que le processus d'importation recherchait les noms anglais du schéma. Cette différence conduisait à l'insertion de valeurs NULL dans sept colonnes critiques.

Une correspondance explicite a supprimé ces sept divergences et fait passer la tâche du statut Rouge au statut Ambre. L'intervention a été rejouée sur plusieurs reconstructions, qui ont produit des empreintes logiques identiques au sein de chaque condition.

L'audit étendu aux vingt tâches a identifié six autres tâches présentant le même type de divergence démontrée. Leur correction a supprimé 351 divergences supplémentaires. Le bilan cumulé s'établit ainsi à 358 divergences corrigées dans le périmètre étudié [E53-E68].

Les quarante et un tests automatisés réussis soutiennent les propriétés techniques des différentes études, tandis qu'un test historique continue volontairement de détecter les sept divergences de la reconstruction non corrigée. Cette séparation confirme que l'état d'origine n'a pas été effacé par la remédiation. Les tests ne prouvent pas la validité externe de la grille, mais ils rendent le protocole local cohérent et contrôlable.

7.3. Contribution principale

La contribution principale ne réside pas uniquement dans la correction de 358 divergences ni dans l'étude particulière de local023. Ces résultats servent à éprouver une proposition plus générale : un corpus destiné à évaluer des agents doit être qualifié avant que les performances observées puissent être interprétées.

Le protocole distingue plusieurs niveaux souvent confondus : présence du fichier, validité technique de la base, conservation des valeurs, préservation des relations nécessaires, interprétabilité du résultat de référence et éligibilité à la mesure. Une base peut être valide mais mal alimentée ; correctement alimentée mais dépourvue de relations utiles ; relationnellement cohérente mais associée à une référence ambiguë.

La méthode consiste donc à vérifier chaque niveau séparément et à conserver la possibilité de suspendre l'évaluation. Cette possibilité d'arrêt n'est pas accessoire : elle évite qu'un score précis en apparence masque une mesure dont le construit n'est pas établi.

La valeur de la méthode tient aussi à sa capacité à produire plusieurs types de sortie : autorisation de mesurer, défaut corrigible, incertitude à documenter ou exclusion motivée. Elle ne réduit donc pas l'audit à la recherche d'erreurs. Si toutes les preuves avaient été positives, le même protocole aurait fourni les éléments justifiant une campagne comparative.

7.4. Une conclusion négative, mais scientifiquement utile

Le protocole initial devait produire un classement d'agents. Le mémoire conclut qu'un tel classement ne peut pas être défendu dans l'environnement étudié. Cette conclusion peut sembler négative ; elle constitue pourtant le résultat le plus important de la recherche.

Produire malgré tout des scores aurait donné une apparence de précision à une mesure dont les conditions n'étaient pas satisfaites. Le protocole de qualification a permis d'identifier cette situation avant qu'elle ne conduise à une comparaison potentiellement trompeuse.

L'absence de calcul de score n'est donc pas une absence de résultat. Elle représente une décision méthodologique fondée sur des preuves : corriger ce qui pouvait être démontré,

documenter ce qui restait incertain et refuser d'attribuer aux agents des effets provenant du support expérimental.

Ce résultat évite également un biais rétrospectif. Après avoir observé des sorties d'agents, il aurait été tentant d'adapter les critères afin de conserver une comparaison. La décision de ne pas calculer de score maintient au contraire la priorité donnée aux conditions du support. Elle constitue ainsi une protection de la crédibilité du travail, même si elle renonce au résultat spectaculaire initialement recherché.

7.5. Portée et limites de la conclusion

Le mémoire ne démontre pas que les référentiels académiques officiels sont incohérents. Il ne compare pas les performances intrinsèques de Vibe, Codex, Gemini ou d'un autre agent. Il établit seulement que l'environnement local reconstruit étudié ne permet pas une telle comparaison.

La méthode a été formalisée et rejouée dans ce périmètre. Elle n'a pas encore été validée par un second évaluateur, appliquée à un corpus indépendant ou testée sur une chaîne complète comportant plusieurs tâches au statut Vert. Les licences et droits de redistribution restent en outre à vérifier avant toute publication des données.

Ces limites n'annulent pas l'intérêt du travail. Elles définissent les étapes nécessaires pour passer d'un protocole local documenté à une méthode évaluée plus largement : validation inter-évaluateurs, réplication multi-machine, application externe et expérimentation sur des tâches positives.

La seconde limite concerne l'indépendance de l'évaluation. La grille a été construite à partir des anomalies étudiées puis rejouée sur le même pilote. L'absence de divergence démontre la cohérence avec les décisions historiques, non un accord entre évaluateurs. Une application en aveugle par un tiers et le calcul d'un accord inter-évaluateurs constitueraient une étape décisive pour renforcer la validité de la méthode.

7.6. Conclusion finale

L'évaluation d'un agent ne commence pas lorsque celui-ci reçoit une question. Elle commence au moment où le corpus est sélectionné, transformé, échantillonné et reconstruit. Chaque opération effectuée en amont peut modifier les informations remises à l'agent et, par conséquent, la signification du score obtenu.

Le travail présenté montre qu'une base de données valide n'est pas nécessairement une tâche mesurable. Il montre également qu'une correction de reconstruction, même complète pour le défaut ciblé, ne suffit pas toujours à rétablir les relations nécessaires à l'évaluation.

La recommandation finale est donc simple : avant de comparer les agents, il faut démontrer que les données permettent réellement de les comparer.

Le résultat final n'est donc ni un palmarès ni une dénonciation des référentiels existants. C'est une méthode de prudence active : vérifier avant de mesurer, corriger sans effacer, distinguer l'incertitude du défaut et préférer l'absence de score à une précision trompeuse.

Références bibliographiques

- Barker, M., Chue Hong, N. P., Katz, D. S., Lamprecht, A.-L., Martinez-Ortiz, C., Psomopoulos, F., Harrow, J., Castro, L. J., Gruenpeter, M., Martinez, P. A., & Honeyman, T. (2022). Introducing the FAIR principles for research software. *Scientific Data*, 9, Article 622. <https://doi.org/10.1038/s41597-022-01710-x>
- Bender, E. M., & Friedman, B. (2018). Data statements for natural language processing: Toward mitigating system bias and enabling better science. *Transactions of the Association for Computational Linguistics*, 6, 587–604. https://doi.org/10.1162/tacl_a_00041
- Buneman, P., Khanna, S., & Tan, W.-C. (2001). Why and where: A characterization of data provenance. In J. Van den Bussche & V. Vianu (Eds.), *Database theory—ICDT 2001* (Lecture Notes in Computer Science, Vol. 1973, pp. 316–330). Springer. https://doi.org/10.1007/3-540-44503-X_20
- Chang, S., Wang, J., Dong, M., Pan, L., Zhu, H., Li, A. H., Lan, W., Zhang, S., Jiang, J., Lilien, J., Ash, S., Wang, W. Y., Wang, Z., Castelli, V., Ng, P., & Xiang, B. (2023). Dr.Spider: A diagnostic evaluation benchmark towards Text-to-SQL robustness. *International Conference on Learning Representations*. <https://arxiv.org/abs/2301.08881>
- Cheney, J., Chiticariu, L., & Tan, W.-C. (2009). Provenance in databases: Why, how, and where. *Foundations and Trends in Databases*, 1(4), 379–474. <https://doi.org/10.1561/19000000006>
- Dou, L., Gao, Y., Pan, M., Wang, D., Che, W., Zhan, D., & Lou, J.-G. (2023). MultiSpider: Towards benchmarking multilingual Text-to-SQL semantic parsing. *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(11), 12745–12753. <https://doi.org/10.1609/aaai.v37i11.26499>

- Finegan-Dollak, C., Kummerfeld, J. K., Zhang, L., Ramanathan, K., Sadasivam, S., Zhang, R., & Radev, D. (2018). Improving Text-to-SQL evaluation methodology. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 351–360). Association for Computational Linguistics. <https://doi.org/10.18653/v1/P18-1033>
- Gebri, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., & Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM*, 64(12), 86–92. <https://doi.org/10.1145/3458723>
- Jacobs, A. Z., & Wallach, H. (2021). Measurement and fairness. In *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency* (pp. 375–385). Association for Computing Machinery. <https://doi.org/10.1145/3442188.3445901>
- Jin, T., Choi, Y., Zhu, Y., & Kang, D. (2026). Text-to-SQL benchmarks are broken: An in-depth analysis of annotation errors. In *Proceedings of the 16th Conference on Innovative Data Systems Research (CIDR 2026)*. <https://www.vldb.org/cidrdb/papers/2026/p5-jin.pdf>
- Kim, H., Taeyang, J., Choi, S., Choi, S., & Cho, H. (2025). FLEX: Expert-level false-less execution metric for Text-to-SQL benchmark. In *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)* (pp. 4448–4475). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2025.naacl-long.228>

- Lei, F., Chen, J., Ye, Y., Cao, R., Shin, D., Su, H., Suo, Z., Gao, H., Hu, W., Yin, P., Zhong, V., Xiong, C., Sun, R., Liu, Q., Wang, S., & Yu, T. (2025). Spider 2.0: Evaluating language models on real-world enterprise Text-to-SQL workflows. *International Conference on Learning Representations*.
https://proceedings.iclr.cc/paper_files/paper/2025/hash/46c10f6c8ea5aa6f267bcdabcb123f97-Abstract-Conference.html
- Li, J., Hui, B., Qu, G., Yang, J., Li, B., Li, B., Wang, B., Qin, B., Geng, R., Huo, N., Zhou, X., Ma, C., Li, G., Chang, K., Huang, F., Cheng, R., & Li, Y. (2023). Can LLM already serve as a database interface? A BIG bench for large-scale database grounded Text-to-SQLs. *Advances in Neural Information Processing Systems*, 36.
https://proceedings.neurips.cc/paper_files/paper/2023/hash/83fc8fab1710363050bbd1d4b8cc0021-Abstract-Datasets_and_Benchmarks.html
- Longjohn, R., Kelly, M., Singh, S., & Smyth, P. (2024). Benchmark data repositories for better benchmarking. *Advances in Neural Information Processing Systems*, 37.
https://proceedings.neurips.cc/paper_files/paper/2024/hash/9d41fddf3169f4df3025fc60bfac94fa-Abstract-Datasets_and_Benchmarks_Track.html
- Mistral AI. (n.d.). *Install and setup: Vibe CLI*. Retrieved July 15, 2026, from
<https://docs.mistral.ai/vibe/code/cli/install-setup>
- OpenAI. (n.d.). *Codex CLI*. Retrieved July 15, 2026, from
<https://developers.openai.com/codex/cli>
- Paullada, A., Raji, I. D., Bender, E. M., Denton, E., & Hanna, A. (2021). Data and its (dis)contents: A survey of dataset development and use in machine learning research. *Patterns*, 2(11), Article 100336. <https://doi.org/10.1016/j.patter.2021.100336>

- Pineau, J., Vincent-Lamarre, P., Sinha, K., Larivière, V., Beygelzimer, A., d'Alché-Buc, F., Fox, E., & Larochelle, H. (2021). Improving reproducibility in machine learning research: A report from the NeurIPS 2019 reproducibility program. *Journal of Machine Learning Research*, 22(164), 1–20. <https://www.jmlr.org/papers/v22/20-303.html>
- Sambasivan, N., Kapania, S., Highfill, H., Akrong, D., Paritosh, P., & Aroyo, L. M. (2021). “Everyone wants to do the model work, not the data work”: Data cascades in high-stakes AI. In *Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems* (Article 39). Association for Computing Machinery. <https://doi.org/10.1145/3411764.3445518>
- Wilkinson, M. D., Dumontier, M., Aalbersberg, I. J., Appleton, G., Axton, M., Baak, A., Blomberg, N., Boiten, J.-W., Bonino da Silva Santos, L., Bourne, P. E., Bouwman, J., Brookes, A. J., Clark, T., Crosas, M., Dillo, I., Dumon, O., Edmunds, S., Evelo, C. T., Finkers, R., ... Mons, B. (2016). The FAIR guiding principles for scientific data management and stewardship. *Scientific Data*, 3, Article 160018. <https://doi.org/10.1038/sdata.2016.18>
- Yu, T., Zhang, R., Er, H., Li, S., Xue, E., Pang, B., Lin, X. V., Tan, Y. C., Shi, T., Li, Z., Jiang, Y., Yasunaga, M., Shim, S., Chen, T., Fabbri, A., Li, Z., Chen, L., Zhang, Y., Dixit, S., ... Radev, D. (2019). CoSQL: A conversational Text-to-SQL challenge towards cross-domain natural language interfaces to databases. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)* (pp. 1962–1979). Association for Computational Linguistics. <https://doi.org/10.18653/v1/D19-1204>

- Yu, T., Zhang, R., Yang, K., Yasunaga, M., Wang, D., Li, Z., Ma, J., Li, I., Yao, Q., Roman, S., Zhang, Z., & Radev, D. (2018). Spider: A large-scale human-labeled dataset for complex and cross-domain semantic parsing and Text-to-SQL task. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing* (pp. 3911–3921). Association for Computational Linguistics.
<https://doi.org/10.18653/v1/D18-1425>
- Yu, T., Zhang, R., Yasunaga, M., Tan, Y. C., Lin, X. V., Li, S., Er, H., Li, I., Pang, B., Chen, T., Ji, E., Dixit, S., Proctor, D., Shim, S., Kraft, J., Zhang, V., Xiong, C., Socher, R., & Radev, D. (2019). SParC: Cross-domain semantic parsing in context. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics* (pp. 4511–4523). Association for Computational Linguistics.
<https://doi.org/10.18653/v1/P19-1443>
- Zhong, R., Yu, T., & Klein, D. (2020). Semantic evaluation for Text-to-SQL with distilled test suites. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)* (pp. 396–411). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2020.emnlp-main.29>

Annexes techniques

Rôle des annexes

Les annexes réunissent les éléments nécessaires à la vérification sans transformer le corps du mémoire en journal de développement.

Les scripts complets, bases SQLite et journaux bruts restent dans le dépôt de travail. Leur diffusion publique dépend de la vérification des licences et droits applicables.

Annexe A - Registre de preuves (79 entrées)

Cette annexe conserve pour chacune des 79 entrées le fait, le diagnostic, la règle méthodologique ou la limite retenue, ainsi que le fichier local qui permet de la contrôler. Le registre source contient les formulations de preuve détaillées ; la présente version en synthétise les éléments de lecture afin de préserver la lisibilité du document.

ID	Affirmation / constat	Artefact local source	Qualification	Portée ou formulation sûre
E01	Le projet travaille sur des tâches Text-to-SQL françaises associées à des bases SQLite locales.	`reports/dataset_inventory.md`	fait observé	Le corpus local recense 547 questions françaises, dont 123 sont associées à des bases SQLite disponibles dans la copie locale local.
E02	Le pilote initial documenté comprend 20 tâches.	`reports/dataset_inventory.md`	fait observé	L'étude pilote s'appuie sur une sélection locale de 20 tâches françaises SQLite.
E03	Les tâches pilotes ont été sélectionnées de manière déterministe dans le rapport d'inventaire.	`reports/dataset_inventory.md`	fait observé	La sélection pilote documentée repose sur une procédure déterministe décrite localement.
E04	La configuration primaire gold locale contient 23 tâches validées techniquement, mais non utilisables pour un score scientifique.	`configs/primary_gold_fr_sqlite_v1.json`	fait observé	Un sous-ensemble primaire de 23 tâches a été validé techniquement sur données échantillons, sans prétention de score scientifique.
E05	Les données locales sont des échantillons JSON limités à 5 lignes par table.	`configs/primary_gold_fr_sqlite_v1.json` ; `reports/gold_preflight.md`	fait observé	Les bases locales sont reconstruites à partir d'échantillons JSON limités, généralement cinq lignes par table.
E06	Les bases locales ne sont pas l'environnement officiel Spider2.	`reports/benchmark_scope.md` ; `reports/dataset_and_reconstruction_limitations.md`	limite	Les résultats décrivent un environnement local reconstruit et non l'environnement officiel Spider2.
E07	Les sources déclarées pour la reconstruction sont les DDL et échantillons SQLite Spider2, plus les questions françaises locales.	`reports/dataset_and_reconstruction_limitations.md`	fait observé	Les expériences utilisent des questions françaises et des bases reconstruites depuis les ressources locales disponibles.
E08	Pour local023, la source Spider2 IPL a été retenue plutôt que les ressources francisées, à cause d'incompatibilités de noms de colonnes.	`reports/dataset_and_reconstruction_limitations.md`	diagnostic étayé	Pour local023, la reconstruction s'appuie sur le dossier Spider2 IPL, les noms de colonnes des ressources francisées étant incompatibles avec le DDL utilisé.
E09	La base locale local023/IPL contient 8 tables et 40 lignes.	`reports/final_technical_status.md` ; `reports/dataset_and_reconstruction_limitations.md` ; `results/20260629_025110/prepare_tasks_output.txt`	fait observé	La base locale IPL préparée pour local023 contient huit tables et quarante lignes au total.
E10	La base local023 préparée a un header SQLite valide et `PRAGMA quick_check = ok`.	`reports/final_technical_status.md`	fait observé	La validité technique du fichier SQLite local023 a été vérifiée par header SQLite et `PRAGMA quick_check`.
E11	`schema.sql` est généré dans l'espace de travail local023.	`reports/final_technical_status.md` ; `results/20260629_025110/prepare_tasks_output.txt`	fait observé	Le protocole fournit à l'agent un `schema.sql` généré depuis la base SQLite du espace de travail.
E12	La validation non-agent de local023 ne lance pas Vibe, Codex ni autre agent.	`reports/final_technical_status.md`	fait observé	Une validation locale non-agent permet de contrôler la base et le schéma avant exécution d'agent.
E13	L'audit de viabilité a évalué 20 tâches pilotes.	`reports/task_viability_audit.md` ; `reports/task_viability_audit.csv`	fait observé	L'audit de viabilité documente les 20 tâches pilotes.

ID	Affirmation / constat	Artefact local source	Qualification	Portée ou formulation sûre
E14	Aucune tâche pilote n'est Vert dans l'audit de viabilité.	`reports/task_viability_audit.md`; `reports/task_viability_audit.csv`	fait observé	L'audit de viabilité ne classe aucune des 20 tâches pilotes comme pleinement verte pour une évaluation d'exactitude fiable.
E15	L'audit classe 13 tâches Ambre et 7 tâches Rouge.	`reports/task_viability_audit.md`	fait observé	Les tâches pilotes se répartissent entre cas techniquement exploitables mais non vérifiables et cas problématiques.
E16	local023 est classée Rouge dans l'audit de viabilité.	`reports/task_viability_audit.csv`	fait observé	La tâche local023 est classée Rouge dans l'audit, malgré une base SQLite techniquement préparée.
E17	Pour local023, le requête SQL de référence s'exécute mais produit 0 ligne sur les échantillons locaux.	`reports/task_viability_audit.csv`	fait observé	Sur la reconstruction locale, la référence SQL de local023 s'exécute mais ne produit aucune ligne exploitable.
E18	L'audit local023 constate des colonnes nécessaires nulles ou non alignées.	`reports/task_viability_audit.md`	diagnostic étayé	Les colonnes nécessaires à local023 sont présentes dans le schéma mais insuffisamment renseignées dans la reconstruction locale.
E19	Une base techniquement valide peut être sémantiquement non exploitable.	`reports/final_technical_status.md`; `reports/task_viability_audit.md`	diagnostic étayé	Le cas local023 illustre qu'une base SQLite valide au sens technique peut rester impropre à une évaluation sémantique fiable.
E20	Le protocole déclare que l'agent ne doit recevoir que son espace de travail.	`reports/experiment_protocol_v1.md`	fait observé	Le protocole organise une séparation pratique entre artefacts exposés à l'agent, références et rapports conservés hors espace de travail.
E21	Le protocole impose que l'agent crée uniquement `answer.json`.	`reports/experiment_protocol_v1.md`; `scripts/run_selected_vibe.ps1`	fait observé	La sortie attendue de l'agent est un fichier unique `answer.json` selon un schéma défini.
E22	Le protocole autorise seulement des requêtes SQL de lecture.	`reports/experiment_protocol_v1.md`; `results/selected_20260629_022234.json`	fait observé	Les interactions SQL de l'agent sont limitées à des opérations de lecture.
E23	Le programme d'exécution de Vibe ne lance une exécution réelle qu'avec l'option `-Execute`.	`scripts/run_selected_vibe.ps1`	fait observé	Le programme d'exécution de Vibe distingue explicitement la simulation de l'exécution réelle grâce à l'option de contrôle `-Execute`.
E24	Vibe a été réellement lancé sur local023 lors de l'exécution 20260629_022234.	`reports/ selected_summary_20260629_022234.md`	fait observé	Une exécution réelle Vibe a été menée sur local023 le 2026-06-29.
E25	L'exécution Vibe local023 utilisait MaxTokens 65000 et MaxTurns 12.	`reports/ selected_summary_20260629_022234.md`; `reports/vibe_local023_run_summary.md`	fait observé	L'exécution Vibe documenté a été lancé avec un plafond de 65 000 tokens et 12 tours.
E26	Vibe n'a pas produit `answer.json` lors de l'exécution réel local023.	`results/selected_20260629_022234.json`; `reports/vibe_local023_run_summary.md`	fait observé	L'exécution Vibe est classée comme une non-finalisation, car aucun fichier `answer.json` n'a été produit.
E27	Vibe s'est arrêté sur dépassement de plafond de tokens.	`agent_workspace/20260629_022234/ local023/vibe_stderr.txt`	fait observé	La terminaison observée du exécution Vibe est un dépassement du plafond de tokens avant production de la sortie attendue.

Annexe A.1 - Registre de preuves, entrées E01 à E27.

ID	Affirmation / constat	Artefact local source	Qualification	Portée ou formulation sûre
E28	Le résultat Vibe ne permet pas de calculer un score d'exactitude.	`reports/vibe_local023_run_summary.md`	diagnostic étayé	L'exécution Vibe ne fournit pas de réponse exploitable pour une évaluation d'exactitude.

ID	Affirmation / constat	Artefact local source	Qualification	Portée ou formulation sûre
E29	Codex CLI 0.142.3 a été réellement lancé sur local023.	`results/20260629_025110/codex_result.json`; `results/20260629_025110/codex_run_metadata.json`	fait observé	Une exécution de Codex CLI 0.142.3 a été effectuée sur local023 dans l'espace de travail dédié.
E30	L'exécution Codex local023 a duré 94,423 secondes et s'est terminé avec code 0.	`results/20260629_025110/codex_result.json`	fait observé	L'exécution Codex documentée s'est terminée sans erreur de processus après environ 94 secondes.
E31	Codex a créé `answer.json`.	`results/20260629_025110/codex_result.json`; `agent_workspace/20260629_025110/local023/answer.json`	fait observé	L'exécution Codex a produit le fichier de sortie attendu.
E32	Le `answer.json` Codex a le statut `abstain`.	`agent_workspace/20260629_025110/local023/answer.json`	fait observé	Codex a produit une réponse d'abstention plutôt qu'une réponse numérique.
E33	Codex signale que les données ne permettent pas de calculer le résultat.	`agent_workspace/20260629_025110/local023/answer.json`	fait observé	L'abstention Codex est motivée par l'absence de valeurs exploitables dans les colonnes nécessaires.
E34	Les traces Codex montrent que `season_id`, `match_id`, `player_id`, `player_name` et `runs_scored` étaient NULL dans les lignes inspectées.	`results/20260629_025110/codex_stdout.jsonl`	fait observé	Les vérifications effectuées pendant l'exécution Codex confirment que les colonnes requises ne portent pas les valeurs nécessaires.
E35	Codex n'a pas modifié les fichiers d'entrée et n'a pas laissé de fichier inattendu selon le programme d'exécution.	`results/20260629_025110/codex_result.json`	fait observé	Le programme d'exécution n'a détecté ni modification d'entrée ni fichier inattendu après l'exécution Codex.
E36	L'exécution Codex est une observation de protocole, pas une mesure de qualité intrinsèque du modèle.	`agent_workspace/20260629_025110/local023/answer.json`; `reports/task_viability_audit.md`	diagnostic étayé	Le comportement Codex observé doit être interprété comme une interaction entre protocole, données et agent, sans conclusion sur la qualité générale de Codex.
E37	L'exécution Vibe est une observation de non-finalisation sous budget, pas une mesure de qualité intrinsèque.	`reports/vibe_local023_run_summary.md`	diagnostic étayé	Le comportement Vibe observé documente une non-finalisation sous configuration donnée, sans conclusion comparative sur Vibe ou son modèle.
E38	Les résultats disponibles ne permettent aucune comparaison fiable entre Vibe et Codex.	`reports/vibe_local023_run_summary.md`; `agent_workspace/20260629_025110/local023/answer.json`; `reports/task_viability_audit.md`	diagnostic étayé	Les deux runs ne constituent pas une comparaison de performance, car la tâche elle-même n'est pas viable pour mesurer l'exactitude.
E39	Les requêtes SQL de référence peuvent vérifier une cohérence technique locale mais pas une performance finale officielle.	`reports/dataset_and_reconstruction_limitations.md`	limite	Les références SQL sont utiles pour auditer l'environnement local, non pour produire un score officiel.
E40	Les résultats vides stables ne suffisent pas à établir une viabilité sémantique.	`configs/primary_gold_fr_sqlite_v1.json`; `reports/task_viability_audit.md`	diagnostic étayé	La stabilité d'une exécution SQL sur échantillons peut masquer une absence de contenu évaluatif.
E41	La reconstruction peut échouer sémantiquement en raison de correspondances de colonnes ou de clés sources probablement non alignées.	`reports/task_viability_audit.md`	diagnostic étayé	Les problèmes d'import ou de correspondance entre DDL et échantillons JSON constituent un diagnostic probable pour local023, sans être une cause racine démontrée.
E42	Les contrôles d'isolation sont pratiques mais non une preuve de sécurité OS formelle.	`reports/dataset_and_reconstruction_limitations.md`; `reports/gold_preflight.md`	limite	Les contraintes déclarées, la séparation pratique des artefacts et les contrôles du programme d'exécution ne constituent pas une garantie d'isolation OS formelle.

ID	Affirmation / constat	Artefact local source	Qualification	Portée ou formulation sûre
E43	Certains DDL contiennent des mots réservés SQLite causant des exclusions.	`reports/gold_preflight.md`; `reports/benchmark_scope.md`	fait observé	Des incompatibilités de DDL avec SQLite ont déjà entraîné l'exclusion d'au moins une tâche locale.
E44	Hypothèse : un protocole robuste doit intégrer un audit de viabilité avant toute exécution d'agent.	`reports/task_viability_audit.md`; `reports/gold_preflight.md`	hypothèse	Les preuves suggèrent qu'un audit de viabilité sémantique devrait précéder toute campagne d'agents.
E45	Hypothèse: l'abstention contrôlée est une sortie méthodologiquement utile dans les tâches non viables.	`agent_workspace/20260629_025110/local023/answer.json`	hypothèse	L'abstention peut être traitée comme un comportement protocolaire pertinent lorsque les données ne permettent pas le calcul.
E46	Hypothèse: les métriques d'exactitude doivent être conditionnées à un statut de tâche Vert.	`reports/task_viability_audit.md`	hypothèse	Une évaluation d'exactitude ne devrait être déclenchée que sur des tâches dont la viabilité sémantique est démontrée.
E47	Hypothèse: la priorité du protocole futur est la traçabilité des données plutôt que l'augmentation du nombre de tâches.	`reports/task_viability_audit.csv`	hypothèse	L'amélioration du protocole devrait d'abord porter sur la traçabilité et la qualité des reconstructions.
E48	Les références externes MultiSpider, Spider2, Spider2-Lite et les versions exactes doivent être vérifiées avant soumission.	`external/...`; rapports locaux	limite	La bibliographie et les métadonnées externes doivent être vérifiées avant publication.
E49	Les anciens rapports peuvent contenir des états intermédiaires dépassés.	`reports/final_technical_status.md`	limite	Les divergences entre rapports doivent être datées et résolues par priorité aux artefacts bruts les plus récents.
E50	Le rapport technique ancien indique que Codex n'avait pas encore été exécuté, mais les artefacts ultérieurs documentent une exécution réelle de Codex.	`reports/final_technical_status.md`; `results/20260629_025110/codex_result.json`	limite	Les analyses doivent dater les sources et privilégier les artefacts d'exécution ultérieurs pour Codex.
E51	La question local023 demande les cinq meilleurs joueurs par moyenne de runs par match en saison 5.	`agent_workspace/20260629_025110/local023/question.txt`; `results/20260629_025110/prepare_tasks_output.txt`	fait observé	Le cas local023 porte sur une agrégation de runs par joueur en saison 5.
E52	Le manuscrit ne doit pas conclure sur Gemini, qui n'a pas de résultat local documenté dans les preuves lues.	Recherche locale ciblée des rapports/résultats/scripts	limite	Gemini doit être mentionné seulement comme outil non évalué dans les preuves disponibles, sans conclusion expérimentale.
E53	La cause racine de local023 est une divergence entre clés JSON françaises et colonnes anglaises du DDL, combinée à une insertion par `row.get(col)`.	`reports/local023_root_cause_audit.md`; `reports/local023_column_lineage.csv`	cause démontrée	Portée limitée à la reconstruction locale étudiée.
E54	Les sept colonnes critiques de local023 ont cinq valeurs sources non nulles sous clés françaises, mais deviennent nulles dans la base reconstruite historique.	`reports/local023_column_lineage.csv`	fait observé	La perte porte sur les colonnes suivies dans l'audit.

Annexe A.2 - Registre de preuves, entrées E28 à E54.

ID	Affirmation / constat	Artefact local source	Qualification	Portée ou formulation sûre
E55	L'intervention local023 conserve une condition historique Rouge avec 7 divergences et une condition corrigée Ambre avec 0 divergence.	`reports/ local023_correspondance_intervention.md; reports/local023_correspondance_intervention.csv`	fait observé	La correction restaure les valeurs critiques sans établir une tâche Verte.
E56	Après correction local023, les colonnes critiques sont restaurées mais les jointures nécessaires et la requête SQL de référence restent à 0 ligne.	`reports/ local023_correspondance_intervention.md; reports/local023_correspondance_intervention.csv`	fait observé	Le statut reste Ambre.
E57	Deux reconstructions historiques local023 ont une empreinte logique identique.	`reports/local023_reproducibility_study.md; reports/local023_reproducibility_manifest.json`	fait observé	afc1f3e7ec5c25b65790e74e53f98fb11debfb e7c1655f94c73614dc771ec7de
E58	Deux reconstructions corrigées local023 ont une empreinte logique identique.	`reports/local023_reproducibility_study.md; reports/local023_reproducibility_manifest.json`	fait observé	226d321fad13b5ed2e5ea908ce2d77c3332d9 975e91aaf6f11ed420c6ca1f32a
E59	Les empreintes logiques historique et corrigée de local023 diffèrent.	`reports/local023_reproducibility_study.md; reports/local023_reproducibility_manifest.json`	fait observé	La correction modifie la représentation logique.
E60	La rejouabilité local023 est démontrée seulement dans le périmètre local documenté.	`reports/local023_reproducibility_study.md`	limite	Aucune extrapolation à une autre machine ou version Python.
E61	La grille de viabilité v1 définit Vert, Ambre et Rouge par sept règles minimales.	`configs/grille_viabilite_v1.json; docs/grille_viabilite_v1.md`	règle méthodologique	Décision locale, non validation externe.
E62	Le rejoueur confirme 20 statuts historiques sur 20 et observe 0 divergence.	`reports/rejeu_grille_viabilite_pilote.md; reports/rejeu_grille_viabilite_pilote.csv`	fait observé	Cohérence déterministe locale.
E63	L'audit de sensibilité classe 9 tâches sans divergence détectée, 7 avec divergence démontrée et 4 avec divergence possible non établie.	`reports/ pilot_correspondance_sensitivity_audit.md; reports/pilot_correspondance_sensitivity_audit.csv`	fait observé	Aucune tâche n'est déclarée insuffisante pour auditer.
E64	Après correction documentée de local023, 14 tâches sont classées Ambre, 6 conservent le statut Rouge et aucune n'atteint le statut Vert.	`reports/ pilot_correspondance_sensitivity_audit.csv`	fait observé	État avant correction des six autres tâches.
E65	Les six tâches corrigées sont local019, local075, local157, local163, local229 et local259.	`reports/ pilot_correspondance_remediation_study.md; reports/pilot_correspondance_remediation_study.csv`	fait observé	local019, local075, local157, local163, local229, local259
E66	La correction applique six correspondances explicites et réduit 351 divergences à 0.	`reports/ pilot_correspondance_remediation_study.md; reports/pilot_correspondance_remediation_study.csv; configs/pilot_explicit_correspondances_remediation_v1.json`	fait observé	Aucune correspondance heuristique déclarée.
E67	Les six tâches corrigées passent du statut Rouge au statut Ambre et aucune n'atteint le statut Vert.	`reports/ pilot_correspondance_remediation_study.md; reports/pilot_correspondance_remediation_study.csv`	fait observé	Les jointures nécessaires restent non établies ou insuffisantes.
E68	Après correction explicite, les 20 tâches sont classées Ambre ; aucune n'est Rouge ni Verte.	`reports/ pilot_correspondance_sensitivity_audit.csv; reports/pilot_correspondance_remediation_study.csv`	diagnostic étayé	Consolidation arithmétique du périmètre remédié.
E69	L'audit de couverture relationnelle classe 16 tâches en relation non établie et 4 en relation absente dans l'échantillon source.	`reports/pilot_relational_coverage_audit.md; reports/pilot_relational_coverage_manifest.json`	fait observé	{"RELATION_NON_ETABLIE": 16, "RELATION_ABSENTE_DANS_L_ECHANTILLON_SOURCE": 4}

ID	Affirmation / constat	Artefact local source	Qualification	Portée ou formulation sûre
E70	Douze relations nécessaires sont absentes dans les sources et aucune relation n'est perdue à l'import après correspondances explicites.	`reports/pilot_relational_coverage_audit.md; reports/pilot_relational_coverage_manifest.json`	fait observé	12 absentes; 0 perdue à l'import.
E71	Aucune tâche de couverture relationnelle ne produit de résultat de référence interprétable et aucune tâche n'est Verte.	`reports/pilot_relational_coverage_audit.md; reports/pilot_relational_coverage_manifest.json`	fait observé	Aucun résultat interprétable ; aucune tâche au statut Vert.
E72	Les défauts de correspondance expliquaient les Rouge, mais l'absence de Vert persiste faute de couverture relationnelle démontrée.	`reports/pilot_correspondance_remediation_study.md; reports/pilot_relational_coverage_audit.md`	diagnostic étayé	Conclusion limitée au corpus local.
E73	Les tests unitaires de l'intervention local023 sont au nombre de 5 et réussissent.	`tests/test_local023_correspondance_intervention.py; sortie unittest locale`	fait observé	Ran 5 tests, OK.
E74	Les tests unitaires de rejouabilité local023 sont au nombre de 7 et réussissent.	`tests/test_local023_reproducibility_study.py; sortie unittest locale`	fait observé	Ran 7 tests, OK.
E75	Les tests unitaires de la grille v1 sont au nombre de 9 et réussissent.	`tests/test_grille_viabilite_v1.py; sortie unittest locale`	fait observé	Ran 9 tests, OK.
E76	Les tests unitaires de sensibilité des correspondances sont au nombre de 7 et réussissent.	`tests/test_pilot_correspondance_sensitivity_audit.py; sortie unittest locale`	fait observé	Ran 7 tests, OK.
E77	Les tests unitaires de correction sont au nombre de 7 et réussissent.	`tests/test_pilot_correspondance_remediation_study.py; sortie unittest locale`	fait observé	Ran 7 tests, OK.
E78	Les tests unitaires de couverture relationnelle sont au nombre de 6 et réussissent.	`tests/test_pilot_relational_coverage_audit.py; sortie unittest locale`	fait observé	Ran 6 tests, OK.
E79	Le test d'intégrité historique local023 échoue en signalant les sept divergences attendues de la reconstruction non corrigée.	`tests/test_local023_reconstruction_integrity.py; sortie unittest locale`	fait observé	Détecteur du défaut historique, non preuve de correction.

Annexe A.3 - Registre de preuves, entrées E55 à E79.

Annexe B - Filiation des colonnes critiques de local023

La filiation suivante explicite le mécanisme observé. Chaque clé française est présente dans les lignes sources suivies, alors que la colonne anglaise attendue par l'insertion historique est absente comme clé de dictionnaire. Le résultat de `row.get(col)` est donc NULL avant l'intervention contrôlée. L'annexe ne généralise pas ce mécanisme à des fichiers ou à des environnements qui n'ont pas été audités [E53-E54].

Table et colonne cible	Clé source française	État historique	État après correspondance explicite
match.season_id	id_de_saison	NULL dans la reconstruction historique suivie	Valeur source restaurée.
match.match_id	id_de_match	NULL dans la reconstruction historique suivie	Valeur source restaurée.
ball_by_ball.match_id	id_de_match	NULL dans la reconstruction historique suivie	Valeur source restaurée.
ball_by_ball.ball_id	id_de_balle	NULL dans la reconstruction historique suivie	Valeur source restaurée.
batsman_scored.runs_score	points_marques	NULL dans la reconstruction historique suivie	Valeur source restaurée.
player.player_id	id_joueur	NULL dans la reconstruction historique suivie	Valeur source restaurée.
player.player_name	nom_joueur	NULL dans la reconstruction historique suivie	Valeur source restaurée.

Annexe B.1 - Filiation des colonnes critiques suivies dans local023 [E53-E56].

Annexe C - Intervention et rejouabilité local023

La condition historique (BASELINE_HISTORIQUE) et la condition corrigée (CORRIGE_MAPPING) sont conservées dans des emplacements distincts. L'intervention ne modifie pas les éléments historiques. La correspondance est explicite et versionnée. L'étude de rejouabilité reconstruit deux fois chacune des conditions et compare une empreinte logique calculée de manière déterministe [E55-E60].

Élément	Résultat local documenté	Limite de portée
Intervention de correspondance	7 divergences critiques avant, 0 après ; statut Rouge → Ambre.	Ne rend pas local023 Vert.
Jointures / référence	Jointures nécessaires à 0 ; référence SQL à 0 ligne après correction.	Interprétation locale ; pas de conclusion sur un dataset externe.
Empreinte historique	afc1f3e7ec5c25b65790e74e53f98fb11debfbe7c1655f94c73614dc771ec7de	Identique entre deux reconstructions historiques.
Empreinte corrigée	226d321fad13b5ed2e5ea908ce2d77c3332d9975e91aaf6f11ed420c6ca1f32a	Identique entre deux reconstructions corrigées.
Écart entre conditions	Empreintes différentes.	Démontre une modification logique locale, pas une généralisation multi-machine.

Annexe C.1 - Résumé de l'intervention et de la rejouabilité local023 [E55-E60].

Annexe D - Grille de viabilité

La grille versionnée introduit une différence de nature entre les trois statuts. Rouge signale un défaut critique démontré ; Ambre conserve une tâche techniquement partielle mais hors calcul d'un score d'exactitude ; Vert exige une preuve positive sur toutes les conditions nécessaires. Le jeu des 20 statuts confirme la cohérence déterministe de cette logique avec l'audit local, mais ne constitue pas une validation indépendante de la grille [E61-E62].

Statut	Règle de décision	Conséquence
Rouge	Défaut critique démontré de reconstruction ou d'interprétation minimale.	Corriger, exclure ou documenter le défaut ; aucun score.
Ambre	Environnement partiellement exploitable mais condition de calcul d'un score d'exactitude absente, ambiguë ou non établie.	Audits et ingénierie possibles ; aucun score.
Vert	Toutes les conditions V1 à V7 sont positivement établies.	Candidat à une évaluation d'exactitude sous protocole figé.

Annexe D.1 - Règles de décision de la grille Vert / Ambre / Rouge [E61].

Annexe E - Sensibilité, correction et couverture relationnelle

Le séquençement des études est important : l'audit de sensibilité identifie les cas de divergence ; la correction ne porte que sur les correspondances démontrées ; la couverture relationnelle vérifie ensuite si une perte persiste à l'import ou si la limite se situe dans les sources ou dans les preuves disponibles. Cette annexe rassemble les trois étapes sans les confondre [E63-E72].

Étude	Résultat principal	Décision méthodologique
Sensibilité des 20 tâches	9 sans divergence détectée ; 7 divergences démontrées ; 4 possibles non établies.	Ne pas corriger les cas ambigus par heuristique.
Correction de six tâches	351 divergences avant, 0 après ; 6 Rouge → 6 Ambre.	Aucune promotion Vert sans preuve relationnelle.
Consolidation	20 tâches Ambre, aucune Rouge ni Verte.	Aucun score agent autorisé.
Couverture relationnelle	16 relations non établies ; 4 tâches avec relation absente dans l'échantillon source ; 12 relations nécessaires absentes ; 0 perdue à l'import.	La limite résiduelle est relationnelle ou probatoire, non une perte résiduelle démontrée à l'import.

Annexe E.1 - Synthèse des études sur le pilote [E63-E72].

Annexe F - Validation post-exécution Codex sur local023

La validation post-exécution établit que le fichier `answer.json` produit par Codex est valide au format JSON, que son statut exact est `abstain` — c'est-à-dire une abstention — et que la requête extraite peut être exécutée en lecture seule dans la base locale. Le résultat retourné est vide. Cette validation ne permet donc ni de déclarer la réponse correcte, ni de calculer un score. Elle est conservée comme trace de protocole [E29-E36].

Contrôle	Observation	Interprétation
Processus	Code de sortie 0 ; durée 94,423 secondes.	Exécution terminée, pas une preuve d'exactitude.
Format de sortie	<code>answer.json</code> présent et valide au format JSON ; statut <code>abstain</code> .	Sortie structurée conforme au protocole local.
SQL	Requête en lecture seule exécutable.	Exécutabilité distincte de la validité analytique.
Résultat	0 ligne.	Pas de résultat interprétable pour une tâche non Vert.
Artefacts	Aucune modification d'entrée ni fichier inattendu détecté par le programme d'exécution.	Contrôle pratique local, non preuve de sécurité système formelle.

Annexe F.1 - Lecture contrôlée de l'exécution Codex local023 [E29-E36].

Annexe G - Registre des scripts, commandes et tests exécutés

Étude	Commande	Résultat documenté	Preuve
Intervention local023	<code>python -m unittest discover -s tests -p "test_local023_correspondance_intervention.py" -v</code>	5 tests, OK	[E73]
Rejouabilité locale de local023	<code>python -m unittest discover -s tests -p "test_local023_reproducibility_study.py" -v</code>	7 tests, OK	[E74]
Grille de viabilité v1	<code>python -m unittest discover -s tests -p "test_grille_viabilite_v1.py" -v</code>	9 tests, OK	[E75]
Sensibilité des correspondances	<code>python -m unittest discover -s tests -p "test_pilot_correspondance_sensitivity_audit.py" -v</code>	7 tests, OK	[E76]
Correction des six tâches	<code>python -m unittest discover -s tests -p "test_pilot_correspondance_remediation_study.py" -v</code>	7 tests, OK	[E77]
Couverture relationnelle	<code>python -m unittest discover -s tests -p "test_pilot_relational_coverage_audit.py" -v</code>	6 tests, OK	[E78]
Intégrité historique local023	<code>python -m unittest discover -s tests -p "test_local023_reconstruction_integrity.py" -v</code>	Détecte les 7 divergences historiques ; échec attendu, non compté comme validation.	[E79]

Annexe G.1 - Commandes et résultats de tests documentés.

Annexe H - Limites ouvertes et conditions de poursuite

Les travaux réalisés n'ont pas résolu toutes les questions. Les éléments suivants restent explicitement ouverts et encadrent toute prolongation du projet.

- validation de la grille par un second évaluateur appliquant les règles sans connaître les statuts historiques
- application du protocole à un corpus indépendant et à des tâches dont la viabilité est connue
- réplique sur une autre machine, avec documentation des versions et des différences d'environnement
- identification ou construction de tâches au statut Vert permettant une évaluation complète de bout en bout
- expérimentation d'un échantillonnage préservant les relations nécessaires aux jointures
- comparaison d'agents uniquement après qualification positive du support de mesure
- vérification complète des licences, versions et droits de redistribution des ressources
- définition éventuelle d'une métrique distincte pour les abstentions justifiées et les diagnostics de données insuffisantes

Ces limites ne doivent pas être masquées. Elles définissent les conditions nécessaires à la poursuite scientifique du projet et empêchent de présenter comme validées des étapes qui ne le sont pas encore.

Annexe I - Guide détaillé d'application du protocole

Cette annexe présente une version opérationnelle du protocole. Elle s'adresse à une personne souhaitant déterminer si un environnement de données peut être utilisé pour évaluer des agents chargés de produire ou d'exécuter des requêtes SQL. Le guide ne remplace pas l'analyse experte ; il fournit une structure minimale afin de ne pas omettre les contrôles dont l'importance a été démontrée.

Annexe I.1. Informations à réunir avant l'audit

Élément	Question de contrôle
Question en langage naturel	Quelle formulation exacte est remise à l'agent ?
Schéma relationnel	Quelles tables, colonnes et relations sont attendues ?
Données sources	Quels fichiers ou quelles bases alimentent l'environnement ?
Requête SQL de référence	Quelle requête est utilisée comme point de comparaison ?
Procédure de reconstruction	Quelles transformations sont appliquées aux sources ?
Version des scripts	Quelle version produit la base auditée ?
Configuration d'exécution	Quelles options, limites et autorisations sont appliquées ?
Empreintes des entrées	Les fichiers sont-ils identifiables sans ambiguïté ?

Tableau A1 - Informations à réunir avant l'audit.

L'absence de l'un de ces éléments ne signifie pas nécessairement que la tâche est inutilisable. Elle constitue toutefois une limite de traçabilité qui doit être enregistrée et prise en compte dans la qualification.

Annexe I.2. Étape 1 - Vérifier la provenance

Déterminer le chemin exact des fichiers, leur origine déclarée, leur date ou leur version lorsqu'elle est connue, les transformations déjà appliquées et les éventuelles restrictions de licence.

La provenance ne doit pas être déduite du seul nom d'un dossier. La formulation doit rester descriptive lorsque l'identité officielle n'est pas démontrée.

Annexe I.3. Étape 2 - Vérifier la reconstruction technique

Contrôler l'existence du fichier, son ouverture en lecture seule, la reconnaissance du format SQLite, le résultat de PRAGMA quick_check, la présence des tables attendues, l'extraction du schéma, le comptage des lignes et l'absence d'erreur critique pendant la génération.

Ces contrôles écartent les fichiers corrompus ou manifestement incomplets, mais ils ne suffisent pas à attribuer le statut Vert.

Annexe I.4. Étape 3 - Identifier les éléments nécessaires à la tâche

À partir de la question, du schéma et de la requête de référence, dresser la liste des tables, colonnes, filtres, agrégations, relations et valeurs indispensables à la réponse.

L'objectif n'est pas de résoudre une nouvelle fois la tâche, mais de définir ce dont la présence doit être vérifiée.

Annexe I.5. Étape 4 - Vérifier la filiation des colonnes

Pour chaque colonne critique, suivre la donnée depuis la clé du fichier source jusqu'à la colonne cible et à la valeur réellement présente dans SQLite.

Comparer les nombres de valeurs non nulles dans la source et dans la base, puis expliquer chaque divergence. Toute correspondance entre deux noms doit être explicite, versionnée et limitée à ce que les fichiers permettent de démontrer.

Annexe I.6. Étape 5 - Vérifier les relations

Lorsqu'une requête utilise une jointure, mesurer les valeurs non nulles de chaque côté, l'intersection des ensembles de clés, le nombre de lignes produit par la jointure minimale et l'évolution de ces indicateurs entre la source et la base reconstruite.

Cette étape distingue une relation absente dans les sources d'une relation perdue pendant l'importation.

Annexe I.7. Étape 6 - Exécuter la requête de référence

Exécuter la requête sur la version exacte de la base destinée à l'agent et enregistrer le succès ou l'échec, les colonnes retournées, le nombre de lignes, les valeurs obtenues et l'interprétabilité du résultat.

Un résultat vide n'est pas automatiquement une erreur, mais il doit pouvoir être expliqué. À défaut, la tâche ne peut pas être Verte.

Annexe I.8. Étape 7 - Vérifier la rejouabilité

Lorsque la reconstruction ou une correction joue un rôle important, la répéter à partir d'un environnement neuf. Comparer les entrées, les paramètres, le nombre de tables et de lignes, les contrôles, les empreintes logiques et les statuts.

Une répétition identique dans le même environnement établit une rejouabilité locale ; elle ne remplace pas une réplication indépendante.

Annexe I.9. Étape 8 - Attribuer le statut

Rouge : un défaut critique démontré empêche la reconstruction, la conservation des valeurs ou l'interprétation minimale.

Ambre : aucun défaut critique non corrigé n'empêche l'exploration, mais une preuve nécessaire à la mesure manque ou demeure ambiguë.

Vert : la provenance, la validité technique, les valeurs, les relations, la référence et la rejouabilité nécessaires sont positivement établies.

Annexe I.10. Modèle de fiche synthétique de qualification

Rubrique	Information à renseigner
Identifiant de la tâche	À renseigner
Question	À reproduire intégralement
Base utilisée	Nom, chemin et version
Sources de données	Fichiers, versions et empreintes
Schéma vérifié	Oui / Non / Non établi
Valeurs critiques présentes	Oui / Non / Partiellement
Divergences source → base	Nombre, colonnes et preuves
Jointures fonctionnelles	Oui / Non / Non établi
Résultat de référence	Résultat, nombre de lignes et interprétation
Rejouabilité vérifiée	Oui / Non / Non applicable
Statut	Vert / Ambre / Rouge
Justification	Décision rattachée aux preuves
Limites	Incertitudes et portée résiduelle
Décision	Évaluer / Maintenir hors score / Réauditer

Tableau A2 - Modèle de fiche synthétique de qualification d'une tâche.

Ce tableau est un modèle à dupliquer pour chaque tâche. Les mentions de la seconde colonne indiquent les informations attendues et ne constituent pas des résultats. Il n'a pas encore fait l'objet d'une validation indépendante par plusieurs évaluateurs.

Annexe J - Chronologie méthodologique détaillée

Annexe J.1. Objectif initial

Le projet avait initialement pour objectif de comparer plusieurs agents sur des tâches d'analyse SQL formulées en français. La démarche prévue consistait à sélectionner les questions, reconstruire les bases, créer un espace de travail comparable, exécuter les agents et comparer leurs résultats.

Annexe J.2. Préparation de l'environnement

La reconstruction locale a produit des bases SQLite techniquement valides. Les premiers contrôles portaient sur la présence des fichiers, la validité des bases, la disponibilité des schémas et la capacité des scripts à préparer les espaces de travail.

Annexe J.3. Apparition des premières limites

Les vérifications approfondies ont montré que certaines requêtes de référence retournaient zéro ligne et que plusieurs colonnes critiques ne contenaient pas les valeurs attendues. La campagne comparative a alors été suspendue. La question est devenue : l'environnement permet-il réellement de distinguer une bonne réponse d'une mauvaise réponse ?

Annexe J.4. Étude de cas et démonstration causale

La tâche local023 a été examinée en détail. L'audit a mis en évidence une incompatibilité entre les clés françaises des fichiers JSON et les colonnes anglaises attendues par la procédure d'importation. La correction contrôlée a supprimé sept divergences critiques sans rendre la tâche évaluable.

Annexe J.5. Extension au pilote

Le mécanisme a ensuite été recherché sur les vingt tâches. Six autres tâches ont été corrigées, ce qui a supprimé 351 divergences supplémentaires. Le bilan cumulé s'établit à 358 divergences supprimées.

Annexe J.6. Audit relationnel

Après correction, les vingt tâches étaient Ambre. Certaines relations nécessaires étaient absentes des échantillons sources ; d'autres ne pouvaient pas être établies avec les preuves

disponibles ; aucune perte relationnelle résiduelle à l'importation corrigée n'était démontrée ; aucune tâche ne produisait un résultat de référence interprétable.

Annexe J.7. Décision finale

La campagne comparative n'a pas été relancée. La décision finale est de ne pas calculer de score d'agent dans cet environnement. Cette décision constitue l'aboutissement logique du protocole de qualification et non une interruption arbitraire de l'expérience.

Annexe K - Extrait de code et règle de lecture

Les scripts complets ne sont pas reproduits dans le mémoire. Seul l'extrait indispensable à la compréhension du mécanisme causal est conservé. Il s'agit de l'instruction historique suivante :

```
row.get(col)
```

Le programme cherche une clé portant exactement le nom de la colonne cible. Lorsque col vaut match_id alors que la ligne source contient uniquement id_de_match, l'appel ne retrouve pas la valeur ; celle-ci est ensuite enregistrée comme NULL dans SQLite.

Les correspondances correctives sont conservées dans des configurations versionnées. Aucun pseudo-code supplémentaire n'est reproduit ici afin d'éviter toute différence entre une formulation illustrative et l'implémentation réellement testée. Les scripts complets appartiennent au paquet de reproduction, sous réserve des droits de diffusion applicables.

Annexe L - Registre synthétique des tests automatisés

Étude	Périmètre	Nombre de tests	Résultat
Intervention sur local023	Correction de correspondance	5	Réussis
Rejouabilité de local023	Comparaison des reconstructions	7	Réussis
Grille de viabilité	Application des règles de décision	9	Réussis
Audit de sensibilité	Analyse des vingt tâches	7	Réussis
Correction des six tâches	Remédiation contrôlée	7	Réussis
Couverture relationnelle	Analyse des relations nécessaires	6	Réussis
Total		41	Réussis

Tableau A3 - Registre synthétique des tests automatisés.

Le test historique destiné à détecter les sept divergences initiales de local023 échoue volontairement lorsqu'il est exécuté sur la reconstruction non corrigée. Il n'est pas inclus dans les quarante et un tests présentés comme réussis. Son intérêt est diagnostique : il démontre que le défaut historique reste détectable.

Annexe M - Règles de formulation scientifique

Afin de ne pas dépasser les preuves disponibles, les formulations suivantes sont appliquées à l'ensemble du document.

Formulation à éviter	Formulation retenue
« Le référentiel officiel contient des erreurs »	« La reconstruction locale étudiée présente des défauts documentés »
« Les agents ont échoué »	« Les exécutions observées ne permettent pas d'établir une mesure d'exactitude »
« La méthode est universelle »	« La méthode est proposée et éprouvée dans le périmètre local étudié »
« La correction rend les tâches valides »	« La correction supprime les divergences ciblées, mais les tâches restent Ambre »
« Les relations n'existent pas »	« Les relations sont absentes des échantillons étudiés ou ne sont pas établies »
« La grille est validée scientifiquement »	« La grille reproduit les décisions historiques sans divergence dans le corpus étudié »
« Le résultat est parfaitement reproductible »	« Le résultat est rejouable dans l'environnement local documenté »

Tableau A4 - Règles de formulation scientifique.

Annexe N - Matrice de conservation des résultats et éléments scientifiques

Cette annexe vérifie que les résultats, limites et éléments méthodologiques validés au cours de la recherche restent présents dans la version finale. Elle ne remplace pas le registre de preuves : elle indique où chaque élément majeur est traité et à quelles preuves il est relié.

Tableau A5 - Matrice de conservation des résultats et éléments scientifiques.

Élément conservé	Contenu scientifique maintenu	Localisation dans le mémoire
Inventaire du corpus local	547 questions françaises, 123 tâches liées à des bases SQLite, 29 bases distinctes et 20 tâches pilotes.	Résumé ; 3.2 ; tableau 2 ; [E01-E05]
Limite des données locales	Échantillons généralement limités à cinq lignes par table ; environnement non assimilé à une distribution officielle.	Avertissement ; 3.3-3.5 ; 6.7.3 ; [E05-E08]
Audit initial	13 tâches Ambre, 7 tâches Rouge et aucune tâche Verte.	5.2 ; tableau 4 ; [E13-E19]
Cas local023	Base IPL de 8 tables et 40 lignes ; sept colonnes critiques suivies.	5.3 ; tableau 5 ; annexes B et K ; [E09-E10, E51-E54]
Cause démontrée	Clés JSON françaises, colonnes anglaises et insertion historique par row.get(col), produisant des valeurs NULL.	5.3 ; figure 4 ; annexe K ; [E53-E54]
Intervention contrôlée	Sept divergences avant correction, zéro après ; passage de Rouge à Ambre, sans promotion Verte.	5.4 ; tableau 6 ; annexe C ; [E55-E56]
Rejouabilité locale	Deux reconstructions historiques identiques entre elles, deux reconstructions corrigées identiques entre elles, empreintes différentes entre conditions.	5.5 ; tableau 7 ; figure 5 ; [E57-E60]
Grille Vert / Ambre / Rouge	Sept règles minimales ; rejeu de 20 statuts sur 20 sans divergence ; validation externe non établie.	4.2-4.9 ; 5.6 ; tableaux 3 et 8 ; [E61-E62]
Audit de sensibilité	9 tâches sans divergence détectée, 7 avec divergence démontrée et 4 avec divergence possible non établie.	5.7 ; tableau 9 ; [E63-E64]
Correction des six autres tâches	351 divergences supplémentaires supprimées ; six tâches Rouge deviennent Ambre.	5.8 ; tableau 10 ; [E65-E67]
Bilan des divergences	358 divergences critiques supprimées au total ; distribution finale de 20 tâches Ambre, 0 Rouge et 0 Verte.	5.10 ; tableau 12 ; [E68]
Couverture relationnelle	16 tâches avec relation non établie, 4 avec relation absente dans l'échantillon source, 12 relations nécessaires absentes et 0 perte relationnelle résiduelle démontrée à l'import.	5.9 ; tableau 11 ; figure 6 ; [E69-E72]
Résultats de référence	Aucune tâche du pilote ne fournit un résultat de référence suffisamment interprétable pour autoriser une mesure d'exactitude.	5.9-5.10 ; 6.4 ; [E71-E72]
Exécution Vibe	Non-finalisation sous la configuration documentée ; aucun fichier answer.json produit.	5.11 ; tableau 13 ; annexe A ; [E24-E28]
Exécution Codex	Sortie answer.json valide, statut abstain, requête en lecture seule exécutable et résultat de zéro ligne ; exactitude non établie.	5.11 ; tableau 13 ; annexe F ; [E29-E36]
Absence de résultat Gemini	Aucun résultat expérimental attribué à Gemini faute d'artefact local documenté.	Avertissement ; 1.8 ; 5.11 ; [E52]

Élément conservé	Contenu scientifique maintenu	Localisation dans le mémoire
Tests automatisés	41 tests réussis sur les études principales ; un test historique échoue volontairement en détectant les sept divergences attendues.	4.5 ; annexe L ; [E73-E79]
Décision scientifique	Aucun classement d'agents n'est publié ; la mise hors score est motivée par l'absence de tâche Verte.	Résumé ; 6.4 ; 7.4-7.6 ; [E68-E72]
Limites majeures	Pas de second évaluateur, pas de corpus indépendant, pas de tâche Verte, pas de réplication multi-machine et provenance complète non certifiée.	6.7 ; 6.12 ; annexe H
Contribution principale	Protocole préalable articulant provenance, reconstruction, valeurs, relations, référence, rejouabilité et décision de mesure.	1.7 ; 4 ; 6.11 ; 7.3

La matrice confirme la conservation de l'ensemble des résultats empiriques et des limites méthodologiques majeures. Les formulations ont été harmonisées et certaines répétitions supprimées, mais aucun résultat validé n'a été remplacé par une conclusion plus favorable.